

Statistiques Inferentielles

Programme :

I - Introduction → Définition

II - Echantillonnage → Cadre probabiliste.

III - Estimation

IV - Comportement asymptotique.

V - Généralités sur les tests.

VI - Un peu de stats non paramétriques.

Chapitre 0 : Introduction

Définition: On dit qu'on se trouve face à un problème statistique si :

- On est confronté à des éventualités, en nombre fini ou infini, dont on sait qu'au moins une est vraie
- On doit choisir une de ces éventualités
- On se basant sur les résultats d'une expérience aléatoire (à définir au préalable)

Exemple: On veut étudier la distribution du montant de sinistres auto.

On suppose que la distribution est une Gamma.

Les éventualités sont l'ensemble des paramètres possibles pour la loi Gamma i.e. $\mathbb{R}^+ \times \mathbb{R}^+$

On va choisir les bons paramètres en se basant sur les montants des sinistres observés.

Définition: On appelle modèle statistique le triplet $(\mathcal{X}, \mathcal{A}, \mathcal{P})$ où

- \mathcal{X} est l'ensemble fondamental ou l'espace des résultats i.e l'endroit où vivent les observations.
- \mathcal{A} est la tribu associée à \mathcal{X} (la priori on ne s'en sera pas).
- \mathcal{P} est une famille de probabilités définies sur $(\mathcal{X}, \mathcal{A})$ qui contient la distribution qui a générée les observations.

On dira que $(\mathcal{X}, \mathcal{A}, \mathcal{P})$ est un modèle statistique paramétrique si:

$$\exists p \in \mathbb{N} \text{ tq } \mathcal{P} = \{ P_\theta, \theta \in \Theta \subseteq \mathbb{R}^p \}$$

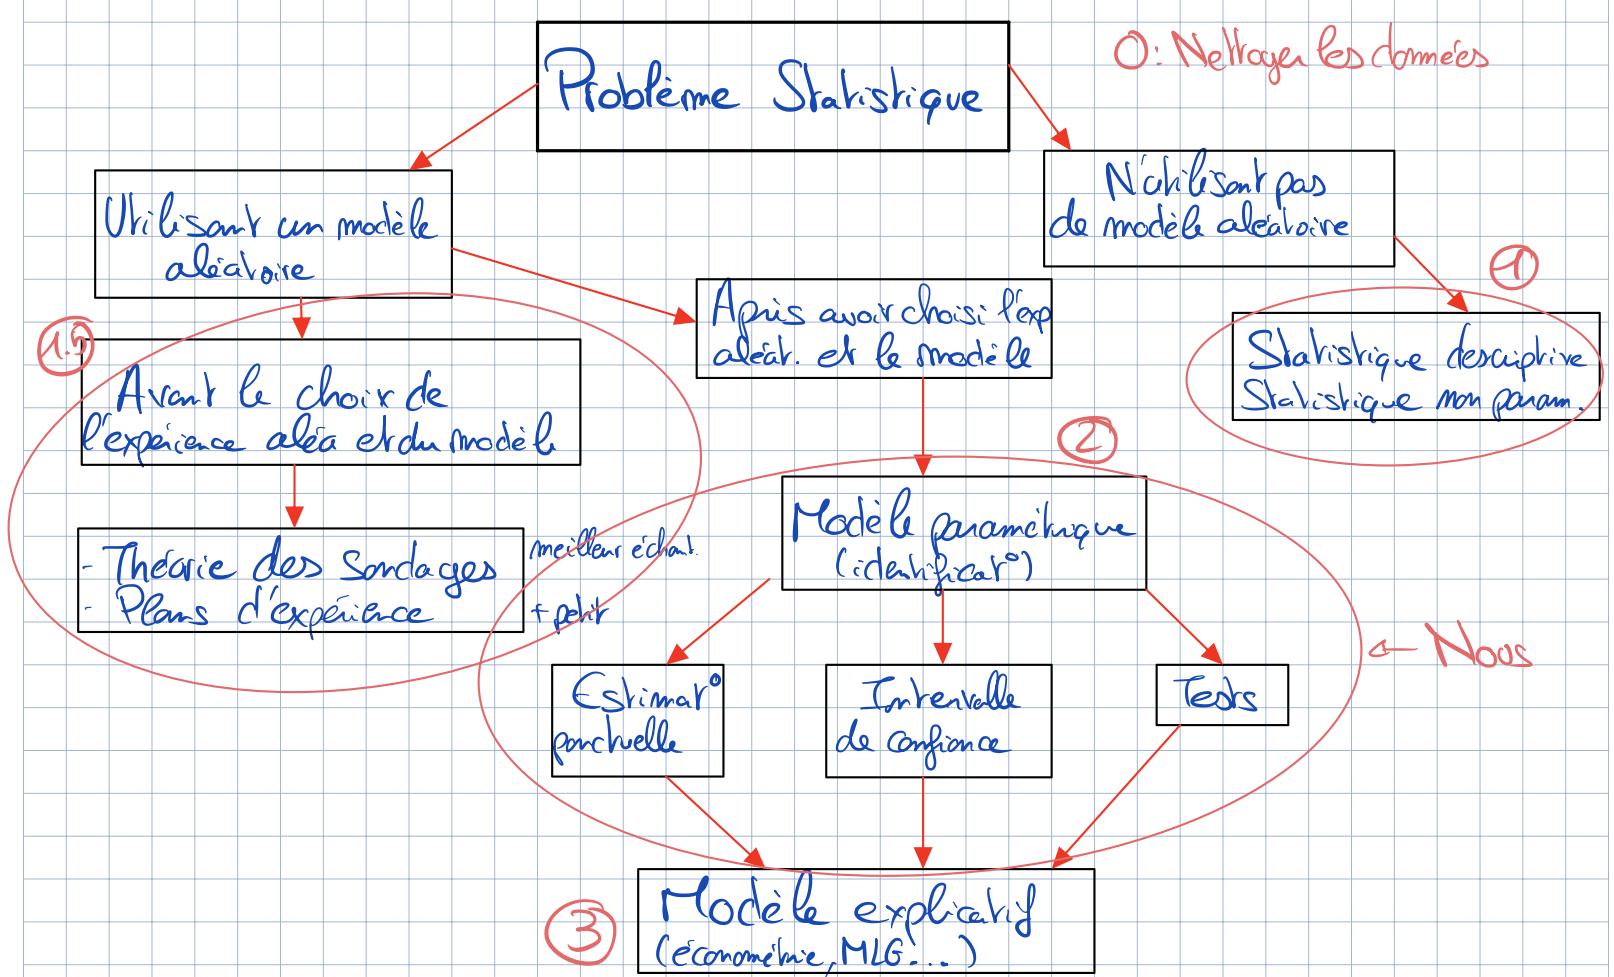
distribution indexée
par un paramètre

espace des paramètres
i.e. là où vit le paramètre

Exemple: $\mathcal{B} = \left\{ \underbrace{\Gamma(a, b)}_{P_0} : \underbrace{(a, b) \in \mathbb{R}_+^* \times \mathbb{R}_+^*}_{\Theta} \subseteq \underbrace{\mathbb{R}^2}_{H} \right\}$

Remarque: On va distinguer 3 types de problèmes:

- estimation ponctuelle : on se place dans le modèle paramétrique, les "éventualités" sont représentées par Θ et on veut choisir θ .
- estimation ensembliste ou par intervalle de confiance : on va choisir un ensemble ou un intervalle qui va contenir le "vrai" paramètre avec une proba élevée.
- Tests : On fait une hypothèse sur la distribution et on compare au résultat obtenu sur les observations. On doit "juste" choisir entre vrai ou faux (pour l'hypothèse).



Chapitre I : Echantillonnage.

I - Modèle Statistique

Soit $X = (X_1, \dots, X_m)$ un vecteur aléatoire de m VA.

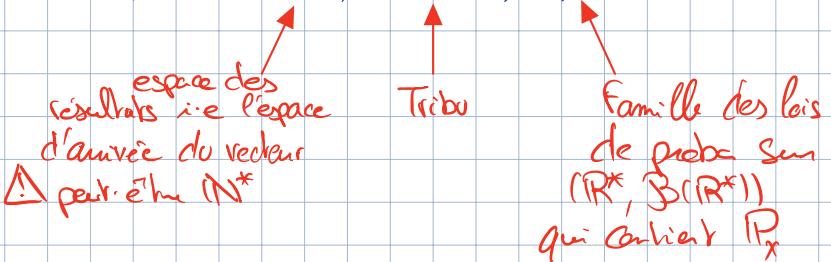
$$X_i : (\Omega, \mathcal{B}, P_x) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}), P_x) \quad X : (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m), P_x)$$

P_x est la loi de probabilité image du vecteur X .

En général, on ne connaît pas P_x et on veut l'approximer le mieux possible.

Hypothèse fondamentale: La proba P_x appartient à une famille de lois de probas (déf sur $(\mathbb{R}^*, \mathcal{B}(\mathbb{R}^*))$) notée \mathcal{P}_x

Modèle d'échantillonnage: C'est le triplet $(\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m), \mathcal{P}_x)$



Remarque: Le choix de la famille \mathcal{P}_x est crucial (risque de modèle)

On se base sur des études précédentes, sur la Stat. non paramétrique ou sur un expert.

Définition: Une série statistique (x_1, \dots, x_m) est une réalisat° du vecteur aléatoire i.e $\exists w \in \Omega \quad (x_1, \dots, x_m) = (X_1(w), \dots, X_m(w))$.

Le modèle d'échantillonnage indépendant est un cas particulier où on considère X_1, \dots, X_m indép et identiquement distribuées.

On a les propriétés suivantes :

- les VA sont identiquem° distrib., elles ont m° loi de P_x ; ne dépend pas de i et de $i \in \{1, m\}$ $P_{x_i} = P$
- les VA sont indép, la loi du vecteur est la loi produit $P_X = P^{\otimes m}$

De manière abusive, on note le modèle d'échantillonnage cindep.

$$(R, \mathcal{B}(R), P)^m$$

↗
 espace des résultats
 ↗
 Tribu
 ↗
 famille de lois de probas qui contient la "vraie" proba P

à l'extérieur pour que les va sont iid et c'est la taille de l'échantillon.

Le modèle d'échantillonnage (cindep) paramétrique est le cas où la famille P est induite par un paramètre θ

$$P = \{P_\theta, \theta \in \Theta \subseteq \mathbb{R}^p\}$$

↗
 loi de proba qui correspond à la valeur θ du paramètre
 ↗
 param.
 ↗
 espace des param.
 i.e. les valeurs possibles du param.

dimensions de paramètre

Remarque: Si mom on a un modèle non paramétrique

Exemple: On peut prendre un modèle $(R, \mathcal{B}(R), P)^m$

$$\text{où } P = \{f_\lambda : f \geq 0 \text{ sur } \mathbb{R}, \int f d\lambda = 1\}$$

= ensemble des distributions qui admettent une densité prr à Lebesgue

Exemple: Si on considère des va X_1, \dots, X_m iid tq $X_i \sim N(\mu, \sigma^2)$

Le modèle stat est

$$(R, \mathcal{B}(R), \underbrace{N(\mu, \sigma^2)}_{P_\theta}, \underbrace{(\mu, \sigma^2)}_{\theta} \in \mathbb{R} \times \mathbb{R}^+ \subseteq \mathbb{R}^{2+p})^m$$

Hypothèse fondamentale: Le modèle est dominé par une mesure μ

Rappel (ou pas): Soit P et μ deux mesures sur $(R, \mathcal{B}(R))$, on dit que P est absolument continue prr à μ ou μ domine P (note $P \ll \mu$)

$$\text{Si } \forall A \in \mathcal{B}(R^*), \mu(A) = 0 \Rightarrow P(A) = 0$$

Rappel: Radon-Nikodym: Si $P \ll \mu$, alors il existe une fonction f telle que

$$\mathbb{E}^P(X) = 1 \text{ et } P(A) = \int_A f d\mu.$$

© Théo Jalabert

TFM

Ici: X est juste une fonction qui intègre à 1 par rapport à μ

On dit que le modèle est dominé par une mesure μ si toutes les probas P_x dans \mathcal{P}_X sont dominées par μ i.e. $\forall P_x \in \mathcal{P}_X, P_x \ll \mu$.

Dans ce cas, il existe une fonction f_X (Radon-Nikodym) telle que $P_x = f_X \cdot \mu$ (i.e. $P_x(A) = \int_A f_X d\mu$)

La fonction f_X est la vraisemblance du modèle (likelihood en anglais)

$$\text{notée } L_X(x) = f_X(x)$$

Traduct° - Exemple: Si le modèle est dominé par λ alors la loi P_X admet une

densité par rapport à λ et $L_X(x) = f_X(x)$ densité du vecteur X .

$$x \in \mathbb{R}^n$$

Dans le cas d'un modèle d'échantillonnage indép. $(R, \mathcal{B}(R), P_\theta, \theta \in \Theta)$ est dominé ssi $(R, \mathcal{B}(R), P_\theta, \theta \in \Theta)$ est dominé.

Dans ce cas là, on a

$$L_X(x_1, \dots, x_n, \theta) = \underbrace{f_{X_1}(x_1)}_{\text{densité de } X} \cdots \underbrace{f_{X_n}(x_n)}_{\text{densité de } X} = f_\theta(x_1) \cdots f_\theta(x_n) = \prod_{i=1}^n f_\theta(x_i)$$

les f_{X_i} sont égaux produit des densités de X_i .

Dans le cas de lois discrètes, on peut construire une mesure μ (mesure de Compte) telle que

$$\mu = \sum_{m \in \mathbb{N}} \delta_m$$

mesure de Dirac en m
i.e. $\delta_m(A) = 1$ si $m \in A$ et 0 sinon

et telle que $P_\theta \ll \mu$ (ex. Poisson, ...)

la densité est la fonction de masse et on a $L_X(x_1, \dots, x_n, \theta) = \prod_{i=1}^n P_\theta(X_i = x_i)$

Remarque: La vraisemblance du modèle $L_X(x_1, \dots, x_n, \theta)$ est l'outil de base

Dans le cas discret $L(x_1, \dots, x_n, \theta)$ est la proba d'observer x_1, \dots, x_n sous le paramètre θ

Si on fixe x_1, \dots, x_m , $\ell(x_1, \dots, x_m, \theta)$ est élevée, + la proba est relevée et + le paramètre θ est "vraisemblable"

On va souvent utiliser la log-vraisemblance i.e. $\ell(x_1, \dots, x_m, \theta) = \log L(x_1, \dots, x_m, \theta)$

II - Définit° d'une statistique

On se place dans le modèle général $(\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m), P_x)$ une statistique est une VA définie sur $(\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m))$

Idee: Dans un modèle paramétrique, on veut que la statistique apparte de l'infométrie pour approcher θ . Elle ne doit pas dépendre (son écriture) de la famille P_θ

D'habitude on note la statistique T_m .

Définit°: Une statistique est une fonction de x_1, \dots, x_m

$$T_m = h(x_1, \dots, x_m)$$

} Pas la "vraie"
} définit° d'une
} star

Exemple: On prend x_1, \dots, x_m iid tq $x_i \sim \mathcal{N}(\mu, 1)$

Le modèle stat associé est $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathcal{N}(\mu, 1), \mu \in \mathbb{R} \subseteq \mathbb{R}^1)^m$

On peut prendre $T_m = \frac{1}{m} \sum_{i=1}^m x_i$

L'écriture ne dépend pas de μ

On a :

- la loi des grands nombres dit que $\frac{1}{m} \sum_{i=1}^m x_i \xrightarrow{\text{P}} \mathbb{E}[x_i] = \mu$

- On peut calculer la loi de T_m .

T_m suit une loi Gaussienne comme CL de Gaussiennes indép

$$\text{On a } \mathbb{E}[T_m] = \mathbb{E}\left(\frac{1}{m} \sum_{i=1}^m x_i\right) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}[x_i] = \mu$$

$$\text{et } V(T_m) = V\left(\frac{1}{m} \sum_{i=1}^m x_i\right) = \frac{1}{m^2} \sum_{i=1}^m V(x_i) = \frac{1}{m}$$

$$\Rightarrow T_m \sim \mathcal{N}\left(\mu, \frac{1}{m}\right)$$

Remarque: On distingue la statistique $T_m = \underline{h(x_1, \dots, x_m)}$ et la statistique observée $\underline{h(x_1, \dots, x_m)} \in \mathbb{R}$

Rappel: On a x_1, \dots, x_m données

- Statistiques descriptives : On a des observ° et on décrit les données
- Statistiques Inferentielles : On considère les observ° comme des réalisat° de v.a. et on veut des infos sur ces v.a. \Rightarrow Modèle proba.

Notre modèle : On considère X_1, \dots, X_m comme des v.a. iid avec $X_i \sim P$

$$(R, \mathcal{B}(R), P)$$

↑
espace des résultats
- l'ensemble des résultats possibles pour X_i

↑
tribu

↑
famille de proba
qui contient la "vraie"
proba P

Dans le cours, on va supposer :

$$- \mathcal{P} = \mathcal{P}_\theta = \{P_\theta, \theta \in \Theta \subseteq \mathbb{R}^p\} \quad \text{et qui est de dimens° p.}$$

La proba est déterminée par un paramètre θ ↗ qui prend ses valeurs dans Θ

- Le modèle est dominé par μ i.e $HPC\mathcal{P}, P \ll \mu$

Critère: Si les distribut° P admettent une densit° ou une fonct° de masse, le modèle est dominé

On appelle vraisemblance, la densit° (plus à la mesure qui domine) du vecteur (X_1, \dots, X_m)

Dans notre cas, comme X_1, \dots, X_m iid, on a :

$$\underline{L(x_1, \dots, x_m, \theta)} = \prod_{i=1}^m f_\theta(x_i)$$

vraisemblance du modèle
= densité de (X_1, \dots, X_m) sous l'hypothèse θ

vraisemblance individuelle
= densité de X_i sous l'hypothèse θ

Définition (pas bonne): Une statistique est une fonct° de X_1, \dots, X_m dont l'écarture ne dépend pas de θ .

Un estimateur de $g(\theta)$ est une statistique à valeurs dans \mathbb{R} . On le note souvent T_m

Remarques:

* Un estimateur ne dépend pas de θ (son écriture ne dépend pas de θ) mais sa distribution dépend de θ .

* On peut parfois estimer une fonction de paramètre θ (par exemple la VAR_{0,05} i.e le quantile d'ordre 0,995), mais pour nous, souvent, $g(\theta) = \theta$

II - Notions de base sur les estimateurs

On se place dans le modèle $(\mathcal{R}, \mathcal{B}(\mathcal{R}), \mathbb{P}_\theta, \theta \in \Theta \subset \mathbb{R}^p)^m$

i.e X_1, \dots, X_n iid tq $X_i \sim \mathbb{P}_\theta$ et $\mathbb{P}_\theta \in \mathcal{B}_\theta$.

On prend un estimateur T_m , on veut qu'il apporte des infos sur $g(\theta)$ \rightarrow on va voir certains mots sur T_m

Définition: On appelle biais de l'estimateur T_m de $g(\theta)$ la quantité

$$B_{g(\theta)}(T_m) = E[T_m] - g(\theta) \quad \text{c'est une fonction de } \theta.$$

On dit que T_m est sans biais pour $g(\theta)$ si $B_{g(\theta)}(T_m) = 0$

Traduct°: Si T_m est sans biais alors il donne "en moyenne" la vraie valeur de $g(\theta)$

On dit que T_m est asymptotiquement sans biais pour $g(\theta)$ si $B_{g(\theta)}(T_m) \xrightarrow[m \rightarrow \infty]{} 0$

Définit°: On dit que T_m est convergent pour $g(\theta)$ si T_m converge en proba vers $g(\theta)$

i.e. $T_m \xrightarrow{P} g(\theta)$

i.e. $\forall \varepsilon > 0, \lim_{m \rightarrow \infty} P(|T_m - g(\theta)| > \varepsilon) \rightarrow 0$

ou

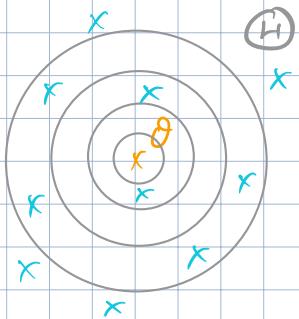
$\forall \varepsilon > 0, \lim_{m \rightarrow \infty} P(|T_m - g(\theta)| < \varepsilon) \rightarrow 1$

Critère de convergence :

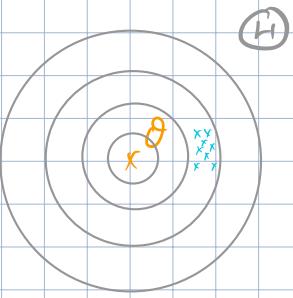
Si T_m est asymptotiquement sans biais pour $g(\theta)$ (i.e $E[T_m] \xrightarrow[m \rightarrow \infty]{} g(\theta)$ et $V(T_m) \xrightarrow[m \rightarrow \infty]{} 0$)

alors T_m est convergent pour $g(\theta)$.

Comparaison d'estimateurs :



$T_m^{(1)}$ est sans biais
mais grande variance



$T_m^{(2)}$ a du biais mais
une petite variance

Pour comparer deux estimateurs du m^e paramètre $g(\theta)$, on utilise le risque quadratique.

Il est défini par $R(T_m, g(\theta)) = \mathbb{E}[(T_m - g(\theta))^2]$

Propriété: $R(T_m, g(\theta)) = B_{g(\theta)}(T_m)^2 + V(T_m)$

Remarques :

* Si on a deux estimateurs, on choisira, en théorie, celui qui a le plus petit risque quadratique

* De manière générale, on essaye de minimiser le risque quadratique (en minimisant le biais car la variance est bornée inf. (Borne de Cramér-Rao))

Exemple: X_1, \dots, X_n iid tq $X_i \sim U(0; \theta)$.

2 façons d'estimer θ .

- On a la loi des grands nombres $\bar{X}_n \rightarrow \mathbb{E}[X]$
ici on a $\bar{X}_n \rightarrow \frac{\theta}{2}$ donc $2\bar{X}_n$ doit être un estimateur correct de θ .

- θ est la valeur max théorique de X_i , donc $\max_{i \in \{1, \dots, n\}} X_i$ doit être un estimateur pas dégueulasse de θ .

Quel estimateur est préférable au sens du risque quadratique ?

On pose $T_m = 2\bar{X}_n$ et $T_{\max} = \max_{i \in \{1, \dots, n\}} X_i$

Étude de T_m

© Théo Jalabert

- Biass de T_m :

$$\mathbb{E}[T_m] = \mathbb{E}[2\bar{X}_m] = 2 \mathbb{E}\left[\frac{1}{m} \sum_{i=1}^m X_i\right] = \frac{2}{m} \sum_{i=1}^m \mathbb{E}[X_i] = 0$$

$$B_\theta(T_m) = \mathbb{E}[T_m] - \theta = 0$$

- Variance de T_m :

$$V(T_m) = V\left(2 \times \frac{1}{m} \sum_{i=1}^m X_i\right) \stackrel{iid}{=} \frac{4}{m^2} \sum_{i=1}^m V(X_i) = \frac{\theta^2}{3m^2} \xrightarrow{m \rightarrow \infty} 0$$

$$= \frac{\theta^2}{\frac{m^2}{2}}$$

cl: T_m est convergent pour θ ou $T_m \xrightarrow{P} \theta$

Risque Quadratique de T_m :

$$R(T_m, \theta) = \mathbb{E}[(T_m - \theta)^2] = B_\theta(T_m)^2 + V(T_m) = V(T_m) = \frac{\theta^2}{3m}$$

Étude de T_{max} :

$$T_{max} = \max_{i \in \{1, \dots, m\}} X_i \quad \mathbb{E}[\max X_i] \neq \max \mathbb{E}[X_i].$$

Loi de T_{max} :

$$\begin{aligned} P(\max_{i \in \{1, \dots, m\}} X_i \leq x) &= P(X_1 \leq x, \dots, X_m \leq x) \\ &= \prod_{i=1}^m P(X_i \leq x) \\ F_{max}(x) &\stackrel{\text{indép iid}}{=} P(X_1 \leq x)^m = \left(\frac{x}{\theta}\right)^m \text{ si } x \in [0, \theta] \end{aligned}$$

Densité de T_{max} :

$$f_{max}(x) = \frac{mx^{m-1}}{\theta^m} I_{[0, \theta]}(x)$$

Biass de T_{max}

$$\begin{aligned} \mathbb{E}[T_{max}] &= \int x f_{max}(x) dx = \int_0^\theta x \frac{mx^{m-1}}{\theta^m} dx \\ &= \frac{m}{\theta^m} \left[\frac{x^{m+1}}{m+1} \right]_0^\theta = \frac{m}{m+2} \theta \end{aligned}$$

T_{max} est asymptotiquement sans biass car $\mathbb{E}[T_{max}] \xrightarrow{m \rightarrow \infty} \theta$

$$B_\theta(T_{max}) = \mathbb{E}[T_{max}] - \theta = -\frac{1}{m+2} \theta$$

Variance de T_{max} :

$$\mathbb{E}[T_{max}^2] = \int x^2 f_{max}(x) dx = \int_0^\theta \frac{mx^{m+1}}{\theta^m} dx = \frac{m}{\theta^m} \left[\frac{x^{m+2}}{m+2} \right]_0^\theta = \frac{m\theta^2}{m+2}$$

$$\mathbb{V}[T_{\max}] = \mathbb{E}[T_{\max}^2] - \mathbb{E}[T_{\max}]^2$$

$$= \frac{m\theta^2}{m+2} - \frac{(m\theta)^2}{(m+1)^2} = \frac{m\theta^2}{(m+1)^2(m+2)}$$

Risque Quadratique de T_{\max} :

$$\begin{aligned} R(T_{\max}, \theta) &= B_\theta (T_{\max})^2 + V(T_{\max}) = \frac{\theta^2}{(m+1)^2} + \frac{m\theta^2}{(m+1)^2(m+2)} \\ &= \frac{2\theta^2}{(m+1)(m+2)} \end{aligned}$$

On avait $R(T_m, \theta) = \frac{\theta^2}{3m}$

Pour $m=1$ ou $m=2$, $R(T_m, \theta) = R(T_{\max}, \theta)$

$\forall m \geq 3$, $R(T_{\max}, \theta) \leq R(T_m, \theta) \Rightarrow$ On préfère T_{\max} au sens du risque quadratique.

On a $\mathbb{E}[T_{\max}] = \frac{m}{m+1} \theta$

Remarque: Si on a un estimateur T_m de θ tq $\mathbb{E}[T_m] = a\theta + b$

alors $T_m^* = \frac{T_m - b}{a}$ est sans biais pour θ .

On pose $T_{\max}^* = \frac{m+1}{m} T_{\max} = \frac{m+1}{m} \max_{i \in \{1, \dots, n\}} X_i$

On a T_{\max}^* sans biais pour θ car $\mathbb{E}[T_{\max}^*] = \frac{m+1}{m} \mathbb{E}[T_{\max}] = \theta$

On a

$$V(T_{\max}^*) = V\left(\frac{m+1}{m} T_{\max}\right) = \frac{(m+1)^2}{m^2} V(T_{\max}) = \frac{\theta^2}{m(m+2)} \xrightarrow[m \rightarrow \infty]{} 0$$

et on obtient $R(T_{\max}^*, \theta) = \underbrace{B_\theta(T_{\max})^2}_{=0} + V(T_{\max}^*) = \frac{\theta^2}{m(m+2)}$

Est-ce qu'on a $R(T_{\max}^*, \theta) \leq R(T_{\max}, \theta)$?

On calcule $\frac{R(T_{\max}^*, \theta)}{R(T_{\max}, \theta)} = \frac{\frac{\theta^2}{m(m+2)}}{\frac{2\theta^2}{(m+1)(m+2)}} = \frac{m+1}{2m} \leq 1$.

$\Rightarrow T_{\max}^*$ est préférable au sens du risque quadratique

Cas particulier: moyenne et variance aléatoire

On se place dans le modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_\theta, \theta \in \Theta \subseteq \mathbb{R}^p)^m$

On suppose que P_θ admet une espérance μ et une variance $\sigma^2 < \infty$

On a des estimateurs "naturels" de μ et σ^2 (qui viennent de la stat. descriptive).

Si (X_1, \dots, X_m) est le vecteur associé au modèle, on appelle **moyenne aléatoire** la v.a.

$$\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i$$

On appelle **variance aléatoire** la stat.

$$V_m = \frac{1}{m} \sum_{i=1}^m (X_i - \bar{X}_m)^2$$

On va utiliser la **variance corrigée** définie par $S_m^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2$

Théorème:

- * \bar{X}_m est sans biais et converge pour μ
- * V_m est asympt. sans biais et converge parfaite pour σ^2
- * S_m^2 est sans biais et converge pour σ^2 .

III - Statistiques Gaussienne

Définition: Un vecteur $X = (X_1, \dots, X_m)$ est Gaussien d'espérance μ et de matrice de variance Σ si sa densité est :

$$f(x) = \frac{1}{(\det \Sigma)^{\frac{m}{2}} (2\pi)^{\frac{m}{2}}} \exp\left(-\frac{1}{2} (x-\mu)' \Sigma^{-1} (x-\mu)\right)$$

Caractéristique: $X = (X_1, \dots, X_m)$ est Gaussien $\Leftrightarrow \forall \lambda = (\lambda_1, \dots, \lambda_m) \in \mathbb{R}^m, \sum_{i=1}^m \lambda_i X_i$ Gaussien

Propriété: Soit $X = (X_1, \dots, X_m)$ Gaussien,

alors, $\text{Cor}(X_i, X_j) = 0 \Leftrightarrow X_i \perp\!\!\!\perp X_j$

Définition: Une var suit une loi Gamma $\Gamma(a, \lambda)$ si sa densité vaut:

$$f_{a,\lambda}(x) = \frac{\lambda^a}{\Gamma(a)} e^{-\lambda x} x^{a-1} I_{[0,+\infty)}$$

⚠ pas la m̄me paramétrisation que sur Wikipedia

Propriétés:

* $E(A) = \Gamma(1, \lambda)$

* Si: $X \sim \Gamma(a, \lambda)$ et $Y \sim \Gamma(b, \lambda)$ et $X \perp\!\!\!\perp Y$

alors $\Gamma(a, \lambda) + \Gamma(b, \lambda) = \Gamma(a+b, \lambda)$

Définition: Si X_1, \dots, X_m iid tq $X_i \sim N(0, 1)$ alors,

$$Z = \sum_{i=1}^m X_i^2 \sim \chi_m^2 \quad (\text{Khi deur à } m \text{ degrés de liberté})$$

Propriétés: $\chi_m^2 = \Gamma(\frac{m}{2}, \frac{1}{2})$

Définition:

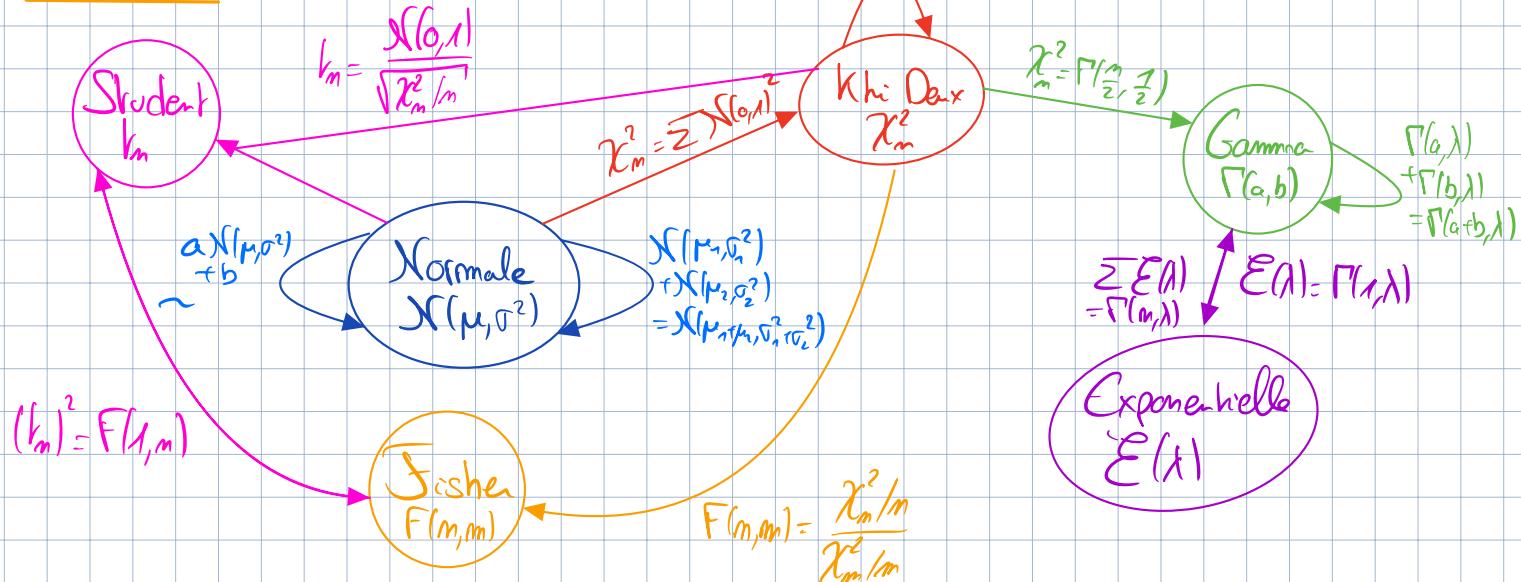
* Soit $X \sim N(0, 1)$, $Y \sim \chi_m^2$ et $X \perp\!\!\!\perp Y$,

alors, $Z = \frac{X}{\sqrt{Y/m}} \sim t_m$ (Student à m degrés de liberté)

* Soit $X \sim \chi_m^2$, $Y \sim \chi_n^2$ et $X \perp\!\!\!\perp Y$,

alors $F = \frac{X/m}{Y/n} \sim F(m, n)$ (Fisher à $m+n$ degrés de liberté)

Résumé



Rappel: X_1, \dots, X_m iid tq $X_i \sim P_\theta$

$$(R, \mathcal{B}(R), P_\theta, \theta \in \Theta \subseteq R^p)^m$$

Statistique = $T_m = \text{fonct}^\circ$ de X_1, \dots, X_m (sans θ)

Estimateur = Statistique à valeurs dans Θ

Critères de qualité d'un estimateur T_m de $g(\theta)$

Est-ce qu'
en moyenne
on voit la
bonne valeur?

\otimes **Biais** $B_{g(\theta)}(T_m) = E[T_m] - g(\theta)$

T_m est (asymp) sans biais si $B_{g(\theta)}(T_m) = 0 \underset{m \rightarrow \infty}{\rightarrow} 0$

Est-ce qu'
gagne en
précis°?
 $m \rightarrow \infty$?

\otimes **Convergence**: $T_m \xrightarrow{P} g(\theta)$

ou $B_{g(\theta)}(T_m) \rightarrow 0$ et $V(T_m) \rightarrow 0$

\otimes **Risque Quadratique moyen**

$$\begin{aligned} R(T_m, g(\theta)) &= E[(T_m - g(\theta))^2] \\ &= B_{g(\theta)}(T_m) + V(T_m) \end{aligned} \quad \left. \begin{array}{l} \text{mélange des} \\ \text{2 autres critères} \end{array} \right.$$

↑

Ça servira:

- Comparer 2 estimateurs (on prend celui qui a le + petit RQM)
- On essaye de minimiser le RQM d'un estimateur

Propriétés:

* Si $\theta = E[X]$ alors \bar{X}_m est un estimateur sans biais convergent pour θ .

* Si $\theta = V(X)$ alors $\frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2$ est un estimateur sans biais convergent pour θ

Statistiques Gaussiennes

Théorème (Cochram): Soit X_1, \dots, X_m des v.a. iid tq $X_i \sim N(\mu, \sigma^2)$

* $\bar{X}_m \sim N(\mu, \frac{\sigma^2}{m})$

* $\frac{m-1}{\sigma^2} S_m^2 \sim \chi_{m-1}^2$ avec $S_m^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2$

* $\bar{X}_m \perp\!\!\!\perp S_m^2$

Remarque: Si on connaît la valeur de μ , on peut estimer σ^2 par $\frac{1}{m} \sum_{i=1}^m (X_i - \mu)^2$

Si on pose $Y_i = (X_i - \mu)^2$, on a $E[Y_i] = E[(X_i - \mu)^2] = \sigma^2$

$\Rightarrow \frac{1}{m} \sum_{i=1}^m Y_i$ est convergent et sans biais pour σ^2

$$V_m^* = \frac{1}{m} \sum_{i=1}^m (X_i - \mu)^2 \quad \text{iid}$$

Rappel: $W = \sum_{i=1}^m Z_i^2$ avec $Z_i \sim N(0, 1)$ alors $W \sim \chi_m^2$

Ici: $X_i \sim N(\mu, \sigma^2) \Rightarrow \underline{X_i - \mu} \sim N(0, 1)$

$$\Rightarrow \sum_{i=1}^m \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_m^2$$

$$\frac{1}{\sigma^2} \sum_{i=1}^m (X_i - \mu)^2 = \frac{m}{\sigma^2} \times \frac{1}{m} \sum_{i=1}^m (X_i - \mu)^2 = \frac{m}{\sigma^2} V_m^*$$

$$\text{Cl: } \frac{m}{\sigma^2} V_m^* \sim \chi_m^2$$

Début de preuve :

On part du fait que $(X_1 - \bar{X}_m, \dots, X_m - \bar{X}_m, \bar{X}_m)$ forme un vecteur Gaussien car toute CL des composantes est Gaussienne

$$\text{On a } \text{Cov}(X_1 - \bar{X}_m, \bar{X}_m) = \text{Cov}(X_1, \bar{X}_m) - \text{Gr}(X_1, \bar{X}_m)$$

$$= \frac{1}{m} \sum_{i=1}^m \underbrace{\text{Cov}(X_1, X_i)}_{= V(X_1) \text{ si } i=1} - \underbrace{\text{Gr}(X_1, \bar{X}_m)}_{= \frac{\sigma^2}{m}} = 0.$$

$= 0 \text{ sinon}$

$$\Rightarrow \forall j \in \{1, m\}, X_j - \bar{X}_m \perp\!\!\!\perp \bar{X}_m$$

Chapitre II : Estimation

On reste dans le cadre du modèle d'échantillonnage paramétrique

$$(R, \mathcal{B}(R), P_0, \theta \in \Theta \subseteq R^m)$$

ou $(\mathbb{N}, \text{Parties}(\mathbb{N}))$

On travaille (au début)
avec un paramètre unidimensionnel

et on a (x_1, \dots, x_n) le vecteur associé au modèle.

- Soit $f(x, \theta)$ la densité (density) de la distribution des X_i (ou la fonction de masse si la loi des X_i est discrète).
- Soit $L(x_1, \dots, x_n, \theta)$ la vraisemblance (likelihood) du modèle

On a $L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta)$ (le modèle est indép.)

densité de (x_1, \dots, x_n)

p/r à la mesure dominante

Soit $\mathcal{X} \subseteq R$ est le support de $f(x, \theta)$

$$\mathcal{X} = \{x \in R \mid f(x, \theta) > 0\}$$

Exemple: - Si $X_i \sim N(\mu, \sigma^2)$, $\mathcal{X} = R$

- Si $X_i \sim U(0, \theta)$, $\mathcal{X} = [0, \theta]$

- Si $X_i \sim P(\theta)$, $\mathcal{X} = \mathbb{N}$

Le support de L est \mathcal{X}^n

II - Hypothèses fondamentales sur f .

On va faire des hypothèses de régularité sur f .

⚠ Si les hypothèses ne sont pas vérifiées, on peut quand même faire de l'estimation mais avec d'autres techniques (moments, moindres carrés, ...).

Hypothèses de régularité:

(H1): $\mathcal{X} \perp\!\!\!\perp \theta$

C'est l'hypothèse qui va faire le tournant

(H2): θ est un ouvert

(le fait d'avoir $f(x, \theta) > 0, \forall x, \theta \in \mathcal{X}, \theta$ permet de ne pas avoir de perte de différentiabilité à la frontière.)

) Si θ est fermé, on l'ouvre

(H3): $\frac{\partial}{\partial \theta} f(x, \theta)$ et $\frac{\partial^2}{\partial \theta^2} f(x, \theta)$ sont définies $\forall (x, \theta) \in \mathcal{X} \times \Theta$

© Théo Jalabert

Ça permet de (H4): Les dérivées premières et secondes de f par rapport à θ sont dominées par des fonctions μ -intégrables sur tout compact K inclus dans Θ (KC Θ).
Pour tout compact $K \subset \Theta$, il existe deux fonctions μ -intégrables $\psi(x)$ et $\psi(x)$ tq $\forall \theta \in K$ et pour presque tout $x \in \mathcal{X}$

$$\left| \frac{\partial}{\partial \theta} f(x, \theta) \right| < \psi(x) \text{ et } \left| \frac{\partial^2}{\partial \theta^2} f(x, \theta) \right| < \psi(x).$$

II - Informat°

Informat°: important
= tout ce qu'on sait sur θ (avec X_1, \dots, X_n)

Définit° (Score):

Score d'un V.A. X :

On appelle fonction Score ou Score la fonction définie par:

$$S: \mathcal{X} \times \Theta \longrightarrow \mathbb{R}$$

$$(x, \theta) \longmapsto \frac{\partial}{\partial \theta} \ln(L(x, \theta))$$

Remarques:

- * Cette fonction Score est bien définie si (H1), (H2) et (H3) sont vérifiés
- * Elle intervient souvent en estimat°
- * On peut définir le Score du modèle i.e. de (X_1, \dots, X_n)

$$S_m(x_1, \dots, x_n, \theta) = \frac{\partial}{\partial \theta} \ln(L(x_1, \dots, x_n, \theta))$$

Si on est dans le cas du modèle d'échantillonnage i.e. X_1, \dots, X_n iid

$$\begin{aligned} S_m(x_1, \dots, x_n, \theta) &= \frac{\partial}{\partial \theta} \ln(L(x_1, \dots, x_n, \theta)) = \frac{\partial}{\partial \theta} \ln\left(\prod_{i=1}^n f(x_i, \theta)\right) \\ &= \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln(f(x_i, \theta)) \\ &= \sum_{i=1}^n S(x_i, \theta) \end{aligned}$$

Propriété: Si (H4) est vérifiée alors on a:

$$\mathbb{E}[S(X, \theta)] = 0 \text{ ou } \mathbb{E}[S_m(X_1, \dots, X_n, \theta)] = 0$$

Preuve:

On parle du fait que f est une densité donc $\int f(x, \theta) dx = 1$

On dérive par rapport à θ et comme on a (H4)

© Théo Jalabert

$$\begin{aligned}\frac{\partial}{\partial \theta} 1=0 &= \frac{\partial}{\partial \theta} \int g(x, \theta) dx = \int \frac{\partial}{\partial \theta} g(x, \theta) dx \\ &= \int \frac{\partial}{\partial \theta} \ln(f(x, \theta)) \cdot f(x, \theta) dx. \quad \left(\begin{array}{l} (\ln(u))' = \frac{u'}{u} \\ u' = f(x, \theta)' \end{array} \right) \\ &= \mathbb{E}\left[\frac{\partial}{\partial \theta} \ln(f(x, \theta))\right] = \mathbb{E}[S(x, \theta)].\end{aligned}$$

Définition: On appelle l'informations de Fisher la fonction I définie par:

$$I: \mathbb{R}^+ \rightarrow \mathbb{R}^+$$
$$\theta \mapsto I(\theta) = \mathbb{E}[S(x, \theta)^2] \quad \leftarrow \text{Information contenue dans un } x_i$$

Remarques:

* L'information est définie si (H1), (H2) et (H3) sont vérifiées,

* L'information dépend uniquement de θ et du modèle choisi.
Elle représente l'information continue dans x_i pour θ .

* On peut définir l'information pour le modèle entier i.e. X_1, \dots, X_n et on a

$$I_m(\theta) = \mathbb{E}[S_m(X_1, \dots, X_n, \theta)^2].$$

Propriété: Si (H4) est vérifiée, on a:

$$I(\theta) = V(S(x, \theta)) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(f(x, \theta))\right].$$

ou

$$I_m(\theta) = V(S_m(X_1, \dots, X_n, \theta)) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(L(X_1, \dots, X_n, \theta))\right]$$

Preuve:

On reprend la preuve précédente :

$$\int \frac{\partial}{\partial \theta} \ln(f(x, \theta)) \cdot f(x, \theta) dx = 0$$

On dérive encore par rapport à θ .

$$\left(\frac{\partial}{\partial \theta} \ln(f(x, \theta))\right) \cdot f(x, \theta)$$

$$\int \frac{\partial^2}{\partial \theta^2} \ln(f(x, \theta)) \cdot f(x, \theta) dx + \int \frac{\partial}{\partial \theta} \ln(f(x, \theta)) \cdot \frac{\partial}{\partial \theta} f(x, \theta) dx = 0$$

$$\Rightarrow \int \frac{\partial^2}{\partial \theta^2} \ln(f(x, \theta)) \cdot f(x, \theta) dx + \int \frac{\partial^2}{\partial \theta^2} \ln(f(x, \theta))^2 \cdot f(x, \theta) dx = 0$$

$$\Rightarrow \mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(f(x, \theta))\right] + \mathbb{E}[S(x, \theta)^2] = 0$$

$$\rightarrow \mathbb{E}[S(\bar{x}, \theta)^2] = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(f(\bar{x}, \theta))\right]$$

$= I(\theta)$

$$\rightarrow \mathbb{E}[S(\bar{x}, \theta)^2] - \mathbb{E}[S(\bar{x}, \theta)]^2 = V(S(\bar{x}, \theta)) = 0 \text{ par prop sur le score}$$

Propriété: Si on est dans le modèle d'échantillonnage i.e. X_1, \dots, X_n iid

et on a (H4) vraie, on a :

$$I_m(\theta) = -\mathbb{E}\left[\ln(L(X_1, \dots, X_n, \theta))\right] = -\sum_{i=1}^n \mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(f(X_i, \theta))\right]$$

$\prod_{i=1}^n f(X_i, \theta)$

$= m I(\theta)$

Informat° contenue
dans un X_i : Chaque X_i (indep des autres)
améliore $I(\theta)$ comme info.

Exemple:

On a X_1, \dots, X_n iid tq $X_i \sim \mathcal{E}(\theta)$

Le modèle est :

$$(R_t^*, \mathcal{B}(R_t^*), \mathcal{E}(\theta), \partial \mathcal{C} R_t^*)^m$$

On veut l'informat° du modèle \leftarrow Informat° dans X_1, \dots, X_n i.e. $I_m(\theta)$

$$\text{On a } L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n \exp(-\theta \sum_{i=1}^n x_i)$$

$$\ln(L(x_1, \dots, x_n, \theta)) = n \ln(\theta) - \theta \sum_{i=1}^n x_i$$

$$S_m(x_1, \dots, x_n, \theta) = \frac{\partial}{\partial \theta} \ln(L(x_1, \dots, x_n, \theta)) = \frac{n}{\theta} - \sum_{i=1}^n x_i$$

On peut calculer l'info par 3 formules (dans ce cas)

$$I_m(\theta) = \mathbb{E}\left[S_m(x_1, \dots, x_n, \theta)^2\right] = V(S_m(x_1, \dots, x_n, \theta)) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(L(x_1, \dots, x_n, \theta))\right]$$

d'habitude galère

un peu moins difficile

normalement + facile.

$$* I_m(\theta) = V(S_m(x_1, \dots, x_n, \theta))$$

$$\begin{aligned} \text{Ici, on a: } I_m(\theta) &= V\left(\frac{n}{\theta} - \sum_{i=1}^n x_i\right) \\ &= V\left(\sum_{i=1}^n x_i\right) \\ &= \frac{n}{\theta^2} \end{aligned}$$

Rappels:

- * Si X_1, \dots, X_n iid tq $X_i \sim \mathcal{E}(\theta)$ alors $\sum X_i \sim \Gamma(n, \theta)$
- * $V(\Gamma(n, \theta)) = \frac{n}{\theta^2}$

$$* I_m(\theta) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(L(x_1, \dots, x_n, \theta))\right]$$

$$\frac{\partial^2}{\partial \theta^2} \ln(L(X_1, \dots, X_m, \theta)) = -\frac{m}{\theta^2}$$

$$\Rightarrow I_m(\theta) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(L(X_1, \dots, X_m, \theta))\right] = \frac{m}{\theta^2}$$

Informat° contenue dans X_1, \dots, X_m sur le paramètre θ .

On peut comparer l'informat° à l'intérieur d'un modèle.

Si : $\begin{cases} \theta \text{ est petit} \rightarrow \text{bcp d'informat°} \rightarrow \text{"facile" à estimer} \\ \theta \text{ est grand} \rightarrow \text{pas trop d'informat°} \rightarrow \text{"difficile" à estimer} \end{cases}$

$$\text{Si } \theta=1 \quad I_m(\theta)=m$$

$$\text{Si } \theta=10 \quad I_m(\theta)=\frac{m}{100} \quad (\text{beaucoup moins d'info})$$

Exemple : X_1, \dots, X_m iid tq $X_i \sim \mathcal{N}(\mu, 1)$

$$\begin{aligned} L(x_1, \dots, x_m, \mu) &= \prod_{i=1}^m f(x_i, \mu) = \prod_{i=1}^m (2\pi)^{-1/2} \exp(-\frac{1}{2}(x_i - \mu)^2) \\ &= (2\pi)^{-m/2} \exp\left(-\frac{1}{2} \sum_{i=1}^m (x_i - \mu)^2\right). \end{aligned}$$

$$\ln(L(x_1, \dots, x_m, \mu)) = -\frac{m}{2} \ln(2\pi) - \frac{1}{2} \sum_{i=1}^m (x_i - \mu)^2$$

$$S_m(x_1, \dots, x_m, \mu) = \frac{\partial}{\partial \mu} \ln(L(x_1, \dots, x_m, \mu)) = \sum_{i=1}^m x_i - m\mu$$

$$\frac{\partial^2}{\partial \mu^2} \ln(L(x_1, \dots, x_m, \mu)) = -m$$

$$I_m(\mu) = -\mathbb{E}\left[\frac{\partial^2}{\partial \mu^2} \ln(L(x_1, \dots, x_m, \mu))\right] = m$$

L'informat° ne dépend pas de μ .
On a la même qté d'info quelque soit μ , on aura la même "précision d'estimation" quelque soit μ .

III - Inégalité de Cramer-Rao.

Hypothèses supplémentaires :

$$(HS) \quad 0 < I(\theta) < \infty \quad \text{et} \quad 0 < I_m(\theta) < \infty$$

\uparrow \uparrow
si faut qu'en mais pas à
au't de l'info l'infinity quand m

On prend un estimateur T_m de θ tq $\mathbb{E}[T_m] = g(\theta)$

Traduire le biais de T_m

$\text{Si } g = \text{Id} \text{, } T_m \text{ est sans biais pour } \theta$.

Théorème : Inégalité de (Fréchet-Darmois). Cramér-Rao

Si on a (H1), (H2), (H3), (H4) et (HS) vérifiées et si g dérivable alors on a

$$V(T_m) \geq \frac{(g'(\theta))^2}{I_m(\theta)} = K_{T_m}(\theta)$$

Borne inférieure
de l'inégalité de
Cramér-Rao

Preuve :

On part de

$$\begin{aligned} \text{Cov}\left(T_m, \frac{\partial}{\partial \theta} \ln(L)\right) &= \mathbb{E}[T_m \frac{\partial}{\partial \theta} \ln(L)] - \mathbb{E}[T_m] \mathbb{E}\left[\frac{\partial}{\partial \theta} \ln(L)\right] \\ &= \int T_m \underbrace{\frac{\partial}{\partial \theta} \ln(L) \cdot L}_{\text{Score}} d\mu^{\otimes m} \\ &= \int \frac{\partial}{\partial \theta} (T_m \cdot L) d\mu^{\otimes m} = \frac{\partial}{\partial \theta} \underbrace{\int T_m \cdot L d\mu^{\otimes m}}_{= \mathbb{E}[T_m] = g(\theta)} \\ &= g'(\theta). \end{aligned}$$

On applique l'inégalité de Cauchy-Schwartz.

$$\begin{aligned} (\text{Cov}\left(T_m, \frac{\partial}{\partial \theta} \ln(L)\right))^2 &\leq V(T_m) \cdot \underbrace{\sqrt{\left(\frac{\partial}{\partial \theta} \ln(L)\right)^2}}_{I_m(\theta)} \\ \Rightarrow V(T_m) &\geq \frac{(g'(\theta))^2}{I_m(\theta)}. \end{aligned}$$

Remarques :

$$* V(T_m) \geq \frac{(g'(\theta))^2}{I_m(\theta)} \quad \begin{array}{l} \text{dépend de l'estimateur } T_m \\ \text{et } I_m(\theta) \end{array}$$

et $I_m(\theta)$ dépend uniquement du modèle

$$* \text{ Si } T_m \text{ est sans biais alors } V(T_m) \geq I_m(\theta)^{-1}$$

Définition: On dit que T_m est un estimateur efficace si :

$$V(T_m) = K_{T_m}(\theta) \quad (\text{Forme de Cramér-Rao})$$

Si T_m n'est pas efficace mais $\frac{V(T_m)}{K_{T_m}(\theta)} \rightarrow 1$, on dit que T_m est asymptotiquement efficace.

Remarque: Si on a un estimateur T_m efficace pour θ alors parmi tous les estimateurs qui ont le même biais, c'est celui qui minimise le risque quadratique

$$(R(T_m, \theta) = B(T_m)^2 + V(T_m))$$

Rappel: On a des données x_1, \dots, x_n . Si on considère les données comme telles, tout ce qu'on peut faire c'est les décrire \Rightarrow stat. descriptive

En stat. inf., on voit les données comme des réalisat° de v.a., on veut avoir des informat° ou à approcher la ou les v.a. qui ont générées les observat°.

Exemple: Sous R, on fait :

> $X = rpois(100, 30)$

($X \sim P(30)$)

Simulat° $\rightarrow r$
densité $\rightarrow d$
fdt $\rightarrow p$
quantile $\rightarrow q$

> $Y = rpois(100, 30)$

> mean(X)
[1] 29.573

> mean(Y)
[1] 31.264

En stat. descriptive les 2 séries sont différentes.

En stat. inf. elles sont "égales" i.e. les v.a. qui ont générées les données ont même distribut°.

La différence est due à la variabilité naturelle de l'expérience aléatoire.

Définition: On dit que T_m est un estimateur efficace si :

(Je réécrits la def pour + de cohérence)

$$V(T_m) = K_{T_m}(\theta) \quad (\text{Forme de Cramér-Rao})$$

Si T_m n'est pas efficace mais $\frac{V(T_m)}{K_{T_m}(\theta)} \rightarrow 1$, on dit que T_m est asymptotiquement efficace.

Exemple: X_1, \dots, X_m iid telles que $X_i \sim \mathcal{P}(\theta)$

On prend $T_m = \frac{1}{m} \sum_{i=1}^m X_i$ (c'est un estimateur sans biais et convergeant pour θ car $\mathbb{E}[X] = \theta$)

On a $V(T_m) = V\left(\frac{1}{m} \sum_{i=1}^m X_i\right) = \frac{1}{m^2} \sum_{i=1}^m V(X_i) = \frac{\theta}{m}$ et $\mathbb{E}[T_m] = \theta$.

$$\begin{aligned} L(x_1, \dots, x_m, \theta) &= \prod_{i=1}^m P(X_i = x_i) \\ &= \prod_{i=1}^m \frac{\theta^{x_i}}{x_i!} e^{-\theta} = \frac{\theta^{\sum_{i=1}^m x_i}}{\prod_{i=1}^m x_i!} e^{-m\theta} \end{aligned}$$

$$\ln(L(x_1, \dots, x_m, \theta)) = \left(\sum_{i=1}^m x_i\right) \ln(\theta) - m\theta - \ln\left(\prod_{i=1}^m x_i\right)$$

$$I_m(\theta) = V(S_m(x_1, \dots, x_m, \theta)) = V\left(\frac{\sum_{i=1}^m X_i}{m}\right) = \frac{\sum_{i=1}^m V(X_i)}{\theta^2} = \frac{m}{\theta^2}$$

Borne de Cramer-Rao: Ici $\mathbb{E}[T_m] = \theta$ donc $h(\theta) = \theta$

$$K_{T_m} = \frac{(h(\theta))^2}{I_m(\theta)} = \frac{1}{m/\theta} = \frac{\theta}{m} = V(T_m) \Rightarrow T_m \text{ est efficace pour } \theta$$

Relation entre estimateurs efficaces

Propriétés:

- ① Si T_m est un estimateur efficace de θ , alors $kT_m + b$ est aussi un estimateur efficace de θ , $\forall k \in \mathbb{R}^*, \forall b \in \mathbb{R}$.
- ② Soient T_m et T_{2m} deux estimateurs sans biais du paramètre θ . Si ils sont tous deux efficaces, alors $T_m = T_{2m}$ presque sûrement.

Traduc: $R(T_m, \theta) = B_\theta(T_m)^2 + V(T_m)$

Si on considère les estimateurs sans biais $R(T_m, \theta) = V(T_m)$, comme tous les estimateurs sans biais ont la même borne de Cramer-Rao et que T_m atteint cette borne alors T_m est le meilleur estimateur au sens du risque quadratique parmi les estimateurs sans biais de paramètre θ .

T_m est BLUE (Best Linear Unbiased Estimator) pour θ .

Preuve:

- ① Si T_m est tq $\mathbb{E}[T_m] = h(\theta)$ et $V(T_m) = \frac{(h'(\theta))^2}{I_m(\theta)}$

Si $T_m^* = aT_m + b$, on a $\mathbb{E}[T_m^*] = a\mathbb{E}[T_m] + b$
 $= a h(\theta) + b$.

$$\text{Donc } k_{T_m^*}(\theta) = \frac{(a h'(\theta))^2}{I_m(\theta)} = a^2 \frac{(h'(\theta))^2}{I_m(\theta)} = a^2 k_{T_m}(\theta) = a^2 V(T_m)$$

© Théo Jalabert

$$\text{et } V(T_m^*) = V(a T_m + b) = a^2 V(T_m) \quad \Rightarrow \quad T_m^* \text{ est efficace}$$

② Soit $T_{m,1}$ et $T_{m,2}$ deux estimateurs sans biais et efficace de θ .

$$T_{m,3} = \frac{T_{m,1} + T_{m,2}}{2} \text{ est un estimateur sans biais de } \theta.$$

$$\text{Donc } V(T_{m,3}) = \frac{1}{4} [V(T_{m,1}) + V(T_{m,2}) + 2 \rho I_{T_{m,1} T_{m,2}}] \text{ où } \rho \text{ est le coeff de corrél° linéaire entre } T_{m,1} \text{ et } T_{m,2}$$

On pose $V(T_{m,1}) = V(T_{m,2}) = V$ (car ils sont tous les deux sans biais et efficace).

$$V(T_{m,3}) = \frac{1}{4} [2V + 2\rho V] = \frac{V}{2}(1+\rho)$$

On peut avoir $\rho < 1$ (on sait $V(T_{m,3}) < V$)

On a alors $\rho = 1$

Si $\rho = 1$, on a $T_{m,1} - \mathbb{E}[T_{m,1}] = \alpha (T_{m,2} - \mathbb{E}[T_{m,2}])$
mais comme $V(T_{m,1}) = V(T_{m,2})$ on a $\alpha = 1$ et donc $T_{m,1} = T_{m,2}$ p.s.

Remarque: Le ① dit que si on a un estimateur efficace, c'est sympa de chercher une transformat° linéaire qui minimise ou annule le biais (on garde l'efficacité).

Degradation de l'information

On a X_1, \dots, X_m iid tq $X_i \sim P_\theta$. $I_m(\theta)$ est toute la qté d'info qu'on a sur θ (je peux pas en avoir +).
On prend X_1, \dots, X_m et on résume tout ça dans une stat. T_m .

Qu'est-ce qu'il s'est passé au niveau de l'informat°?

Si $h(t, \theta)$ est la vraisemblance de T , on note $I_T(\theta)$ l'informat° relative à T :

$$I_T(\theta) = \mathbb{E}[S(T, \theta)^2] \text{ où } S(T, \theta) = \frac{\partial \ln(h(t, \theta))}{\partial \theta}$$

$I_T(\theta)$ vérifie les m° prop (centrée, relat° avec $\frac{\partial^2}{\partial \theta^2} h$, inégalité de Cramér-Rao) que $I(\theta)$.

Propos 1°:

Soit T une stat., on a $I_T(\theta) \leq I_m(\theta)$ avec égalité ssi la stat T est exhaustive pour le paramètre θ .

Exemple: On prend X_1, \dots, X_m iid tq $X_i \sim P(\theta)$

On prend $T_m = \sum_{i=1}^m X_i \sim \mathcal{P}_m(\theta)$.

\sum de $P(\theta)$ indép

$$\text{Ic: } h(t, \theta) = P(T_m=t) = \frac{(m\theta)^t}{t!} e^{-m\theta}$$

$$\ln(h(t, \theta)) = t \ln(m\theta) - \ln(t!) - m\theta$$

$$\frac{\partial}{\partial \theta} \ln(h(t, \theta)) = \frac{t}{\theta} - m = S_1(t, \theta) \quad \frac{\partial^2}{\partial \theta^2} \ln(h(t, \theta)) = -\frac{t}{\theta^2}$$

$$I_{T_m}(\theta) = -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \ln(h(T, \theta))\right] = -\mathbb{E}\left(-\frac{T}{\theta^2}\right) = \frac{\mathbb{E}[T]}{\theta^2} = \frac{m}{\theta} = I_m(\theta)$$

On a autant d'info. pour θ dans X_1, \dots, X_m que dans $\sum X_i$ si on a des v.a.

Consequence: On a un porte feuille avec m contrats d'assurance indép.

On s'intéresse au nbr de sinistres sur chaque contrat, on peut considérer que ce sont des réalisat° de v.a. de Poisson iid

On observe $0, 1, 0, 0, 0, 2, 1, 0, \dots, 2, 1$ et on a $\sum x_i = 168$

Vocabulaire:

Si on a $I_{T_m}(\theta) = I_m(\theta)$ on dit que T_m est exhaustive pour θ (en anglais sufficient statistic).

IV - Exhaustivité

Dans un problème stat avec un paramètre θ , l'échantillon X_1, \dots, X_m apporte une certaine qté d'info ($I_m(\theta)$)

On réserve l'échantillon pour une statistique T_m et on veut essayer de ne pas perdre d'infos.

Une stat T_m qui conserve l'info est une stat exhaustive.

On peut traduire ça par le fait que la loi conditionnelle de X_1, \dots, X_m sachant que T_m est indép de θ .

⚠ Spoiler: 99,9% de stats que l'on va étudier sont exhaustives.

Formellement, on se place dans le modèle $(\mathcal{R}, \mathcal{S}(\mathcal{R}), \mathcal{P}_\theta, \theta \in \Theta \subseteq \mathcal{R})$

Définition: (Principe de factorisat°)

La stat T_m est ici une v.a. définie sur $(X, \mathcal{B}_X, \mathcal{P}_\theta, \theta \in \Theta \subseteq \mathcal{R})$ à valeurs dans $(\mathcal{G}, \mathcal{B}_{\mathcal{G}})$

On considère :

- La vraisemblance (fonct° de densité ou de proba) de T_m que l'on va noter $f_t(t, \theta)$
- La densité conjointe de l'échantillon (X_1, \dots, X_m) notée $L(x_1, \dots, x_m, \theta)$

On dira que la stat. T_m est exhaustive pour θ s'il existe une fonct° f sur X^m tq :

$$L(x_1, \dots, x_m, \theta) = f_t(t, \theta) f_{\text{vraisemblance ou densité de } (X_1, \dots, X_m, \theta)} \text{ "de } T_m \text{ " conditionnelle de } X_1, \dots, X_m \text{ sachant que } T_m \text{ indép de } \theta.$$

Si T_m exhaustive pour θ .

On a:

$$\begin{aligned} L(x_1, \dots, x_m, \theta) &= h(t, \theta) k(x_1, \dots, x_m) \\ h(L(x_1, \dots, x_m, \theta)) &= h(h(t, \theta)) + h(k(x_1, \dots, x_m)) \end{aligned}$$

$$\frac{\partial}{\partial \theta} h(L(x_1, \dots, x_m, \theta)) = \frac{\partial}{\partial \theta} h(h(t, \theta))$$

:

$$I_m(\theta) = I(\theta)$$

On peut aussi dire que T_m est exhaustive pour θ si:

$$\frac{L(x_1, \dots, x_m, \theta)}{h(t, \theta)} \text{ est indép de } \theta.$$

Théorème (de factorisation):

Pour qu'une stat T soit exhaustive, il suffit que la vraisemblance s'écrive:

$$L(x_1, \dots, x_m, \theta) = \underbrace{\phi(t, \theta)}_{\text{dépend indépendamment de } t \text{ et } \theta} \underbrace{\psi(x_1, \dots, x_m)}_{\text{dépend uniquement de } x_1, \dots, x_m}$$

Remarque:

- C'est une bonne méthode pour montrer T_m est exhaustive mais pas pour montrer qu'elle n'est pas exhaustive
- Une transformat° bijective d'une stat. exhaustive est exhaustive

Exemple:

X_1, \dots, X_m iid tq $X_i \sim \mathcal{B}(\theta)$ et $T_m = \sum_{i=1}^m X_i$

$$\text{On a } L(x_1, \dots, x_m, \theta) = \frac{\theta^{\sum x_i}}{\prod x_i!} e^{-m\theta} = \underbrace{\theta^{\sum x_i}}_{\phi(t, \theta)} \underbrace{e^{-m\theta}}_{\psi(x_1, \dots, x_m)} \times \underbrace{\left(\prod x_i!\right)^{-1}}_{\sum x_i}$$

IV - Exhaustivité et estimateurs efficaces : la famille exponentielle

Définition: On appelle famille exponentielle à paramètre unidimensionnel θ toute loi de proba (discrete ou continue)

dont la vraisemblance peut se mettre sous la forme:

$$f(x, \theta) = \begin{cases} \exp[\alpha(\theta) \beta(x) + \gamma(\theta) + \delta(\alpha)] & \text{si } x \in \mathcal{X} \\ 0 & \text{si } x \notin \mathcal{X} \end{cases}$$

avec α, β, γ des fonct° de 2 lois ≠

Si $\alpha(\theta) = \theta$, c'est la forme naturelle de la famille exponentielle

Si $\beta(\theta) = x$, c'est la forme canonique de la famille exponentielle

Rq: Les fonct° α, β, γ et δ ne sont pas uniques.

Proposition:

Dans la famille exponentielle, toute stat sous la forme $T_m = \ln \sum_{i=1}^m \beta(x_i)$ est exhaustive pour θ .

Preuve:

Si f est dans la famille exponentielle, on a:

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \exp[\alpha(\theta)\beta(x_i) + \gamma(\theta) + \delta(x_i)] \\ &= \exp[\alpha(\theta) \sum \beta(x_i) + n\gamma(\theta) + \sum \delta(x_i)] \\ &= \underbrace{\exp[\alpha(\theta) \sum \beta(x_i) + n\gamma(\theta)]}_{\varphi(h = \sum \beta(x_i), \theta)} \cdot \underbrace{\exp[\sum \delta(x_i)]}_{\psi(x_1, \dots, x_n)} \end{aligned}$$

Exemple:

S: $X \sim \mathcal{P}(\theta)$, on a $f(x) = \frac{\theta^x}{x!} e^{-\theta}$

$$\text{On a } f(x) = \exp \left(x \underbrace{\ln(\theta)}_{\beta(x)} - \theta - \underbrace{\ln(x!)}_{\delta(x)} \right) \quad \text{si } x \in \mathbb{N}$$

$$\Rightarrow T_m = \frac{1}{m} \sum_{i=1}^m \beta(x_i) = \frac{1}{m} \sum_{i=1}^m x_i \text{ est une stat exhaustive.}$$

Modèle exponentiel:

Pr appartenir au modèle exponentiel si sa densité s'écrit

$$f(x, \theta) = \exp(\alpha(\theta)\beta(x) + \gamma(\theta) + \delta(x))$$

$$\Rightarrow a \sum_{i=1}^m \beta(x_i) \text{ est une stat exhaustive}$$

Propositi°:

S: ΔX est indep de θ alors le modèle admet une stat exhaustive ssi il est exponentiel

Théorème: Si \mathcal{X} est indép de θ et que le modèle admet un estimateur efficace alors le modèle est exponentiel car l'estimateur est exhaustif.

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{N}(\mu, \sigma^2)$

On veut estimer μ . On sait que \bar{X}_m est sans biais et converge pour μ

On a :

$$\begin{aligned} L(x_1, \dots, x_m, \mu) &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2\sigma^2}(x_i - \mu)^2\right) \\ &= (2\pi)^{-\frac{m}{2}} \sigma^{-m} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^m (x_i - \mu)^2\right) \end{aligned}$$

$$\ln(L(x_1, \dots, x_m, \mu)) = \frac{m}{2} \ln(2\pi) - m \ln(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^m (x_i - \mu)^2$$

$$\frac{\partial}{\partial \mu} \ln(L(x_1, \dots, x_m, \mu)) = \frac{1}{\sigma^2} \sum_{i=1}^m (x_i - \mu) = \frac{\sum_{i=1}^m x_i}{\sigma^2} - \frac{m\mu}{\sigma^2}$$

$$\frac{\partial^2}{\partial \mu^2} \ln(L(x_1, \dots, x_m, \mu)) = -\frac{m}{\sigma^2}$$

$$I_m(\mu) = -\mathbb{E}\left[\frac{\partial^2}{\partial \mu^2} \ln L(x_1, \dots, x_m, \mu)\right] = -\mathbb{E}\left[-\frac{m}{\sigma^2}\right] = \frac{m}{\sigma^2}$$

$$\text{On a } \mathbb{E}[\bar{X}_m] = \mu \text{ et } V(\bar{X}_m) = \frac{\sum V(X_i)}{m^2} = \frac{\sigma^2}{m}$$

$$\bar{X}_m \text{ est efficace pour } \theta \text{ si } V(\bar{X}_m) = \frac{1}{I_m(\mu)} = \frac{\sigma^2}{m}$$

Il existe : $\mathcal{X} = \mathbb{R}$ indép de θ .

\Rightarrow Le modèle est exponentiel

Vérifier :

$$\begin{aligned} f(x, \mu) &= (2\pi)^{-\frac{1}{2}} \sigma^{-1} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right) \\ &= \exp\left(\underbrace{x\mu}_{\beta(\mu)} - \frac{\mu^2}{2\sigma^2} - \underbrace{\frac{x^2}{2\sigma^2} - \ln(\sigma) - \frac{1}{2}\ln(2\pi)}_{\gamma(x)}\right) \end{aligned}$$

\Rightarrow Le modèle est exponentiel.

$\Rightarrow \bar{X}_m$ est exhaustive pour μ

Vérifier :

$$\text{On a } \bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{m}\right).$$

$$L_{\bar{X}}(x, \mu) = \left(\frac{1}{2\pi}\right) \left(\frac{\sigma}{\sqrt{m}}\right)^m \exp\left(-\frac{m}{2\sigma^2}(x - \mu)^2\right)$$

$$\ln(L_{\bar{x}}(x, \mu)) = -\ln(2\pi) - \ln\left(\frac{1}{\sqrt{m}}\right) - \frac{m}{2\sigma^2}(x-\mu)^2$$

$$\frac{\partial}{\partial \mu} \ln(L_{\bar{x}}(x, \mu)) = \frac{m}{\sigma^2}(x-\mu) = \frac{mx}{\sigma^2} - \frac{m\mu}{\sigma^2}$$

$$\frac{\partial^2}{\partial \mu^2} \ln(L_{\bar{x}}(x, \mu)) = -\frac{m}{\sigma^2} \Rightarrow I_{\bar{x}}(\mu) = -\mathbb{E}\left[\frac{\partial^2}{\partial \mu^2} \ln(L_{\bar{x}}(x, \mu))\right] = \frac{m}{\sigma^2} = I_m(\mu)$$

$\Rightarrow \bar{X}_m$ exhaustive.

II - Quelques méthodes d'estimation.

Méthode empirique ou bricolage

Si le paramètre θ représente une quantité particulière pour le modèle (expérience, variable, forme sup...), on peut choisir "naturellement" la quantité empirique correspondante (issue de la stat descriptive) calculée sur l'échantillon X_1, \dots, X_m

Pour exemple, X_1, \dots, X_m iid tq $X_i \sim \mathcal{B}(\theta)$

On a $\mathbb{E}[X] = \theta$ et $V(X) = \theta$

On peut estimer θ par $\frac{1}{m} \sum_{i=1}^m X_i$ ou par $\frac{1}{m} \sum_{i=1}^m (X_i - \bar{X}_m)^2$

Avantage: Facile à utiliser

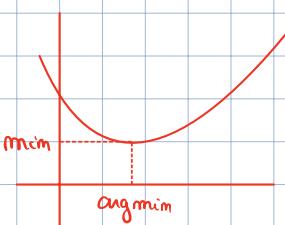
Inconvénient: Limité

Moindres carrés:

Définition: On appelle estimateur des moindres carrés de θ la statistique

$$\hat{\theta}_{MC} = \arg \min_{\theta} \sum_{i=1}^m (X_i - h_i(\theta))^2$$

où $h_i(\theta) = \mathbb{E}[X_i]$
 le θ qui
 minimise



Idee: On cherche θ qui minimise la distance entre les observat° et leurs valeur théorique.

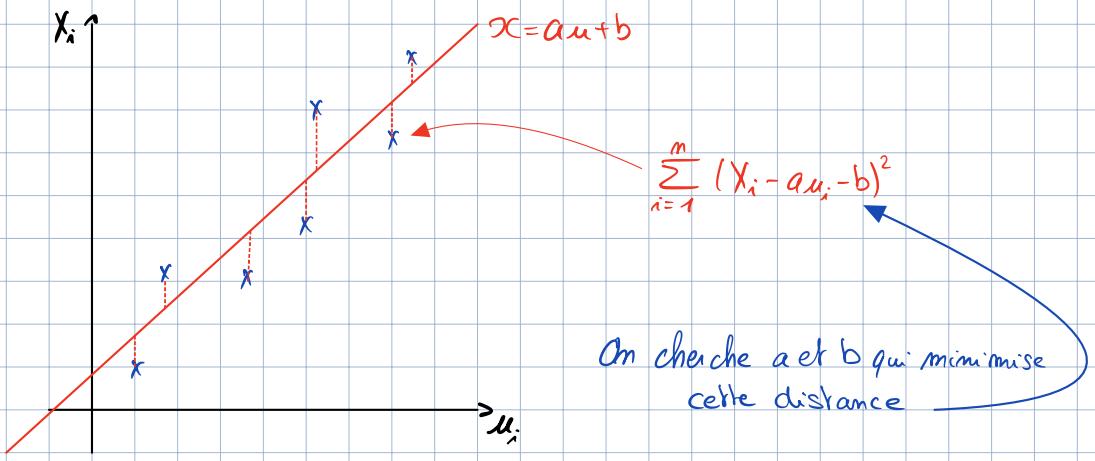
Exemple: En économétrie, on prend

$$X_i = a u_i + b + \varepsilon_i$$

Les v.a. observés
 Comme
 paramètres du modèle.

v.a. centrée et
 tq $V(\varepsilon_i) = \sigma^2$
 et $\varepsilon_1, \dots, \varepsilon_m$ indép.

On a $\mathbb{E}[X_i] = au_i + b$.



Icissi $E_i \sim \mathcal{X}(0, \sigma^2)$

$X_i \sim N(au_i + b, \sigma^2)$ donc les X_i sont indép mais m'ont pas la même loi.

Théorème: Si on est dans le cas X_1, \dots, X_m iid tq $\mathbb{E}[X_i] = h(\theta)$ avec h bijective

$$\hat{\theta}_{MC} = \underset{\theta \in \Theta}{\operatorname{arg\,min}} \sum_{i=1}^m (X_i - h(\theta))^2$$

$$\text{alors } \hat{\theta}_m = h^{-1}(\bar{X}_m)$$

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{E}(\theta)$. On a $\mathbb{E}[X_i] = \frac{1}{\theta}$.

$$\begin{aligned} \hat{\theta}_{MC} &= \underset{\theta}{\operatorname{arg\,min}} \sum_{i=1}^m \left(X_i - \frac{1}{\theta}\right)^2 && \rightsquigarrow \begin{cases} h(\theta) = \sum (X_i - \frac{1}{\theta})^2 \\ h'(\theta) = \cancel{\frac{1}{\theta^2}} 2 \sum (X_i - \frac{1}{\theta}) \end{cases} \\ \Rightarrow \hat{\theta}_{MC} &= (\bar{X}_m)^{-1} && \begin{aligned} \text{Truc} \\ \Rightarrow \frac{1}{\theta} = \sum \frac{X_i}{m} \\ \rightarrow \hat{\theta} = \frac{m}{\sum X_i} \end{aligned} \end{aligned}$$

Avantages:

- adaptée à des paramètres multidimensionnels
- adaptée au cas où les v.a sont indép mais pas identiquement distribuées (cf modèle linéaire).

Inconvénients:

- Truc d'économétrie
- Il faut que l'espérance s'exprime comme une fonction de (tous les) paramètres.

Méthode des moments

Rappel: Soit X une v.a.r

Le moment (théorique) d'ordre r de X est $M_r(\theta) = \mathbb{E}[X^r]$

Le moment centré (théorique) d'ordre r de X est $\bar{M}_r(\theta) = \mathbb{E}[(X - \mathbb{E}[X])^r]$

Si on a un échantillon d'observation (x_1, \dots, x_m) , le moment empirique d'ordre r est $m_r = \frac{1}{m} \sum_{i=1}^m x_i^r$.

Le moment empirique centré d'ordre r est $\bar{m}_r = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^r$

Principe: On suppose que le paramètre est de dimension p . On cherche θ qui égale les p premiers moments empiriques et théoriques. Autrement dit, on pose le système d'éqns:

$$\left\{ \begin{array}{l} M_1(\theta) = m_1 \\ M_p(\theta) = \bar{m}_p \end{array} \right. \quad \text{ou} \quad \left\{ \begin{array}{l} M_1(\theta) = m_1 \\ \bar{M}_p(\theta) = \bar{m}_p \end{array} \right.$$

dépendant de θ

ne dépend pas de θ

\Rightarrow Nb d'éqns = dimens° du paramètre.

Exemple: On prend X_1, \dots, X_m iid tq $X_i \sim \text{Gamma}(a, b)$ de densité $\frac{x^{a-1} \theta^a}{\Gamma(a)} e^{-\theta x}$.

On a $\mathbb{E}[X_i] = \frac{a}{\theta}$ et $V(X) = \frac{a}{\theta^2}$

L'estimateur des moments $(\hat{a}_m, \hat{\theta}_m)$ est tq

$$\left\{ \begin{array}{l} \bar{X}_m = \frac{\hat{a}_m}{\hat{\theta}_m} \\ \bar{X}_m^2 - \bar{X}_m = \frac{\hat{a}_m}{\hat{\theta}_m^2} \end{array} \right. \Rightarrow \begin{aligned} \hat{a}_m &= \frac{(\bar{X}_m)^2}{\bar{X}_m^2 - \bar{X}_m} \\ \hat{\theta}_m &= \frac{\bar{X}_m}{\bar{X}_m^2 - \bar{X}_m} \end{aligned}$$

$\frac{1}{m} \sum_{i=1}^m \hat{X}_i^2 - (\frac{1}{m} \sum_{i=1}^m \hat{X}_i)^2$

Avantages

- adaptée aux paramètres multidimensionnels
- Relativement simple à mettre en place
- On peut trouver des propriétés asymptotiques pour les estimateurs
- On n'a pas besoin de connaître le modèle, juste les moments.
- Numériquement léger.

Inconvénients:

- ne servir à cas iid
- On a besoin des moments jusqu'à l'ordre p.

Méthode du maximum de vraisemblance

Définition: On appelle estimateur du maximum de vraisemblance (maximum likelihood estimator) de θ la statistique

$\hat{\theta}_{\text{MV}}$ rendant maximale la vraisemblance i.e.

$$\hat{\theta}_{\text{MV}} = \underset{\theta \in \Theta}{\operatorname{arg\,max}} L(X_1, \dots, X_m, \theta)$$

Remarque:

- L'idée de maximiser la vraisemblance est assez naturelle : c'est la valeur qui maximise la probabilité d'obtenir les réalisations.
- C'est valable quelque soit le modèle mais si on a les bonnes hypothèses, c'est + facile.

Propriété: Si le modèle vérifie les hypothèses (H1) à (H4)

alors pour que $\hat{\theta}_{\text{MV}}$ soit un EMV (estimateur du maximum de vraisemblance) de θ , il est nécessaire que :

$$\begin{cases} \frac{\partial}{\partial \theta} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{\text{MV}}} = 0 \text{ i.e. } S_m(X_1, \dots, X_m, \hat{\theta}_{\text{MV}}) = 0 \\ \frac{\partial^2}{\partial \theta^2} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{\text{MV}}} < 0 \end{cases}$$

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{E}(\theta)$

On a bien toutes les hypothèses.

$$L(X_1, \dots, X_m, \theta) = \prod_{i=1}^m f(x_i) = \prod_{i=1}^m \theta e^{-\theta x_i} = \theta^m e^{-\theta \sum_{i=1}^m x_i}$$

$$\ln L(X_1, \dots, X_m, \theta) = m \ln(\theta) - \theta \sum_{i=1}^m x_i$$

$$\frac{\partial}{\partial \theta} \ln L(X_1, \dots, X_m, \theta) = \frac{m}{\theta} - \sum_{i=1}^m x_i$$

$$\hat{\theta}_{\text{MV}} \text{ est tq } \frac{m}{\hat{\theta}_{\text{MV}}} - \sum_{i=1}^m x_i = 0$$

$$\Rightarrow \hat{\theta}_{\text{MV}} = \frac{\sum_{i=1}^m x_i}{m}$$

$$\left. \begin{aligned} \frac{\partial^2}{\partial \theta^2} \ln L(x_1, \dots, x_m, \theta) &= -\frac{m}{\theta^2} \end{aligned} \right\} \Rightarrow \hat{\theta}_{\text{MV}} = \frac{m}{\sum_{i=1}^m x_i} \text{ est l'EMV de } \theta.$$

Exemple:

On prend X_1, \dots, X_m iid tq $X_i \sim U[0, \theta]$

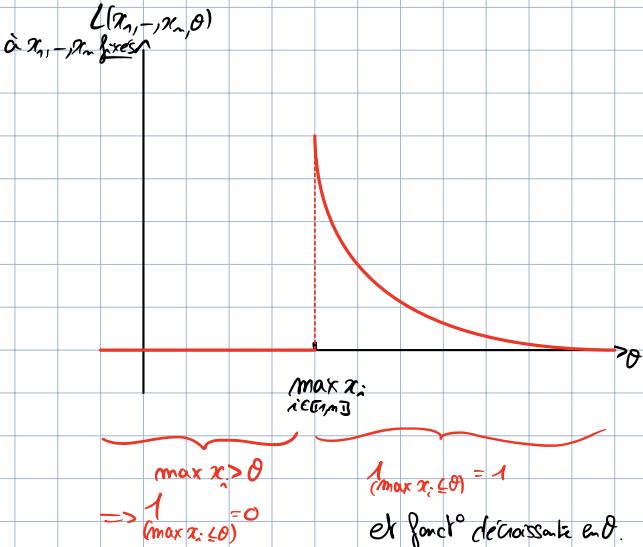
$$\begin{aligned} L(x_1, \dots, x_m, \theta) &= \prod_{i=1}^m f(x_i, \theta) = \prod_{i=1}^m \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) \\ &= \frac{1}{\theta^m} \prod_{i=1}^m \mathbf{1}_{[0, \theta]}(x_i) \quad = \mathbf{1}_{(\min x_i \geq 0)} \times \mathbf{1}_{(\max x_i \leq \theta)} \\ &= \begin{cases} 1 & \text{si tous les } x_i \text{ sont } [0, \theta] \\ 0 & \text{sinon} \end{cases} \end{aligned}$$

On n'a pas (H1) donc on ne peut pas passer par le ln

On maximise directement la vraisemblance

$$L(x_1, \dots, x_m, \theta) = \frac{1}{\theta^m} \mathbf{1}_{(\min x_i \geq 0)} \times \mathbf{1}_{(\max x_i \leq \theta)}$$

$$\Rightarrow \hat{\theta}_{\text{MV}} = \max_{i \in \{1, \dots, m\}} X_i$$



Aantages:

- C'est celui qu'on utilise le + en pratique
- S'il existe une stat exhaustive T_m , $\hat{\theta}_{\text{MV}}$ dépend que de T_m
- Il a beaucoup de propriétés asymptotiques.

Inconvénients:

- Il faut très bien connaître le modèle.
- Numériquement ça peut être lourd.

Rappel: X_1, \dots, X_m iid tq $X_i \sim P_\theta$

T_m est l'estimateur de θ

Exhaustivité

$$1 - I_{T_m}(\theta) = I_m(\theta)$$

avant d'informations
dans X_1, \dots, X_m que
dans T_m

2- Si h est la densité de T_m .

$$L(x_1, \dots, x_m, \theta) = h(t, \theta) k(x_1, \dots, x_m)$$

$$3- L(x_1, \dots, x_m, \theta) = \psi(t, \theta) \psi(x_1, \dots, x_m)$$

4- Si on a le modèle exponentiel i.e. $f(x) = \exp\{\alpha(\theta)\beta(x) + \delta(x) + g(\theta)\}$

$$\Rightarrow \sum \beta(x_i)$$
 exhaustive

5- Si X ne dépend pas de θ (H1) alors efficace \Rightarrow exhaustif.

Méthodes d'estimation:

- Moindres Carrés:

$$\hat{\theta}_{MC} = \underset{\theta \in \Theta}{\operatorname{argmin}} \sum_{i=1}^m (X_i - h_i(\theta))^2$$

$h_i(\theta) = E[X_i]$

- Méthode des moments:

$$\text{Si } \theta \text{ est de dimens}^o p, E[X_i^k] = M_k(\theta)$$

$$\text{et } \frac{1}{m} \sum_{i=1}^m x_i^k = m_k$$

$$\hat{\theta}_{MM} \text{ est tq } \begin{cases} M_1(\hat{\theta}_{MM}) = m_1 \\ \vdots \\ M_p(\hat{\theta}_{MM}) = m_p \end{cases}$$

- Méthode du max de vraisemblance: (Maximum Likelihood Estimator)

$$\hat{\theta}_{ML} = \underset{\theta \in \Theta}{\operatorname{argmax}} L(X_1, \dots, X_m, \theta)$$

) On n'a pas besoin de (H1) etc.

Si on a (H1) à (H4) vérifiée alors $\hat{\theta}_{ML}$ tq:

$$\begin{cases} \frac{\partial}{\partial \theta} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{ML}} = 0 \\ \frac{\partial^2}{\partial \theta^2} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{ML}} < 0 \end{cases}$$

VII - Généralisation à un paramètre multidimensionnel

On considère le modèle stat

$$(R, \mathcal{B}(R), P_\theta, \theta \in \Theta \subseteq R^p)^m$$

p ≥ 2

Une stat T_m est une fonction de X_1, \dots, X_m pas la vraie def.
C'est un vecteur aléatoire de dimension p avec

$$\bar{T}_m = (T_{m,1}, \dots, T_{m,p})$$

$$\text{et on a } \theta = (\theta_1, \dots, \theta_p)$$

Biais:

$$B_\theta(T_m) = E[T_m] - \theta = \begin{pmatrix} E[T_{m,1}] \\ \vdots \\ E[T_{m,p}] \end{pmatrix} - \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_p \end{pmatrix} = \begin{pmatrix} E[T_{m,1}] - \theta_1 \\ \vdots \\ E[T_{m,p}] - \theta_p \end{pmatrix} = \begin{pmatrix} B_{\theta_1}(T_{m,1}) \\ \vdots \\ B_{\theta_p}(T_{m,p}) \end{pmatrix}$$

\bar{T}_m est sans biais si $B_\theta(\bar{T}_m) = \theta$

\bar{T}_m est asymptotiquement sans biais si: $B_\theta(\bar{T}_m) \rightarrow \theta$ i.e. $\forall j \in \{1, p\}, E[T_{m,j}] \rightarrow \theta_j$

Convergence:

\bar{T}_m est convergent pour θ si $\bar{T}_m \xrightarrow{P} \theta$.

C'est à dire si $\forall j \in \{1, p\}, T_{m,j} \xrightarrow{P} \theta_j$

Risque quadratique: Rappel: en dim 1 $R(T_m, \theta) = E((T_m - \theta)^2)$

$$\begin{aligned} R(T_m, \theta) &= E[(T_m - \theta)'(T_m - \theta)] = E[(T_{m,1} - \theta_1, \dots, T_{m,p} - \theta_p) \begin{pmatrix} T_{m,1} - \theta_1 \\ \vdots \\ T_{m,p} - \theta_p \end{pmatrix}] \\ &= E\left[\sum_{j=1}^p (T_{m,j} - \theta_j)^2\right] = \sum_{j=1}^p E[(T_{m,j} - \theta_j)^2] \\ &= \sum_{j=1}^p R(T_{m,j}, \theta_j) \\ \Rightarrow R(T_m, \theta) &= \sum_{j=1}^p B_{\theta_j}(T_j)^2 + \sum_{j=1}^p V(T_{m,j}) \\ &= B_\theta(T_m)' B_\theta(T_m) + \sum_{j=1}^p V(T_{m,j}) \end{aligned}$$

Généralisation de Cramér-Rao:

On note

$f(x, \theta)$ la vraisemblance du modèle en dimension 1 i.e. si m=1
= densité de X.

$L(x_1, \dots, x_m, \theta)$ la vraisemblance du modèle
= densité du vecteur (X_1, \dots, X_m)

\mathcal{X} est le support de f et \mathcal{X}' est le support de L .

Hypothèses de régularité

(H1') \mathcal{X} est indépendant de θ) On a $f(x, \theta) > 0$

(H2') \mathcal{X} est un ouvert. $\forall (x, \theta) \in \mathcal{X} \times \Theta$

(H3') $\forall j \in \{1, p\}$, $\frac{\partial}{\partial \theta_j} f(x, \theta)$ est bien définie $\forall (x, \theta) \in \mathcal{X} \times \Theta$

$\forall (j, k) \in \{1, p\}^2$, $\frac{\partial^2}{\partial \theta_j \partial \theta_k} f(x, \theta)$ est bien définie $\forall (x, \theta) \in \mathcal{X} \times \Theta$

(H4') $\forall (j, k) \in \{1, p\}^2$, $\frac{\partial}{\partial \theta_j} f(x, \theta)$ et $\frac{\partial^2}{\partial \theta_j \partial \theta_k} f(x, \theta)$

Vérifiant l'hypothèse (H4) de dominatio sur tout compact de Θ
par des fonct° de x μ -intégrables

$$\left(\frac{\partial}{\partial \theta} \int = \int \frac{\partial}{\partial \theta} \right) \text{ pour pouvoir}$$

Définition: (Score)

La fonction score définie par la fonct°

$$S: \mathcal{X} \times \Theta \longrightarrow \mathbb{R}$$

$$(x, \theta) \longmapsto \text{grad} \ln f(x, \theta) = \begin{pmatrix} \frac{\partial}{\partial \theta_1} \ln f(x, \theta) \\ \vdots \\ \frac{\partial}{\partial \theta_m} \ln f(x, \theta) \end{pmatrix}$$

On peut définir $S_m(x_1, \dots, x_m, \theta) = \text{grad} \ln L(x_1, \dots, x_m, \theta)$

Si on a le modèle d'échantillonnage (i.e. X_1, \dots, X_m iid)

$$S_m(x_1, \dots, x_m, \theta) = \sum_{i=1}^m S(x_i, \theta)$$

Si on a (H4') on a $\mathbb{E}[S(X, \theta)] = \mathbf{0}_p = \mathbb{E}[S_m(x_1, \dots, x_m, \theta)]$

Définition: (Matrice d'informat°)

La matrice d'informat° de Fisher est une matrice $p \times p$ définie par
 $I(\theta) = \mathbb{E}[S(X, \theta) S(X, \theta)']$

C'est la matrice de forme générale

$$\mathbb{E}\left[\frac{\partial}{\partial \theta_i} \ln f(x, \theta) \frac{\partial}{\partial \theta_k} \ln f(x, \theta)\right]$$

Sur la diagonale on a $\mathbb{E}\left[\left(\frac{\partial}{\partial \theta_i} \ln f(x, \theta)\right)^2\right] = \mathbb{E}[S(X, \theta)_i^2] = I(\theta_i)$

$$I_m(\theta) = \mathbb{E}[S_m(x_1, \dots, x_m, \theta) \cdot S_m(x_1, \dots, x_m, \theta)']$$

Si (H_4') vérifiée, la matrice $I(\theta)$ est la matrice de variance de $S(X, \theta)$.

© Théo Jalabert

$\Rightarrow I(\theta)$ est une matrice symétrique et (semi) définie positive.

Le terme général de $I(\theta)$ est

$$-\mathbb{E}\left[\frac{\partial^2}{\partial \theta_j \partial \theta_k} \ln f(x, \theta)\right]$$

Dans le modèle d'échantillonnage $I_m(\theta) = m I(\theta)$

Exemple:

X_1, \dots, X_n va suivre $X_i \sim N(\mu, \sigma^2)$

$$I_{\text{ci}}(\theta) = (\mu, \sigma^2) = (\mu, \alpha)$$

La densité est :

$$f(x, \theta) = \frac{1}{\sqrt{2\pi}} \alpha^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\alpha} (x - \mu)^2\right\}$$

$$L(X_1, \dots, X_n, \theta) = \prod_{i=1}^n f(x_i, \theta) = (2\pi)^{-\frac{n}{2}} \alpha^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\alpha} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

$$=\left(2\pi\right)^{-\frac{n}{2}} \alpha^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\alpha} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

$$\ln L(X_1, \dots, X_n, \theta) = -\frac{m}{2} \ln(2\pi) - \frac{m}{2} \ln(\alpha) - \frac{1}{2\alpha} \sum_{i=1}^m (x_i - \mu)^2$$

$$\frac{\partial}{\partial \alpha} \ln L(X_1, \dots, X_n, \theta) = -\frac{m}{2\alpha} + \frac{\alpha^{-2}}{2} \sum_{i=1}^m (x_i - \mu)^2$$

$$\frac{\partial}{\partial \mu} \ln L(X_1, \dots, X_n, \theta) = \alpha^{-1} \sum_{i=1}^m (x_i - \mu)$$

$$\Rightarrow S_m(X_1, \dots, X_n, \theta) = \begin{pmatrix} \alpha^{-1} \sum (x_i - \mu)^2 \\ -\frac{m}{2\alpha} + \frac{1}{2} \alpha^{-2} \sum (x_i - \mu)^2 \end{pmatrix}$$

On utilise la formule $I_m(\theta) = (-\mathbb{E}\left[\frac{\partial^2}{\partial \theta_j \partial \theta_k} \ln L(X_1, \dots, X_n, \theta)\right])_{j,k}$

$$\frac{\partial^2}{\partial \alpha^2} \ln L(X_1, \dots, X_n, \theta) = \frac{m}{2\alpha^2} - \alpha^{-3} \sum (x_i - \mu)^2$$

$$\frac{\partial^2}{\partial \mu^2} \ln L(X_1, \dots, X_n, \theta) = -\frac{m}{\alpha}$$

$$\frac{\partial^2}{\partial \alpha \partial \mu} \ln L(X_1, \dots, X_n, \theta) = -\alpha^{-2} \sum_{i=1}^m (x_i - \mu)$$

$$-\mathbb{E}\left[-\alpha^{-2} \sum_{i=1}^m (x_i - \mu)\right] = \alpha^{-2} \sum \mathbb{E}(x_i - \mu)$$

$$I_m(\theta) = \begin{pmatrix} -\mathbb{E}\left[\frac{\partial^2}{\partial \alpha^2} \ln L\right] & -\mathbb{E}\left[\frac{\partial^2}{\partial \alpha \partial \mu} \ln L\right] \\ -\mathbb{E}\left[\frac{\partial^2}{\partial \mu \partial \alpha} \ln L\right] & -\mathbb{E}\left[\frac{\partial^2}{\partial \mu^2} \ln L\right] \end{pmatrix}$$

$$= \begin{pmatrix} \frac{m}{\alpha} & 0 \\ 0 & \frac{m}{2\alpha^2} \end{pmatrix}$$

$$I_m(\theta) = \begin{pmatrix} \frac{m}{\alpha^2} & 0 \\ 0 & \frac{m}{2\alpha^4} \end{pmatrix}$$

On a 0 car on n'a pas d'interaction entre les paramètres.

$$\begin{aligned} & \text{Car } \mathbb{E}\left[\sum (x_i - \mu)^2\right] = m \\ & \mathbb{E}\left[\sum (x_i - \mu)^2\right] = m \\ & \Rightarrow \mathbb{E}\left[\sum (x_i - \mu)^2\right] = m^2 \end{aligned}$$

$$-\frac{m}{2\alpha^2} + \alpha^{-3} \mathbb{E}\left[\sum_{i=1}^m (x_i - \mu)^2\right] = -\frac{m}{2\alpha^2} + \frac{2m}{2\alpha^2} = \frac{m}{2\alpha^2}$$

Inégalité de Cramér-Rao :

Soit T_m un estimateur de θ tq $E[T_m] = g(\theta)$ i.e. $\forall j \in \{1, p\}$, $E[T_{m,j}] = g_{jj}(\theta)$

Soit $D_g(\theta)$ la matrice Jacobienne de g i.e. la matrice carrée de forme général $\frac{\partial}{\partial \theta_k} g_{ij}(\theta)$ pour $(i, k) \in \{1, p\}^2$

Soit $V(T_m)$ la matrice de variance de T_m .

On a besoin en plus

(HS') $I_m(\theta)$ est définie positive, alors la matrice

$V(T_m) - D_g(\theta) I_m(\theta)^{-1} D_g(\theta)'$ est semi définie positive

Borne inf de l'inégalité
de Cramér-Rao.

T_m est efficace si $V(T_m) = D_g(\theta) I_m^{-1}(\theta) D_g(\theta)'$

Dans le cas d'un estimateur sans biais, on a $V(T_m) - I_m(\theta)^{-1}$ est semi définie positive.

Exemple : X_1, \dots, X_m va iid tq $X_i \sim N(\mu, \sigma^2)$

On sait que \bar{X}_m est un ESB de μ et $\frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2$ est un ESB de σ^2

On a $\bar{X}_m \sim N(\mu, \frac{\sigma^2}{m})$ et on a $\sigma^2 \sum_{i=1}^m (X_i - \bar{X}_m)^2 \sim \chi_{m-1}^2 \Rightarrow \begin{cases} E[\sum_{i=1}^m (X_i - \bar{X}_m)^2] = (m-1)\sigma^2 \\ V[\sum_{i=1}^m (X_i - \bar{X}_m)^2] = 2(m-1)\sigma^4 \end{cases}$

Si $T_m = (\bar{X}_m, \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2)$ alors

$$\begin{aligned} V(T_m) &= \begin{pmatrix} \frac{\sigma^2}{m} & 0 \\ 0 & \frac{2\sigma^4}{m-1} \end{pmatrix} \quad \text{CP TO 1 exo!} \\ V(\bar{X}_m) &= \frac{\sigma^2}{m} \quad \quad \quad V\left(\frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2\right) \\ &= \frac{1}{(m-1)^2} V\left(\sum_{i=1}^m (X_i - \bar{X})^2\right) = \frac{2\sigma^4}{m-1} \end{aligned}$$

$$I_m(\theta)^{-1} = \begin{pmatrix} \frac{1}{m} & 0 \\ 0 & \frac{1}{2\sigma^2} \end{pmatrix} \Rightarrow T_m \text{ est sans biais. } T_m \text{ efficace si } V(T_m) = I_m(\theta)^{-1}$$

i.e., T_m n'est pas efficace pour θ .

Généralisation de la famille exponentielle :

Définition : On dit qu'une loi de probabilité appartient à la famille exponentielle (à paramètre multidimensionnel) si sa vraisemblance s'écrira sous la forme

$$f(x, \theta) = \exp\left(\sum_{j=1}^p \alpha_j(\theta) \beta_j(x) + g(x) + h(\theta)\right) \quad \text{si } x \in \mathcal{X}$$

fonct de $R \rightarrow R$
fonct de $R^p \rightarrow R$

Si $\forall j \in \{1, p\}$, $\alpha_j(\theta) = \theta_j$, on a la forme naturelle de la loi exponentielle

Si $\forall j \in \{1, p\}$, $\beta_j(x) = x_j$, on a la forme canonique de la loi exponentielle.

Exemple: $X \sim \mathcal{N}(\mu, \sigma^2)$, on a

$$f(x) = (2\pi)^{-\frac{n}{2}} (\sigma^2)^{\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

$$= \exp\left(-\frac{x^2}{2\sigma^2} + \frac{x\mu}{\sigma^2} - \frac{\mu^2}{2\sigma^2} - \frac{1}{2}\ln(\sigma^2) - \frac{1}{2}\ln(2\pi)\right)$$

$$\text{ici, } \begin{cases} \alpha_1(\mu, \sigma^2) = \frac{1}{2\sigma^2} & \beta_1(x) = x^2 \\ \alpha_2(\mu, \sigma^2) = \frac{\mu}{\sigma^2} & \beta_2(x) = x \end{cases}$$

$$f(x) = 0 \quad \delta(\mu, \sigma^2) = -\frac{\mu^2}{2\sigma^2} - \frac{1}{2}\ln(\sigma^2) - \frac{1}{2}\ln(2\pi)$$

Généralisation du maximum de vraisemblance :

Définition: L'estimateur du maximum de vraisemblance du θ est défini par

$$\hat{\theta}_{\text{MV}} = \underset{\theta \in \Theta}{\operatorname{argmax}} L(X_1, \dots, X_m, \theta)$$

Caractéristique: Si on a (H1') à (H4') vérifiés, alors pour déterminer $\hat{\theta}_{\text{MV}}$, on résoud

$$S_m(X_1, \dots, X_m, \hat{\theta}_{\text{MV}}) = 0 \quad \text{i.e.} \quad \begin{cases} \frac{\partial}{\partial \theta_1} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{\text{MV}}} = 0 \\ \vdots \\ \frac{\partial}{\partial \theta_p} \ln L(X_1, \dots, X_m, \theta) \Big|_{\theta=\hat{\theta}_{\text{MV}}} = 0 \end{cases}$$

et on vérifie que la matrice jacobienne de $\ln L$ (matrice carrée de forme général $\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j}$) calculée en $\hat{\theta}_{\text{MV}}$ est définie négative.

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{N}(\mu, \sigma^2 = \alpha)$

$$L(x_1, \dots, x_m, \mu, \alpha) = (2\pi)^{-\frac{m}{2}} 2^{-\frac{m}{2}} \exp\left(-\frac{1}{2\alpha} \sum_{i=1}^m (x_i - \mu)^2\right)$$

$$\ln L(x_1, \dots, x_m, \mu, \alpha) = -\frac{m}{2} \ln(2\pi) - \frac{m}{2} \ln(\alpha) - \frac{1}{2\alpha} \sum_{i=1}^m (x_i - \mu)^2$$

$$\frac{\partial}{\partial \mu} \ln L(x_1, \dots, x_m, \mu, \alpha) = -\frac{m}{2\alpha} + \frac{1}{2\alpha^2} \sum_{i=1}^m (x_i - \mu)^2$$

$$\frac{\partial}{\partial \alpha} \ln L(x_1, \dots, x_m, \mu, \alpha) = \frac{1}{2} \sum_{i=1}^m (x_i - \mu)$$

L'estimateur du maximum de vraisemblance de (μ, α) est tq

$$\begin{cases} -\frac{m}{2\alpha} + \frac{1}{2\alpha^2} \sum_{i=1}^m (x_i - \mu)^2 = 0 \\ \frac{1}{2} \sum_{i=1}^m (x_i - \mu) = 0 \end{cases} \iff \begin{cases} m\hat{\alpha} = \sum_{i=1}^m (x_i - \hat{\mu})^2 \\ \sum_{i=1}^m x_i = m\hat{\mu} \end{cases}$$

$$\Rightarrow \begin{cases} \hat{\mu}_{\text{MV}} = \frac{1}{m} \sum_{i=1}^m x_i \\ \hat{\alpha}^2 = \frac{1}{m} \sum_{i=1}^m (X_i - \bar{X}_m)^2 \end{cases}$$

On calcule la matrice jacobienne

$$\frac{\partial^2}{\partial \mu^2} \ln L(x_1, \dots, x_m, \mu, \alpha) = -\frac{m}{\alpha}$$

$$\frac{\partial^2}{\partial \alpha^2} \ln L(x_1, \dots, x_m, \mu, \alpha) = \frac{m}{2\alpha} - \frac{1}{\alpha^3} \sum_{i=1}^m (x_i - \mu)^2$$

© Théo Jalabert 

$$\frac{\partial^2}{\partial \alpha \partial \mu} \ln L(x_1, \dots, x_m, \mu, \alpha) = -\frac{1}{\alpha^2} \sum_{i=1}^m (x_i - \mu)$$

$$\Rightarrow H(x_1, \dots, x_m, \mu, \alpha) = \begin{pmatrix} -\frac{m}{\alpha} & -\frac{1}{\alpha^2} \sum_{i=1}^m (x_i - \mu)^2 \\ \frac{m-1}{2\alpha^3} \sum_{i=1}^m (x_i - \mu)^4 & \end{pmatrix}$$

Pour que $(\hat{\mu}_{MV}, \hat{\sigma}_{MV})$ soit un EMV, il faut que $H(\hat{\mu}_{MV}, \hat{\sigma}_{MV})$ soit définie négative.

$$H(\hat{\mu}_{MV}, \hat{\sigma}_{MV}) = \begin{pmatrix} -\frac{m}{2\hat{\sigma}_{MV}} & 0 \\ 0 & -\frac{m}{2\hat{\sigma}_{MV}^2} \end{pmatrix}$$

$\begin{aligned} -\frac{1}{2\hat{\sigma}_{MV}^2} \sum_{i=1}^m (x_i - \hat{\mu}_{MV})^2 &= 0 \\ &= \sum_{i=1}^m x_i - m\hat{\mu}_{MV} \\ &= \bar{x} \end{aligned}$

 $\begin{aligned} \frac{m}{2\hat{\sigma}_{MV}} - \frac{1}{2\hat{\sigma}_{MV}^3} \sum_{i=1}^m (x_i - \hat{\mu}_{MV})^4 & \\ &= \frac{m}{2\hat{\sigma}_{MV}} - \frac{m}{2\hat{\sigma}_{MV}^2} = -\frac{m}{2\hat{\sigma}_{MV}^2} \end{aligned}$

9 Novembre CC.

Chapitre III : Comportement asymptotique des estimateurs



Idee: On a X_1, \dots, X_m iid $\ln X_i \sim P_\theta$. On a un estimateur T_m de θ mais on ne peut l'evaluer pas calculer sa loi. On regarde ce qu'il se passe quand $m \rightarrow \infty$.

On a besoin de deux hypothèses supplémentaires :

$$(H6) \theta \neq \theta' \Rightarrow P_\theta \neq P_{\theta'} \quad (\text{on dit que le modèle est identifiable}).$$

Exemple: $Y_i = aX_i + b + \varepsilon_i$ $\varepsilon_i \sim N(0, \sigma^2)$ (a, b, m) et $(a, b-m, 0)$ donnent la même distribution des Y_i

$$(H7) \frac{\partial^2}{\partial \theta^2} \ln f(x, \theta) \text{ est continue en } \theta, \text{ uniformément en } x.$$

Théorème: Si on a les hypothèses (H1) à (H4) et (H6) vérifiées, alors

il existe une suite d'estimateurs du max de vraisemblance $(\hat{\theta}_m^{MV})_m$ qui converge presque sûrement vers θ .

Rq: C'est la version de la LGN pour les EMV.

Théorème: Sous les hypothèses (H1) à (H7), on a

$$\sqrt{m}(\hat{\theta}_m^{MV} - \theta) \xrightarrow{\mathcal{L}} N(0, I^{-1}(\theta))$$

Preuve:

On considère

$$h_m(X_1, \dots, X_m, \theta) = \frac{1}{m} \sum_{i=1}^m \underbrace{\frac{\partial \ln f(X_i, \theta)}{\partial \theta}}$$

$= S(X_i, \theta)$

Va d'espérance nulle et de variance $I(\theta)$.

$$\text{On a } \sqrt{m} h_m(X_1, \dots, X_m, \theta) \xrightarrow{\mathcal{L}} N(0, I(\theta)) \text{ ou } \sqrt{m} \frac{h_m(X_1, \dots, X_m, \theta)}{\sqrt{I(\theta)}} \xrightarrow{\mathcal{L}} N(0, 1).$$

On note

$$K_m(X_1, \dots, X_m, \theta) = \frac{1}{m} \sum_{i=1}^m \frac{\partial^2}{\partial \theta^2} \ln f(X_i, \theta) \longrightarrow I(\theta)$$

On a

$$h_m(X_1, \dots, X_m, \theta) = h_m(X_1, \dots, X_m, \theta) + (t - \theta) K_m(X_1, \dots, X_m, \theta)$$

avec $\theta^* \in]\min(t, \theta), \max(t, \theta)[$

On calcule en $\hat{\theta}_m^{MV}$

$$\begin{aligned} h_m(X_1, \dots, X_m, \hat{\theta}_m^{MV}) &= h_m(X_1, \dots, X_m, \theta) + (\hat{\theta}_m^{MV} - \theta) K_m(X_1, \dots, X_m, \theta^*) \\ &= 0 \quad \text{car } S_m(X_1, \dots, X_m, \hat{\theta}_m^{MV}) = 0 \end{aligned}$$

$$\Rightarrow \underbrace{h_m(X_1, \dots, X_n, \theta)}_{\mathcal{L} \downarrow N(0, I(\theta))} + (\hat{\theta}_m^{MV} - \theta) \underbrace{V_m(X_1, \dots, X_n, \theta^*)}_{\begin{array}{l} \text{On a } \hat{\theta}_m^{MV} \xrightarrow{\text{P.S.}} \theta \\ \text{et } \frac{\partial^2}{\partial \theta^2} \ln f(x, \theta) \text{ continue en } \theta \text{ uniforme en } x \end{array}} \downarrow -I(\theta)$$

$$\Rightarrow \sqrt{n}(\hat{\theta}_m^{MV} - \theta) \xrightarrow{} N(0, I(\theta)^{-1})$$

Rappel:Maximum de vraisemblance ($\theta \in \mathbb{R}^p$)

$$\hat{\theta}_m^{MV} = \underset{\theta \in \Theta}{\operatorname{argmax}} L(X_1, \dots, X_n, \theta)$$

Si on a toutes les hypothèses $\hat{\theta}_m^{MV}$ est lg
 $S_m(X_1, \dots, X_n, \hat{\theta}_m^{MV}) = 0$

et la matrice Hessianne de $\ln L$ est def négative

Comportement asympt.

Si on a toutes les hypothèses (Surtout H1 X indep de θ et H_X : Identifiabilité du modèle i.e. $\theta \neq \theta'$
 $\Rightarrow P_\theta \neq P_{\theta'}$)

$$\begin{aligned} \hat{\theta}_m^{MV} &\xrightarrow{\text{P.S.}} \theta \\ \text{et } \sqrt{n}(\hat{\theta}_m^{MV} - \theta) &\xrightarrow{\mathcal{L}} N(0, I(\theta)) \end{aligned}$$

Remarque:

④ $\hat{\theta}_m^{MV} \xrightarrow{\text{P.S.}} \theta$ justifie que dans la pratique on cherche une valeur qui annule l'égalité de vraisemblance et on prend cette valeur comme estimateur de $\hat{\theta}_m^{MV}$

(Rappel: $\hat{T}_m = g_m(X_1, \dots, X_n)$ estimateur, $\hat{t}_m = g(x_1, \dots, x_n)$ estimateur)

En particulier, dans les cas "compliqués" où on ne peut pas obtenir d'expressions analytiques de $\hat{\theta}_m^{MV}$, on utilise un algorithme d'optimisation pour obtenir une estimateur du max de vraisemblance).

Pour exemple, X_1, \dots, X_n iid lg $X_i \sim \text{GEV}(\mu, \sigma, \zeta)$

Generalized Extreme Value Distribution.

i.e de densité

$$f(x) = \frac{1}{\Gamma} \left(1 + \zeta \left(\frac{x-\mu}{\sigma}\right)\right)^{-\frac{\zeta+1}{\zeta}} \exp\left(-\left(1 + \zeta \left(\frac{x-\mu}{\sigma}\right)\right)^{\frac{1}{\zeta}}\right)$$

Sous R

X observat°

```

 $\loglik = \text{function(theta)}$ 
 $\{$ 
 $\text{mu} = \text{theta}[1]; \sigma = \text{theta}[2]; \zeta = \text{theta}[3]$ 
 $\text{resultat} = \text{sum}(\log(dgev(x, -)))\}$ 
 $\text{optimize(loglik, -1)}$ 

```

④ On peut écrire
 $\sqrt{m} (\hat{\theta}_m^{\text{MV}} - \theta) \xrightarrow{\mathcal{L}} N(0, 1)$

ou
 $\sqrt{I_m(\theta)} (\hat{\theta}_m^{\text{MV}} - \theta) \xrightarrow{\mathcal{L}} N(0, 1)$

⑤ Si on est en dimension $p \geq 2$, en adoptant les hypothèses on a
 $\sqrt{m} (\hat{\theta}_m^{\text{MV}} - \theta) \xrightarrow{\mathcal{L}} N_p(0, I'(\theta))$

matrice info
de Fisher.

II - Notations - Définitions

- Soit T_m un estimateur de θ .

S'il existe Σ tq

$$\sqrt{m}(T_m - \theta) \xrightarrow{\mathcal{L}} N(0, \Sigma)$$

) Asympt. normal

On dit que T_m est asympt. normal.

La matrice Σ est la matrice de variance asymptotique de T_m .

Si on a :

$$\sqrt{m}(T_m - \theta) \xrightarrow{\mathcal{L}} N_p(0, I'(\theta))$$

alors

T_m est asympt. efficace pour θ .

Rq: L'EMV est asympt. normal et asympt. efficace.

Rappel:

④ Si $X_m - Y_m \xrightarrow{P} 0$ et $X_m \xrightarrow{\mathcal{L}} X$ alors $Y_m \xrightarrow{\mathcal{L}} X$.

④ Si $X_m \xrightarrow{\mathcal{L}} X$ et $Y_m \xrightarrow{P} a$ alors $X_m Y_m \xrightarrow{\mathcal{L}} aX$.

④ $a_m(X_m - \mu) \xrightarrow{\mathcal{L}} X$ et $a_m \rightarrow \infty$ alors $X_m \xrightarrow{P} \mu$.

Méthode Delta:

Cette méthode extrait le Si on a un estimateur asymptotiquement normal du paramètre θ et que je m'intéresse à $g(\theta)$

Soit g une fonct° C^1 , on suppose qu'on a un estimateur T_m de θ tq:

on peut remplacer
par $a_m \rightarrow \infty$

$$\sqrt{m}(T_m - \theta) \xrightarrow{\mathcal{L}} N(0, \sigma^2(\theta))$$

alors $g(T_m)$ converge en proba vers $g(\theta)$ et on a:

$$\sqrt{m}(g(T_m) - g(\theta)) \xrightarrow{\mathcal{L}} N(0, \sigma^2(\theta) (g'(\theta))^2)$$

Exemple: X_1, \dots, X_n iid tq $X_i \sim \mathcal{E}(\theta)$

Maximum de vraisemblance:

$$L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum_{i=1}^n x_i}$$

$$\ln L(x_1, \dots, x_n, \theta) = n \ln \theta - \theta \sum_{i=1}^n x_i$$

$$\frac{\partial}{\partial \theta} \ln L(x_1, \dots, x_m, \theta) = \frac{m}{\theta} - \sum_{i=1}^m x_i$$

$$\text{L'EMV } \hat{\theta}_m^{\text{MV}} \text{ est tel que } \frac{m}{\hat{\theta}_m^{\text{MV}}} - \sum_{i=1}^m x_i = 0$$

$$\Rightarrow \hat{\theta}_m^{\text{MV}} = \frac{m}{\sum_{i=1}^m x_i}$$

$$\frac{\partial^2}{\partial \theta^2} \ln L(x_1, \dots, x_m, \theta) = -\frac{m}{\theta^2} < 0$$

$$\therefore I_m(\theta) = -E\left[\frac{\partial^2}{\partial \theta^2} \ln L(x_1, \dots, x_m, \theta)\right] = \frac{m}{\theta^2} \Rightarrow I(\theta) = \theta^{-2}$$

Comme toutes les hypothèses sont vérifiées, on a:

$$\sqrt{m}(\hat{\theta}_m^{\text{MV}} - \theta) \xrightarrow{\mathcal{D}} N(0, I^{-1}(\theta))$$

$$\Rightarrow \sqrt{m}(\hat{\theta}_m^{\text{MV}} - \theta) \xrightarrow{\mathcal{D}} N(0, \theta^2)$$

Méthode des moments: (on oublie tout)

Le paramètre θ est en dimension 1 donc on a besoin que de 1 équation $E[X_1] = \frac{1}{\theta}$.

L'estimateur des moments $\hat{\theta}_m^{\text{MV}}$ est tel que

$$M_1(\hat{\theta}_m^{\text{MV}}) = \bar{X}_m$$

i.e.

$$\frac{1}{\hat{\theta}_m^{\text{MV}}} = \bar{X}_m \Rightarrow \hat{\theta}_m^{\text{MV}} = \frac{1}{\bar{X}_m}$$

Normalité asymptotique de $\hat{\theta}_m^{\text{MV}}$?

On applique le TCL à X_1, \dots, X_m i.e.

$$\sqrt{m} \frac{\bar{X}_m - E[X_1]}{\sqrt{V(X_1)}} \xrightarrow{\mathcal{D}} N(0, 1)$$

$$\begin{aligned} \Rightarrow \sqrt{m} \frac{\bar{X}_m - \frac{1}{\theta}}{\sqrt{1/\theta^2}} &\xrightarrow{\mathcal{D}} N(0, 1) && \text{dans l'échelle de la méthode Delta.} \\ \Rightarrow \sqrt{m} \left(\bar{X}_m - \frac{1}{\theta} \right) &\xrightarrow{\mathcal{D}} N(0, \theta^2) \end{aligned}$$

On va appliquer la méthode Delta au TCL avec $g(x) = \frac{1}{x}$.

$$\text{On a } g(\bar{X}_m) = \frac{1}{\bar{X}_m} = \hat{\theta}_m^{\text{MM}} ; \quad g\left(\frac{1}{\theta}\right) = \theta ; \quad g'(x) = -\frac{1}{x^2} \quad (g'\left(\frac{1}{\theta}\right))^2 = \theta^4$$

$$\Rightarrow \sqrt{m}(g(\bar{X}_m) - g\left(\frac{1}{\theta}\right)) \xrightarrow{\mathcal{D}} N(0, \theta^2(g'\left(\frac{1}{\theta}\right))^2)$$

$$\Rightarrow \sqrt{m}(\hat{\theta}_m^{\text{MM}} - \theta) \xrightarrow{\mathcal{D}} N(0, \theta^2)$$

On obtient bien le même résultat que le max de vraisemblance
(car dans ce cas, on a $\hat{\theta}_m^{\text{MV}} = \hat{\theta}_m^{\text{MM}}$)

Méthode Delta en dimension Sup:

On considère T_m un vecteur aléatoire de \mathbb{R}^k , Σ est une matrice de variance telle que

$$\sqrt{m}(T_m - \theta) \xrightarrow{\mathcal{D}} N(0, \Sigma)$$

Soit g une fonction alors,
 $\sqrt{m} (g(\bar{X}_m) - g(0)) \xrightarrow{\mathcal{L}} N(0, D_g \sum D_g^{-1})$

© Théo Jalabert

TF

où D_g est la matrice Jacobienne de g calculée en 0.

Rq:

Si on veut la normalité asymptotique d'un estimateur des moments $\hat{\theta}_m^{\text{MM}}$ de $\theta \in \mathbb{R}$:

$$\text{On a } \hat{\theta}_m^{\text{MM}} = g(\bar{X}_m, \bar{X}_m^2)$$

$$\begin{pmatrix} V(X_m) & \text{Cor}(X_m, X_m^2) \\ \text{Cor}(X_m, X_m^2) & V(X_m^2) \end{pmatrix}$$

On prend le TCL multivarié

$$\sqrt{m} \begin{pmatrix} \bar{X}_m - E[X_m] \\ \bar{X}_m^2 - E[X_m^2] \end{pmatrix} \xrightarrow{\mathcal{L}} N(0, \Sigma)$$

On applique la méthode Delta au TCL et à g

Exemple: X_1, \dots, X_m i.i.d. t.q. $X_i \sim \Gamma(k, \theta)$

$\overset{?}{\text{ER}}$

$$\text{i.e. de densité } f(x) = \frac{x^{k-1} \theta^k e^{-\theta x}}{\Gamma(k)}$$

On veut estimer k et θ par la méthode des moments.

On a besoin de deux moments.

$$E[X] = \int x \frac{x^{k-1} \theta^k}{\Gamma(k)} e^{-\theta x} dx = \int x^k \frac{\theta^k}{\Gamma(k+1)} e^{-\theta x} dx = \frac{k}{\theta} \int x^k \frac{\theta^{k+1}}{\Gamma(k+1)} e^{-\theta x} dx$$

densité d'une $\Gamma(k+1, \theta)$

$$= \frac{k}{\theta}$$

$$E[X^2] = \int x^2 \frac{x^{k-1} \theta^k}{\Gamma(k)} e^{-\theta x} dx = \frac{k(k+1)}{\theta^2} \int x^{k+1} \frac{\theta^{k+2}}{\Gamma(k+2)} e^{-\theta x} dx = \frac{k(k+1)}{\theta^2}$$

L'estimateur des moments $(\hat{\theta}_m^{\text{M}}, \hat{\theta}_m^{\text{MM}})$ est t.q.

$$\begin{cases} \frac{\hat{\theta}_m^{\text{M}}}{\hat{\theta}_m^{\text{MM}}} = \bar{X}_m \\ \frac{(\hat{\theta}_m^{\text{M}})(\hat{\theta}_m^{\text{M}} + 1)}{(\hat{\theta}_m^{\text{MM}})^2} = \bar{X}_m^2 \end{cases} \Rightarrow \begin{cases} \hat{\theta}_m^{\text{M}} = \frac{\hat{\theta}_m^{\text{MM}}}{\bar{X}_m} \\ (\hat{\theta}_m^{\text{M}} + 1) = \frac{\bar{X}_m^2}{\hat{\theta}_m^{\text{MM}}} \end{cases}$$

$$\begin{cases} \hat{\theta}_m^{\text{M}} = \frac{\hat{\theta}_m^{\text{MM}}}{\bar{X}_m} \\ (\bar{X}_m)^2 (\hat{\theta}_m^{\text{M}} + 1) = \bar{X}_m^2 \hat{\theta}_m^{\text{MM}} \end{cases} \Rightarrow \begin{cases} \hat{\theta}_m^{\text{M}} = \frac{\hat{\theta}_m^{\text{MM}}}{\bar{X}_m} \\ \hat{\theta}_m^{\text{M}} (\bar{X}_m^2 - \bar{X}_m^2) = \bar{X}_m^2 \end{cases}$$

$$\begin{cases} \hat{\theta}_m^{\text{M}} = \frac{\bar{X}_m}{\bar{X}_m^2 - \bar{X}_m^2} \\ \hat{\theta}_m^{\text{MM}} = \frac{\bar{X}_m^2}{\bar{X}_m^2 - \bar{X}_m^2} \end{cases}$$

Si on veut trouver la normalité asymptotique de $(\hat{\theta}_m^{\text{M}}, \hat{\theta}_m^{\text{MM}})$ on applique la méthode Delta au TCL bidimensionnel appliquée à (X_m, X_m^2) et $g(x, y) = \left(\frac{x}{y-x^2}, \frac{x^2}{y-x^2} \right)$

i.e. on a le TCL

$$\sqrt{m} \begin{pmatrix} \bar{X}_m - \frac{k}{\theta} \\ \bar{X}_m^2 - \frac{k(k+1)}{\theta^2} \end{pmatrix} \xrightarrow{\mathcal{L}} N(0, \Sigma)$$

$$\begin{pmatrix} \frac{k}{\theta^2} & \text{Cor}(X, X^2) \\ \text{Cor}(X, X^2) & V(X^2) \end{pmatrix}$$

$$E[X^3] - E[X]E[X^2] = \frac{k(k+1)(k+2)}{\theta^3} - \frac{k}{\theta} \frac{(k+1)k}{\theta^2}$$

$$\text{On prend la fonction } g(x, y) = \left(\frac{x}{y-x^2}, \frac{x^2}{y-x^2} \right) \text{ avec } g\left(\frac{k}{\theta}, \frac{k(k+1)k}{\theta^2}\right) = (\theta, k)$$

... finir les calculs

⚠ Pour le CC du 09/11/22. On s'arrête ici, le reste me sera pas au programme.

Chapitre IV : Estimation par intervalle de Confiance

TD Actuariat

+ 10/11 AM // Access
 09/11 PM → 10/11 PM // SAS
 16/11 PM → 17/11 PM // SAS
 30/11 PM → 28/11 PM // Access
 07/12 PM → 08/12 PM // Access
 14/12 PM → 12/12 PM // économie

CM

09/11 PM ← CC
 16/11 PM
 30/11 PM

Idee: Si on a une distribution continue P_θ , on estime θ par T_m alors $P(T_m = \theta) = 0$ et en plus on sait pas si T_m est proche ou pas de θ .

⇒ On va donner un intervalle qui va contenir θ avec une proba très élevée (style 95% ou +)

Modèle: On se place dans le modèle $(R, \mathcal{B}(R), P_\theta, \theta \in \Theta \subseteq R)^m$

Définition: Soit $\alpha \in [0, 1]$. On appelle intervalle de confiance de niveau $1-\alpha$ de paramètre θ la donnée de 2 statistiques A_m et B_m tq: $P(A_m \leq \theta \leq B_m) = 1-\alpha$.

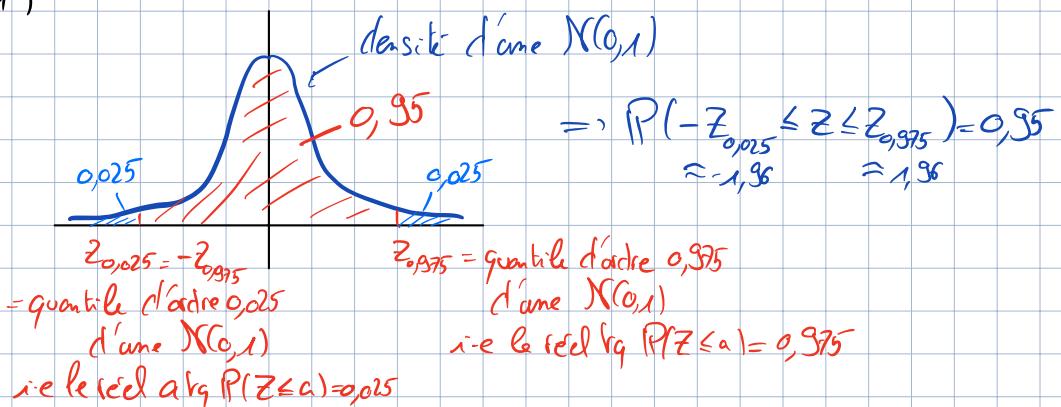
Exemple: Soit X_1, \dots, X_m iid tq $X_i \sim N(\theta, 1)$

On veut construire un intervalle de confiance pour θ de niveau 95% i.e $\alpha = 5\%$

Donc $\sqrt{m}(\bar{X}_m - \theta) \sim N(0, 1)$

Fond "pivot" = fond de T_m et de θ mais dont la loi ne dépend pas de θ

Si $Z \sim N(0, 1)$



Comme $\sqrt{m}(\bar{X}_m - \theta) \sim N(0, 1)$ on a

$$P(-Z_{0,975} \leq \sqrt{m}(\bar{X}_m - \theta) \leq Z_{0,975}) = 0,95$$

$$\Rightarrow P\left(-\frac{Z_{0,975}}{\sqrt{m}} \leq \bar{X}_m - \theta \leq \frac{Z_{0,975}}{\sqrt{m}}\right) = 0,95$$

$$\Rightarrow P\left(\underbrace{\bar{X}_m - \frac{Z_{0,975}}{\sqrt{m}}}_{A_m} \leq \theta \leq \underbrace{\bar{X}_m + \frac{Z_{0,975}}{\sqrt{m}}}_{B_m}\right) = 0,95$$

de la def

Remarques - Commentaires:

⊗ α est un risque i.e le risque que le paramètre θ ne soit pas dans l'intervalle de confiance. C'est nous qui le choisissons.

Si α est trop petit, l'IC est très grand et pas informatif

Si α est trop grand, l'IC sera à rien (prob. trop forte de ne pas contenir θ).

\Rightarrow En général, on prend $\alpha = 5\%$ (ou 1% ou 10%).

Le niveau $1-\alpha$ est appelé $\begin{cases} \text{coefficier de confiance} \\ \text{niveau} \end{cases}$

⊗ On a $P(A_m \leq B_m) = 1$

⊗ Soit x_1, \dots, x_m des réalisat° de X_1, \dots, X_n

On a $a_m = A_m(x_1, \dots, x_m)$ et $b_m = B_m(x_1, \dots, x_m)$

On a $[a_m, b_m]$ est un intervalle réel inclus dans ⊗

Pour contre, on a $P(a_m \leq \theta \leq b_m) = 0$ ou 1.
rien d'aléatoire.

⊗ C'est plus raisonnable d'estimer θ par IC que par estimation ponctuelle.

⊗ L'intervalle de confiance n'est pas unique.

Si on revient à l'exemple



Remarque: La notion d'intervalle de confiance est liée aux tests.

On pense que le montant moyen des sinistres sur un porte feuille (i.e l'espérance de la v.a qui génère les sinistres) est 7800€

On regarde les observations et on calcule un intervalle de confiance de niveau 95% (basé sur le modèle choisi) par $\mu = \mathbb{E}[X]$ et on trouve [7857, 8216]

2 possibilités

- on n'a pas eu de chance et on est tombé sur un des 5% d'échantillons ne contenant pas μ .
- on s'est planté et $\mu \neq 7800\text{€}$) on cherche ça.

Exemple:

$$X_1, \dots, X_m \text{ iid } \text{Ig} \quad X_i \sim N(\mu, \sigma^2)$$

μ et σ^2 sont inconnus et on veut un intervalle de confiance pour μ .

On ne peut pas utiliser $\sqrt{m} \frac{\bar{X}_m - \mu}{\sigma} \sim N(0, 1)$

On remplace σ par $\sqrt{S_m^2}$ i.e $\sqrt{\frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X}_m)^2}$

$$\left\{ \begin{array}{l} \bar{X}_m \sim N\left(\mu, \frac{\sigma^2}{m}\right) \text{ i.e } \frac{\bar{X}_m - \mu}{\sigma/\sqrt{m}} \sim N(0, 1) \\ \sigma^2 \sum_{i=1}^m (X_i - \bar{X}_m)^2 \sim \chi^2_{m-1} \text{ i.e } \sigma^2(m-1) S_m^2 \sim \chi^2_{m-1} \end{array} \right.$$

Rappel: Si $Z \sim N(0, 1)$ $W \sim \chi^2_k$ et Z indép de W

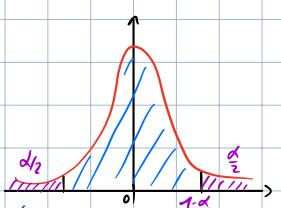
$$\text{alors } \frac{Z}{\sqrt{W/k}} \sim t_k$$

Ici :

$$\frac{\frac{\bar{X}_m - \mu}{\sigma/\sqrt{m}}}{\sqrt{\frac{(m-1) S_m^2}{\sigma^2(m-1)}}} \sim t_{m-1} \quad (\text{Student à } (m-1) \text{ degrés de liberté})$$

$$= \sqrt{m} \frac{\bar{X}_m - \mu}{\sqrt{S_m^2}} \sim t_{m-1}$$

Si $T \sim t_{m-1}$



t_{m-1} = quantile d'ordre $1 - \frac{\alpha}{2}$ d'une Student à $m-1$ degrés de liberté.

Rappel: Si X_m est une suite de v.a lg $X_m \sim t_m$ alors $X_m \xrightarrow{L} X$ avec $X_m \sim N(0, 1)$

$$k_{m-1} = x \quad \text{tq } P(k_{m-1} \leq x) = 1 - \frac{\alpha}{2}$$

$$= q_{\text{Student}}(1 - \frac{\alpha}{2}, df=m-1)$$

quantile Student degree of freedom

k_{m-1} = quantile d'ordre $\frac{\alpha}{2}$ de la $t_{m-1} \sim t_{m-1}^{1-\frac{\alpha}{2}}$

\curvearrowleft distribution de Student est symétrique.

$$\text{Si } T \sim k_{m-1} \text{ alors } P(-k_{m-1}^{1-\frac{\alpha}{2}} \leq T \leq k_{m-1}^{1-\frac{\alpha}{2}}) = 1 - \alpha$$

$$\text{Comme } \sqrt{m} \frac{\bar{X}_m - \mu}{\sqrt{S_m^2}} \sim k_{m-1}$$

$$\text{On a } P(-k_{m-1}^{1-\frac{\alpha}{2}} \leq \sqrt{m} \frac{\bar{X}_m - \mu}{\sqrt{S_m^2}} \leq k_{m-1}^{1-\frac{\alpha}{2}}) = 1 - \alpha$$

$$P\left(-k_{m-1}^{1-\frac{\alpha}{2}} \sqrt{\frac{S_m^2}{m}} \leq \bar{X}_m - \mu \leq k_{m-1}^{1-\frac{\alpha}{2}} \sqrt{\frac{S_m^2}{m}}\right) = 1 - \alpha$$

$$P\left(\underbrace{\bar{X}_m - k_{m-1}^{1-\frac{\alpha}{2}} \sqrt{\frac{S_m^2}{m}}}_{A_m} \leq \mu \leq \underbrace{\bar{X}_m + k_{m-1}^{1-\frac{\alpha}{2}} \sqrt{\frac{S_m^2}{m}}}_{B_m}\right) = 1 - \alpha$$

A.N: On suppose qu'on a des pertes sur des contrats x_1, \dots, x_n .

On suppose qu'elles sont indép et qu'elles sont les observat° de $N(\mu, \sigma^2)$. On a observé $\bar{x}_m = 80,12 \text{ €}$ et $S_m^2 = 16,16$ (variance estimée).

(o) Valeur estimée de \bar{x}_m

(o) Valeur observée de S_m^2

On veut un intervalle de confiance de niveau 95% pour μ .

$$\text{Pour } m=100 \text{ et } \alpha = 5\%. \text{ On a } k_{99}^{0,875} = q_t(0,975, df=99) = 1,984$$

\Rightarrow L'intervalle de confiance observé de niveau 95% pour μ est :

$$\left[80,12 - 1,984 \times \sqrt{\frac{16,16}{100}}, 80,12 + 1,984 \times \sqrt{\frac{16,16}{100}} \right]$$

$$= [80,12 \pm 7,97] \approx [80,04; 82,20].$$

\Rightarrow L'intervalle est petit, a priori on a une « bonne estimation ».

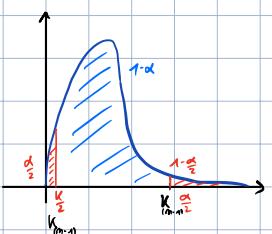
Exemple:

$$X_1, \dots, X_m \text{ iid tq } X_i \sim N(\mu, \sigma^2)$$

μ et σ^2 sont inconnus et on veut construire un intervalle de confiance de niveau $1 - \alpha$ pour σ^2 .

$$\text{On a } \frac{1}{\sigma^2} \sum_{i=1}^m (X_i - \bar{X})^2 \sim \chi^2_{m-1}$$

$$\text{Si } W = \chi^2_{m-1}$$



$$\begin{aligned} k_{m-1} &= \text{Quantile d'ordre } 1 - \frac{\alpha}{2} \text{ d'une } \chi^2_{m-1} \\ &= x \in \text{ER tq } P(\chi^2_{m-1} \leq x) = 1 - \frac{\alpha}{2} \\ &= q_{\text{chisq}}(1 - \frac{\alpha}{2}, df=m-1) \end{aligned}$$

quantile chisquare degree of freedom

quantile d'ordre $\frac{\alpha}{2}$ d'une χ^2_{m-1}
 $\Rightarrow P(K_{(m-1)}^{\alpha/2} \leq W \leq k_{(m-1)}^{1-\alpha/2}) = 1-\alpha$.

Comme $\frac{1}{\sigma^2} \sum_{i=1}^m (X_i - \bar{X}_m)^2 \sim \chi^2_{m-1}$, on a $P(K_{(m-1)}^{\alpha/2} \leq \frac{1}{\sigma^2} \sum_{i=1}^m (X_i - \bar{X}_m)^2 \leq k_{(m-1)}^{1-\alpha/2}) = 1-\alpha$.

$$\Rightarrow P\left(\frac{\sum_{i=1}^m (X_i - \bar{X}_m)^2}{k_{(m-1)}^{1-\alpha/2}} \leq \frac{\sigma^2}{A_m} \leq \frac{\sum_{i=1}^m (X_i - \bar{X}_m)^2}{B_m}\right) = 1-\alpha$$

$$P\left(\frac{(m-1)S_m^2}{k_{(m-1)}^{1-\alpha/2}} \leq \sigma^2 \leq \frac{(m-1)S_m^2}{k_{(m-1)}^{\alpha/2}}\right) = 1-\alpha.$$

A.N: $m=100$, $\alpha=5\%$, $\bar{x}=8012$ et $S_m^2=1616$

$$\text{Ici, } k_{m-1}^{1-\alpha/2} = \text{qchisq}(0.975, df=99) \approx 129$$

$$k_{m-1}^{\alpha/2} = \text{qchisq}(0.025, df=99) \approx 74$$

$$\text{et } (m-1)S_m^2 = 159984.$$

L'intervalle de confiance estimé de niveau $1-\alpha$ pour σ^2 vaut:

$$\left[\frac{(m-1)S_m^2}{k_{m-1}^{1-\alpha/2}}, \frac{(m-1)S_m^2}{k_{m-1}^{\alpha/2}} \right] = \left[\frac{159984}{129}, \frac{159984}{74} \right] \approx [1240, 2162].$$

II – Intervalles de Confiance asymptotique.

Idee: C'est pas facile de faire des I.C de niveau exact $1-\alpha$ (on doit bien connaître l'estimateur etc.)

\Rightarrow On va chercher A_m et B_m tq $P(A_m \leq \theta \leq B_m) \rightarrow 1-\alpha$.

Définition: Un intervalle de confiance asymptotique ou de niveau de confiance asymptotique est deux statistiques A_m et B_m tq $P(A_m \leq \theta \leq B_m) \rightarrow 1-\alpha$.

Utilisation du TCL

Soit X_1, \dots, X_m v.a. iid tq $X_i \sim P_0$, $E[X_i] = \mu$ et $V(X_i) = \sigma^2$ alors on sait que:

$$\sqrt{m} \frac{\bar{X}_m - \mu}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1) \text{ quand } m \rightarrow \infty.$$

En utilisant cela, on peut construire des IC asymptotiques:

- de μ si σ est connu
- de σ si μ est connu
- de θ si μ et σ^2 dépendent de θ (Style Poisson, exponentielle...)

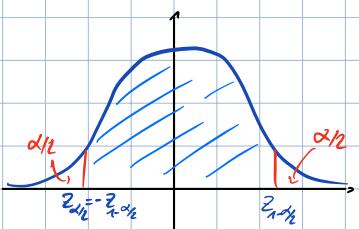
Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{E}(\theta)$

Exponentielle

On veut construire un IC de niveau asymptotique $1-\alpha$ pour θ .

$$\text{On a } \sqrt{m} \frac{\bar{X}_m - \frac{1}{\theta}}{\sqrt{1/\theta^2}} \xrightarrow{\mathcal{L}} N(0, 1)$$

Si $Z \sim N(0, 1)$



$$\text{On a } P(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha}) = 1-\alpha$$

Si on a $Z_m \xrightarrow{\mathcal{L}} Z$ alors

$$P(-z_{1-\alpha/2} \leq Z_m \leq z_{1-\alpha}) \rightarrow 1-\alpha.$$

$$\text{Ici on a: } P(-z_{1-\alpha/2} \leq \sqrt{m} \frac{\bar{X}_m - \frac{1}{\theta}}{\sqrt{1/\theta^2}} \leq z_{1-\alpha}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(-z_{1-\alpha/2} \leq \sqrt{m} (\theta \bar{X}_m - 1) \leq z_{1-\alpha}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(-\frac{z_{1-\alpha/2}}{\sqrt{m}} \leq \theta \bar{X}_m - 1 \leq \frac{z_{1-\alpha/2}}{\sqrt{m}}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(\frac{1}{\bar{X}_m} - \frac{z_{1-\alpha/2}}{\sqrt{m} \bar{X}_m} \leq \theta \leq \frac{1}{\bar{X}_m} + \frac{z_{1-\alpha/2}}{\sqrt{m} \bar{X}_m}) \rightarrow 1-\alpha.$$

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{P}(\lambda)$

Poisson

On a \bar{X}_m est un super estimateur de λ et $\bar{X}_m \xrightarrow{P} \lambda$

On a

$$\sqrt{m} \frac{\bar{X}_m - 1}{\sqrt{\lambda}} \xrightarrow{\mathcal{L}} N(0, 1)$$

Rappel (Slutsky): Si $\begin{cases} X_m \xrightarrow{\mathcal{L}} X \\ Y_m \xrightarrow{P} 1 \end{cases} \Rightarrow X_m Y_m \xrightarrow{\mathcal{L}} X.$

Ici on a $\frac{\lambda}{\bar{X}_m} \xrightarrow{P} 1$ et $\sqrt{\frac{\lambda}{\bar{X}_m}} \xrightarrow{P} 1$

Idée: On remplace dans le TCL le paramètre σ par un estimateur convergent: $\sqrt{m} \frac{\bar{X}_m - \mu}{\sigma} \xrightarrow{\mathcal{L}} N(0, 1)$

Ici on a: $\sqrt{\frac{\lambda}{\bar{X}_m}} \times \sqrt{m} \frac{\bar{X}_m - \lambda}{\sqrt{\lambda}} \xrightarrow{\mathcal{L}} N(0, 1).$

$\downarrow P$ $\downarrow \mathcal{L}$

$N(0, 1)$

$$\Rightarrow \sqrt{m} \frac{\bar{X}_m - \theta}{\sqrt{\hat{I}_m}} \xrightarrow{\mathcal{L}} N(0, 1)$$

$$\text{On a } P(-Z_{1-\alpha/2} \leq \sqrt{m} \frac{\bar{X}_m - \theta}{\sqrt{\hat{I}_m}} \leq Z_{1-\alpha/2}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(\underbrace{\bar{X}_m - Z_{1-\alpha/2} \sqrt{\frac{\hat{I}_m}{m}}}_{A_m} \leq \theta \leq \underbrace{\bar{X}_m + Z_{1-\alpha/2} \sqrt{\frac{\hat{I}_m}{m}}}_{B_m}) \rightarrow 1-\alpha.$$

Utilisation de la normalité asymptotique de l'EMV.

Rappel: Si on a toutes les hypothèses alors si $\hat{\theta}_m$ est la suite d'EMV de θ .

$$\sqrt{m} (\hat{\theta}_m - \theta) \xrightarrow{\mathcal{L}} N(0, I'(\theta))$$

$$\text{ou } \sqrt{m} \left(\frac{\hat{\theta}_m - \theta}{\sqrt{I'(\theta)}} \right) \xrightarrow{\mathcal{L}} N(0, 1)$$

$$\text{ou } \sqrt{I'(\theta)} (\hat{\theta}_m - \theta) \xrightarrow{\mathcal{L}} N(0, 1).$$

En général, on prend $\widehat{I}'(\theta)$ un estimateur convergent pour $I'(\theta)$.

On a $\sqrt{\frac{\widehat{I}'(\theta)}{I'(\theta)}} \xrightarrow{P} 1$. et donc $\sqrt{m} \frac{\hat{\theta}_m - \theta}{\sqrt{\widehat{I}'(\theta)}} \xrightarrow{\mathcal{L}} N(0, 1)$.

$$\Rightarrow P(-Z_{1-\alpha/2} \leq \sqrt{m} \frac{\hat{\theta}_m - \theta}{\sqrt{\widehat{I}'(\theta)}} \leq Z_{1-\alpha/2}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(\hat{\theta}_m - Z_{1-\alpha/2} \sqrt{\frac{\widehat{I}'(\theta)}{m}} \leq \theta \leq \hat{\theta}_m + Z_{1-\alpha/2} \sqrt{\frac{\widehat{I}'(\theta)}{m}}) \rightarrow 1-\alpha.$$

Exemple: X_1, \dots, X_n iid tq $X_i \sim \mathcal{E}(\theta)$

$$L(x_1, \dots, x_n, \theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i}$$

$$\Rightarrow \ln(L(x_1, \dots, x_n, \theta)) = n \ln(\theta) - \theta \sum_{i=1}^n x_i$$

$$\Rightarrow \frac{\partial}{\partial \theta} \ln L = \frac{n}{\theta} - \sum_{i=1}^n x_i$$

$$\Rightarrow \frac{\partial^2}{\partial \theta^2} \ln L = -\frac{n}{\theta^2}$$

$$\Rightarrow \hat{\theta}_{\text{MV}} = \frac{n}{\sum_{i=1}^n x_i} \quad I'_m(\theta) = \frac{n}{\theta^2} \Rightarrow I(\theta) = \frac{1}{\theta^2}$$

$$\text{On a } \sqrt{m} \frac{\hat{\theta}_{\text{MV}} - \theta}{\theta} \xrightarrow{\mathcal{L}} N(0, 1)$$

On remplace θ (en bas) par $\hat{\theta}_{\text{MV}}$ (rappel: $\hat{\theta}_{\text{MV}} \xrightarrow{P} \theta$ au EMV)

$$\text{car } \frac{\theta}{\hat{\theta}_{\text{MV}}} \xrightarrow{P} 1.$$

$$\text{On a } \sqrt{m} \frac{\hat{\theta}_{\text{MV}} - \theta}{\hat{\theta}_{\text{MV}}} \xrightarrow{\mathcal{L}} N(0, 1)$$

$$\Rightarrow P(-Z_{1-\alpha/2} \leq \sqrt{m} \frac{\hat{\theta}_{\text{MV}} - \theta}{\hat{\theta}_{\text{MV}}} \leq Z_{1-\alpha/2}) \rightarrow 1-\alpha.$$

$$\Rightarrow P(\hat{\theta}_{\text{MV}} - Z_{1-\alpha/2} \frac{\hat{\theta}_{\text{MV}}}{\sqrt{m}} \leq \theta \leq \hat{\theta}_{\text{MV}} + Z_{1-\alpha/2} \frac{\hat{\theta}_{\text{MV}}}{\sqrt{m}}) \rightarrow 1-\alpha.$$

Rappel:Intervalle de Confiance:

Def: Un IC pour θ de niveau $1-\alpha$ est deux stats A_m et B_m tq

$$P(A_m \leq \theta \leq B_m) = 1-\alpha$$

(de niveau asymptotique $1-\alpha$ si $P(A_m \leq \theta \leq B_m) \rightarrow 1-\alpha$)

Technique: On prend une fonction pivot i.e. une fonction de X_1, \dots, X_m et de θ mais dont la loi ne dépend pas de θ .

Exemple: $X_i \sim N(\mu, \sigma^2)$ iid mon commun

On sait que $\frac{\bar{X}_m - \mu}{\sqrt{S_m^2}} \sim t_{m-1}$

Fonct° de pivot $\bar{X}_m - \mu$ Pivot indép de μ

On encadre la fonction pivot avec une probabilité $1-\alpha$ et on isole le paramètre.

Exemple: Si $T \sim t_{m-1}$, alors $P(-t_{1-\alpha/2}^{m-1} \leq T \leq t_{1-\alpha/2}^{m-1}) = 1-\alpha$

$$\Rightarrow P(-t_{1-\alpha/2}^{m-1} \leq \sqrt{m} \frac{\bar{X}_m - \mu}{\sqrt{S_m^2}} \leq t_{1-\alpha/2}^{m-1}) = 1-\alpha.$$

$$\Rightarrow P(\bar{X}_m - t_{1-\alpha/2}^{m-1} \sqrt{\frac{S_m^2}{m}} \leq \mu \leq \bar{X}_m + t_{1-\alpha/2}^{m-1} \sqrt{\frac{S_m^2}{m}}) = 1-\alpha.$$

Pour les IC asymétriques, de même sauf qu'on veut la distribution asymptotique du paramètre.

Exemple: X_1, \dots, X_m iid tq $X_i \sim \mathcal{P}(\lambda)$

On a vu que l'EMV $\hat{\lambda}_m$ de λ est \bar{X}_m et $I(\lambda) = \frac{1}{\lambda}$

Donc comme on a toutes les hypothèses, on a

$$\sqrt{m} (\bar{X}_m - \lambda) \xrightarrow{\mathcal{D}} N(0, \lambda)$$

ou $\sqrt{m} \frac{\bar{X}_m - \lambda}{\sqrt{\lambda}} \xrightarrow{\mathcal{D}} N(0, 1)$

pivot de la loi
asymptotiquement indép de λ

Par Slutsky, comme $\sqrt{\frac{\lambda}{\bar{X}_m}} \xrightarrow{P} 1$, on a

$$\sqrt{m} \frac{\bar{X}_m - \lambda}{\sqrt{\bar{X}}} \xrightarrow{\mathcal{L}} N(0, 1)$$

fond^e pivot
de la loi asymptotique de λ

Si $Z \sim N(0, 1)$, alors $P(-Z_{1-\alpha/2} \leq Z \leq Z_{1-\alpha/2}) = 1-\alpha$
on remplace Z par la fond^e pivot.

$$P(-Z_{1-\alpha/2} \leq \sqrt{m} \frac{\bar{X}_m - \lambda}{\sqrt{\bar{X}_m}} \leq Z_{1-\alpha/2}) \rightarrow 1-\alpha$$

$$\Rightarrow P(\bar{X}_m - Z_{1-\alpha/2} \sqrt{\frac{\bar{X}_m}{m}} \leq \lambda \leq \bar{X}_m + Z_{1-\alpha/2} \sqrt{\frac{\bar{X}_m}{m}}) \rightarrow 1-\alpha.$$

Application numérique

On a un portefeuille avec 10 000 contrats et X_1, \dots, X_{10000} représentant le nbr de sinistre par contrat.

On suppose que les $X_i \sim \mathcal{B}(\lambda)$

L'an dernier, sur le même portefeuille, on avait estimé le paramètre à 3,6. Cette année, on observe $\bar{x}_m = 3,72$
→ On veut un IC à 95% pour λ .

On applique l'exemple : $Z_{1-\alpha/2} = Z_{0,975} = 1,96$.

L'intervalle estimé est

$$[\bar{x}_m \pm 1,96 \sqrt{\frac{\bar{x}_m}{m}}] = [3,682 ; 3,758]$$

Si on regarde d'un point de vue estimation ponctuelle, d'une année à l'autre la distribution a changé.

D'un point de vue IC, si $3,6 \in \text{IC}$ alors ça signifie que 3,72 est un résultat "compatibile" avec la variabilité d'une $\mathcal{B}(3,6)$.

Ici, $3,6 \notin \text{IC}$, donc la distribution a changé.

Chapitre V - Tests

Objectif: On veut construire une aide à la décision (ça aide à décider mais ne décide pas pour autant à notre place) pour choisir entre deux hypothèses H_0 et H_1 .

Exemple: On a des nombres de sinistres par contrats et on a calculé les années passées $\lambda = 3,6$ (paramètre de la loi de Poisson), cette année on a observé $\hat{\lambda}_m = 3,72$.

On veut choisir entre $H_0: \lambda = 3,6$ et $H_1: \lambda \neq 3,6$

Exemple: On a fait une régression linéaire ($y = a_0 + a_1 x + a_2 x_2$) et on a estimé $\begin{cases} a_0 = 4,12 \\ a_1 = 3,48 \\ a_2 = 0,07 \end{cases}$

On veut décider entre $H_0: a_2 = 0$ et $H_1: a_2 \neq 0$.

Exemple: On prend X_1, \dots, X_m iid tq $X_i \sim N(\mu, 1)$

On veut choisir entre $H_0: \mu = 0$ et $H_1: \mu = 1$

On a observé $m = 100$ et $\bar{x} = 0,48$

Idee: On estime μ par \bar{X}_m , on rejette H_0 si \bar{X}_m devient trop grand.

I - Généralités sur les tests.

Le but d'un test statistique est de fournir un critère qui permet de retenir une hypothèse H_0 ou H_1 .
Contre une hypothèse alternative $H_1: \theta \in \mathbb{H}_1$

La mise en œuvre d'un test statistique détermine une zone de rejet W (on rejette H_0) et une zone d'acceptation W^c (on accepte H_0).

Comme c'est basé sur un modèle proba, on a différents risques concernant les hypothèses, l'hypothèse H_0 est celle qu'on pense être vraie et qui est privilégiée. C'est l'hypothèse qu'on va rejeter uniquement si on a de vraies arguments pour le rejeter.

Parallèle: Au tribunal, un prévenu est supposé innocent jusqu'à ce qu'on amène les preuves de sa culpabilité.

H_0 : il est innocent contre H_1 : il est coupable.

Le rôle des hypothèses n'est pas symétrique.



Risques:

* Le premier risque est le risque de première espèce = proba. On risque de rejeter H_0 alors que H_0 est vraie.

On le note $\alpha = \underline{\underline{P(W|H_0)}}$ ← on le choisir
proba d'être dans la zone de rejet sachant que H_0 est vraie

La puissance du test est la proba de rejeter H_0 avec $\beta = P(W^c|H_1)$

* Le risque de deuxième espèce est la proba d'accepter H_0 alors que H_1 est vraie.

$$1-\beta = P(W^c|H_1)$$

		H_0	H_1
<u>réalité</u>	H_0	$1-\alpha$ ①	α ②
	H_1	$1-\beta$ ③	β ④

1. proba d'accepter H_0 avec raison
2. proba de rejeter H_0 à tort
3. proba d'accepter H_0 à tort
4. proba de rejeter H_0 avec raison.

Définition: On se place dans le modèle statistique $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_\theta, \mathcal{D} \textcircled{G})^m$

* Un test statistique est donné par une fonction $\phi: \mathbb{R}^m \rightarrow \{0,1\}$

On rejette H_0 si $\phi(X_1, \dots, X_m) = 0$ et on accepte H_0 si $\phi(X_1, \dots, X_m) = 1$.

* La zone de rejet W est l'ensemble $\{(X_1, \dots, X_m) \in \mathbb{R}^m, \phi(X_1, \dots, X_m) = 1\}$

Si on a une région de rejet W alors $\phi = 1_W$

Si $H_0: \textcircled{G} = \{\theta_0\}$ et $H_1: \textcircled{G} = \{\theta_1\}$, on parle d'hypothèses simples.

* Le niveau d'un test, ou sensibilité, est la proba de rejeter H_0 à tort.

$$\alpha = \sup_{\theta \in \textcircled{G}} P_\theta((X_1, \dots, X_m) \in W)$$

$$\begin{aligned} &\text{Si on a } H_0: \theta = \theta_0 \\ &\alpha = P_{\theta_0}((X_1, \dots, X_m) \in W) \end{aligned}$$

* La puissance du test est la fonction $\beta: \textcircled{G} \rightarrow [0,1]$ telle que
 $\beta(\theta) = P_\theta((X_1, \dots, X_m) \in W)$

Le test est sans biais si

$$\forall \theta \in \textcircled{G}, \beta(\theta) \geq \alpha$$

Si on a $H_1: \theta = \theta_1$,

$$\beta = P_{\theta_1}((X_1, \dots, X_m) \in W)$$

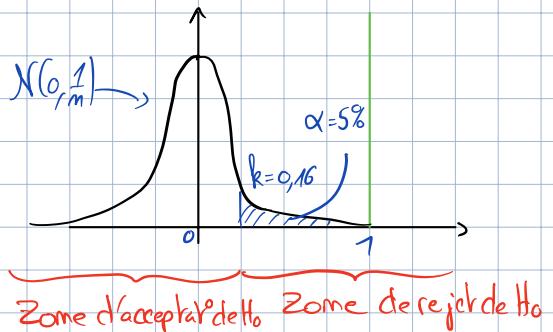
(spécificité du test).

Exemple: On repart l'exemple où X_1, \dots, X_m i.i.d t.q. $X_i \sim N(\mu, 1)$. Application numérique, on a $m=100$ et $\bar{x}_m = 0,28$.

On veut choisir autre $H_0: \mu=0$ et $H_1: \mu=1$.

Idee: On estime μ par \bar{X}_m et on rejette H_0 si: \bar{X}_m s'éloigne trop de 0 (vers 1) ou \Leftrightarrow on rejette H_0 si: $\bar{X}_m > k$ à déterminer

Sous H_0 (i.e. $\mu=0$), $\bar{X}_m \sim N(0, 1/m)$



$$\begin{aligned} \text{On a } \alpha &= P(\text{rejeter } H_0 \mid H_0 \text{ est vraie}) = 5\% = 0,05 \\ &= P(\bar{X}_m > k \mid \bar{X}_m \sim N(0, \frac{1}{m})) = P(N(0, \frac{1}{m}) > k) = \alpha \end{aligned}$$

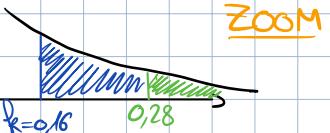
$$\alpha = P_0(\sqrt{m} \bar{X}_m > \sqrt{m} k) \underbrace{\sim N(0, 1)}_{Z_{1-\alpha} \text{ quantile d'ordre } 1-\alpha \text{ d'une } N(0, 1)}$$

Si on prend $\alpha = 0,05$, $Z_{0,95} = 1,6$, $m=100 \rightarrow k \approx 0,16$.

On a observé 0,28, $0,28 > 0,16 \Rightarrow$ on rejette H_0 .

Quelle est la valeur minimale de α pour qu'on accepte H_0 alors qu'on a observé 0,28?

Le plus petit α tq on accepte H_0
en observant 0,28 = p.value
 $P(\bar{X}_m \geq 0,28 \mid H_0)$
 $= P(N(0, \frac{1}{m}) \geq 0,28)$



Réponse: Le plus petit α tq on accepte H_0 si on observe 0,28 est $P(N(0, \frac{1}{m}) \geq 0,28) = P(N(0, 1) \geq \sqrt{m} \cdot 0,28)$
 $= P(N(0, 1) \geq 2,8) = 0,0026$
 $m=100$
 $= p.\text{value}$.

\Rightarrow On accepte H_0 si la p.value est supérieure à α et on rejette si elle est inférieure à α .

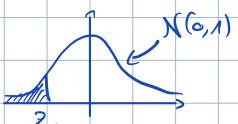
Remarque: Les hypothèses ne sont pas symétriques:

Puisque H_0 est l'hypothèse privilégiée et H_1 n'intervient pas dans la construction.

Si on inverse les hypothèses : $H_0: \mu=1$ contre $H_1: \mu=0$

On rejette H_0 quand $\bar{X}_m < k$ i.e. on cherche k tq $P(\bar{X}_m < k \mid \mu=1) = \alpha$

$$\Rightarrow P(\underbrace{\sqrt{m}(\bar{X}_m - 1)}_{\sim N(0, 1)} < \underbrace{\sqrt{m}(k-1)}_{Z_\alpha} \mid \mu=1) = \alpha$$



Si $\alpha = 5\%$, $m=100$, on a $10(k-1) = -1,6$
 $\Rightarrow \underline{k = 0,84}$

\Rightarrow On rejette H_0 si $\bar{x}_m < 0,84$
Comme on a observé $\bar{x} = 0,28$, on rejette H_0

© Théo Jalabert

Conclusion : Si $\bar{x}_m = 0,28$

Il faut faire attention à commencer à choisir les hypothèses

$$\left\{ \begin{array}{l} H_0: \mu = 0 \text{ et } H_1: \mu = 1 \Rightarrow \text{on rejette } H_0 \\ H_0: \mu = 1 \text{ et } H_1: \mu = 0 \Rightarrow \text{on rejette } H_0 \end{array} \right.$$

II - Tests uniformément plus puissants.

Définition: Chant donnée deux tests ϕ_1 et ϕ_2 de niveau $<\alpha$ pour tester

$$H_0: \theta \in \Theta_0 \text{ contre } H_1: \theta \in \Theta_1.$$

Le test ϕ_1 est uniformément plus puissant que ϕ_2 ssi

$$\forall \theta \in \Theta_1, \beta_1(\theta) \geq \beta_2(\theta)$$

Dans le cas où $H_0: \theta = \theta_0$ et $H_1: \theta = \theta_1$, on dit que ϕ_1 est plus puissant que ϕ_2 si $\beta_1 \geq \beta_2$

On prend les hypothèses $H_0: \theta = \theta_0$ contre $H_1: \theta = \theta_1$.

Soit $L(x_1, \dots, x_m, \theta)$ la fonction de vraisemblance.

Définition: On considère $H_0: \theta = \theta_0$ contre $H_1: \theta = \theta_1$,

Soit $V_{\theta_0, \theta_1} = \frac{L(x_1, \dots, x_m, \theta_1)}{L(x_1, \dots, x_m, \theta_0)}$ le rapport de vraisemblance.

On considère la famille du test ϕ_α de région de rejet $V_{\theta_0, \theta_1} > k_\alpha$

On appelle ces tests des tests de Neyman-Pearson

Remarque: $L(x_1, \dots, x_m, \theta)$ est le "degré de vraisemblance" de θ sachant qu'on a observé x_1, \dots, x_m
i.e. \approx la proba d'observer x_1, \dots, x_m sous l'hypothèse θ .

Dans un test de NP, on rejette H_0 si θ_1 devient plus vraisemblable que θ_0 .

Exemple: X_1, \dots, X_m iid tq $X_i \sim N(\mu, 1)$, on veut $H_0: \mu = 0$ contre $H_1: \mu = 1$

On veut construire un test de Neyman-Pearson

$$L(x_1, \dots, x_m, \mu) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x_i - \mu)^2\right)$$

$$\Rightarrow L(x_1, \dots, x_m) = (2\pi)^{-m/2} \exp\left(-\frac{1}{2} \sum_{i=1}^m (x_i - \mu)^2\right)$$

$$\begin{aligned} V_{0,1} &= \frac{L(x_1, \dots, x_m, 1)}{L(x_1, \dots, x_m, 0)} = \frac{(2\pi)^{-m/2} \exp\left(-\frac{1}{2} \sum_{i=1}^m (x_i - 1)^2\right)}{(2\pi)^{-m/2} \exp\left(-\frac{1}{2} \sum_{i=1}^m x_i^2\right)} \\ &= \exp\left(-\frac{1}{2} \sum_{i=1}^m (x_i^2 - 2x_i + 1) + \frac{1}{2} \sum_{i=1}^m x_i^2\right) \\ &= \exp\left(\sum_{i=1}^m x_i - \frac{m}{2}\right) \end{aligned}$$

On rejette H_0 si $\exp\left(\sum_{i=1}^m x_i - \frac{m}{2}\right) > k_\alpha$

On détermine k_α tel que

$$P\left(\exp\left(\sum_{i=1}^m x_i - \frac{m}{2}\right) > k_\alpha \mid H_0\right) = \alpha$$

$x_i \sim N(0, 1)$

Donc on cherche k_α tq :

$$P_0\left(\exp\left(\sum_{i=1}^m x_i - \frac{m}{2}\right) > k_\alpha\right) = \alpha \quad \text{avec } x_i \sim N(0, 1)$$

$$\Leftrightarrow P_0\left(\sum_{i=1}^m x_i > \ln(k_\alpha) + \frac{m}{2}\right) = \alpha$$

$$\Leftrightarrow P_0\left(\underbrace{\sqrt{m} \bar{x}_m}_{\sim N(0, 1)} > \underbrace{\frac{\ln(k_\alpha)}{\sqrt{m}} + \frac{\sqrt{m}}{2}}_{Z_{1-\alpha}}\right) = \alpha$$

$$\Rightarrow \text{On rejette } H_0 \text{ si } \sqrt{m} \bar{x}_m > Z_{1-\alpha} \quad \text{où } \bar{x}_m = \frac{Z_{1-\alpha}}{\sqrt{m}}$$

On retrouve sur le régime de rejeter qu'on avait trouver avant.

Théorème **Neyman - Pearson**

* Soit $\alpha > 0$ et Φ_k un test de Neyman - Pearson de niveau α alors il est plus puissant que tout autre test de niveau $\leq \alpha$ et en plus il est sans biais.
 ↳ C'est le meilleur.

* Si $\alpha \in [0, 1]$, si les lois P_θ sont absolument continues, il existe $k_\alpha \in \mathbb{R}$ tq Φ_{k_α} est de niveau α .

Si les lois sont discrètes alors il existe un plus petit k_α tq Φ_{k_α} est de niveau $\leq \alpha$.

* Soit Φ un test plus puissant de niveau α alors $\forall \theta \in \{\theta_0, \theta_1\}$,

$$P_\theta(\Phi(X) \neq \Phi_{k_\alpha}(X)) \neq k_\alpha \quad \text{et} \quad V(X) \neq k_\alpha = 0.$$

Rappel: On veut choisir entre deux hypothèses

J. Galbraith

$H_0: \theta \in \Theta_0$ contre $H_1: \theta \in \Theta_1$

Definition: Ch test est une fonction $\phi: \mathbb{R}^m \rightarrow \{0,1\}$

(Si $\phi(x_m, \dots, x_m) = 1$, on rejette H_0 et inversement)

$$W = \text{région de rejet} = \{(x_1, \dots, x_m) \in \mathbb{R}^m \mid g(x_1, \dots, x_m) = 1\}$$

Si on veut tester $H_0: \theta \in \Theta_0$ contre $H_1: \theta \in \Theta_1$

\Rightarrow Test de Neyman-Pearson (n'est plus puissant dans ce cas)

$$\text{On calcule } V_{\theta_1, \theta_0} = \frac{L(x_1, -, x_0, \theta_1)}{L(x_1, -, x_0, \theta_0)}$$

On rejette H_0 si $V_{\theta_0, \theta_1} > V_{\theta_0, \theta_1} \geq k_\alpha$ et k_α est déterminé par le fait que

$$P_{H_0} (V_{\theta_0, \theta_1} \geq k_\alpha) = \alpha$$

Sous l'hypothèse H_0 Rejet de H_0 ↑ Risque de 1^{er} espèce

On a déduit k_α proba de rejeter H_0 alors que H_0 est vraie

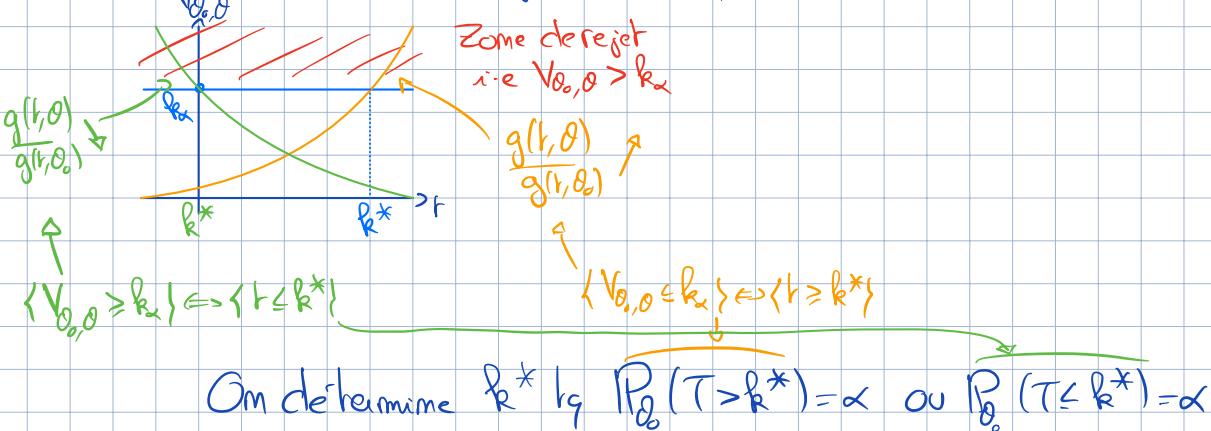
Si on veut tester $H_0: \theta = \theta_0$ contre $H_1: \theta > \theta_0$ (ou $H_1: \theta < \theta_0$)

Idee: On fait Neyman - Pearson avec $H_0: \theta = \theta_0$ et $H_1: \theta = \theta_1 > \theta_0$

Si on a une stat exhaustive T_m de vraisemblance g.

$$\nabla_{\theta_0, \theta} = \frac{L(x_1, \dots, x_n, \theta)}{L(x_1, \dots, x_n, \theta_0)} = \frac{g(b, \theta)}{g(b, \theta_0)} \text{ monotone en } b.$$

alors on rejette H_0 si $\{T_n \geq k\}$ si croissante et $\{T_n \leq k\}$ si décroissante



Exemple: X_1, \dots, X_m iid tq $X_i \sim N(\mu, 1)$

On veut tester $H_0: \mu = 0$ contre $H_1: \mu > 0$

$$L(x_1, \dots, x_m, \mu) = (2\pi)^{-\frac{m}{2}} \exp\left[-\frac{1}{2} \sum_{i=1}^m (x_i^2 - 2x_i\mu + \mu^2)\right]$$

$$\mathbb{V}_{0,\mu} = \exp\left[-\frac{1}{2} \sum_{i=1}^m (2x_i\mu - \mu^2)\right] = \exp\left[\mu \sum x_i - \frac{m\mu^2}{2}\right].$$

On sait que \bar{X}_m est une stat exhaustive.

$$\text{Si on pose } t = \frac{1}{m} \sum_{i=1}^m x_i$$

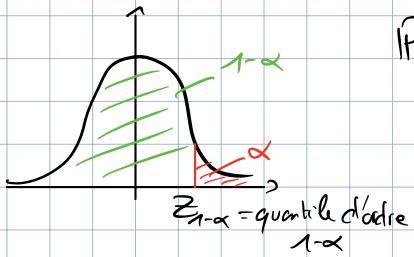
$$\mathbb{V}_{0,\mu} = \exp\left[m\mu t - \frac{m\mu^2}{2}\right] \text{ fonction croissante de } t.$$

On rejette si $t > k$ avec P tq $P_0(\bar{X}_m > k) = \alpha$

Sous H_0 , $\bar{X}_m \sim N(0, \frac{1}{m})$ donc $\sqrt{m}\bar{X}_m \sim N(0, 1)$

$$\text{Fk tq } P_0(\bar{X}_m > k) = \alpha \iff P_0(\sqrt{m}\bar{X}_m > \sqrt{m}k) = \alpha.$$

Si $Z \sim N(0, 1)$



$$P(Z > Z_{1-\alpha}) = 1-\alpha \Rightarrow P_0(\sqrt{m}\bar{X}_m > Z_{1-\alpha}) = 1-\alpha$$

$$=\sqrt{m}k$$

Réponse: On retombe sur la même région de rejet que pour test $H_0: \mu = 0$ contre $H_1: \mu = 1$ (ou n'importe quoi > 0)

La région de rejeter c'est $\{\sqrt{m}\bar{X}_m \geq Z_{1-\alpha}\}$

Application numérique: On a 100 observations qui viennent d'une loi $N(\mu, 1)$.

On a observé $\bar{x}_m = 0,196$ et on veut tester $H_0: \mu = 0$ contre $H_1: \mu > 0$ de niveau $\alpha = 5\%$

On calcule la statistique du test ($\sqrt{m}\bar{X}_m$), $\sqrt{m}\bar{x}_m = 1,96$.

Si on a $\alpha = 5\%$, alors $Z_{1-\alpha} = Z_{0,95} \approx 1,6$.

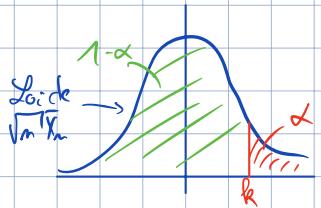
Ici, $\sqrt{m}\bar{x}_m = 1,96 \geq 1,6 = Z_{1-\alpha} = Z_{0,95}$ On rejette H_0 de niveau $\alpha = 5\%$

A quel niveau de α est-ce qu'on aurait accepté le test?

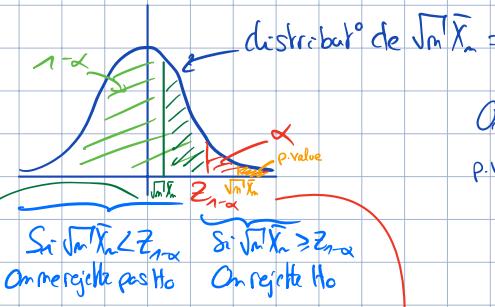
$\Rightarrow p\text{-Value}$

On cherche le plus petit α tq $\sqrt{m}\bar{x}_m = Z_{1-\alpha}$ équivaut à calculer $P(\sqrt{m}\bar{X}_m > \underline{\sqrt{m}\bar{X}_m})$

statistique valeur qu'on observe



Si $\sqrt{m} \bar{X}_m < z_{1-\alpha}$
On accepte H_0 et
p.value < α .



On veut calculer la proba.
p.value = $P(\sqrt{m} \bar{X}_m > \sqrt{m} \bar{x})$

$$\text{Si } \sqrt{m} \bar{X}_m > z_{1-\alpha} \Rightarrow \text{p.value} < \alpha$$

Ici, on a $\sqrt{m} \bar{X}_m = 1.96$.

$$\text{p.value} = P(\sqrt{m} \bar{X}_m \geq 1.96) = 0.025$$

→ p.value = plus petit α tq on accepterait H_0 i.e on aurait accepté H_0 au niveau $\alpha = 2.5\%$

⇒ La p.value permet de contrôler la décision qu'on prend.

Si p.value très grande ⇒ on accepte H_0

très petit ⇒ on rejette H_0

pas trop loin de $\alpha = 5\%$ ⇒ on réfléchit.

III - Tests fondés sur le rapport du maximum de vraisemblance.

On appelle test du rapport du max de vraisemblance tout test de région de rejet

$$W = \left\{ x \in \mathbb{R}^m \mid \frac{\sup_{\theta \in \Theta_1} L(x_1, \dots, x_m, \theta)}{\sup_{\theta \in \Theta_0} L(x_1, \dots, x_m, \theta)} > k_\alpha \right\}$$

pour tester $H_0: \theta \in \Theta_0$ contre $H_1: \theta \in \Theta_1$ avec k_α tq $\sup_{\theta \in \Theta_0} P_\theta(W) = k_\alpha$

Dans le cas où $\Theta_1 = \Theta_0^c$, $W = \left\{ (x_1, \dots, x_m) \in \mathbb{R}^m \mid q \frac{\sup_{\theta \in \Theta_0} L(x_1, \dots, x_m, \theta)}{\sup_{\theta \in \Theta_0^c} L(x_1, \dots, x_m, \theta)} > k_\alpha \right\}$

Résumé:

$H_0: \theta = \theta_0$ contre $H_1: \theta = \theta_1 \Rightarrow$ Neyman-Pearson = test plus puissant

$H_0: \theta = \theta_0$ contre $H_1: \theta > \theta_0 \Rightarrow V_{\theta_0, \theta} + T$ exhaustive = test unif plus puissant.

$H_0: \theta \in \Theta_0$ contre $H_1: \theta \in \Theta_1 \Rightarrow$ Test rapport max vraisemblance = pas de propriété

Exemple: X_1, \dots, X_m iid tq $X_i \sim N(\mu, \sigma^2)$

On veut tester $H_0: \mu = \mu_0$

$\otimes H_1: \mu = \mu_1 \Rightarrow$ déjà fait

$\textcircled{1} \quad H_1: \mu > \mu_0 \Rightarrow$ déjà fait si σ^2 connue

© Théo Jalabert

Si σ^2 inconnue, on a toujours $\sqrt{n}(\bar{X}_m - \mu_0) \xrightarrow{\text{D}} N(0, \sigma^2)$
 \Rightarrow on rejette si $\bar{X}_m > k_\alpha$ avec $P_{\mu_0}(\bar{X}_m > k_\alpha) = \alpha$.

Sous H_0 , $\bar{X}_m \sim N(\mu_0, \frac{\sigma^2}{n})$.

On a:

$$\sqrt{n} \frac{\bar{X}_m - \mu_0}{\sigma} \sim N(0, 1).$$

inconnue.

On remplace σ^2 par $S_m^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_m)^2$

Parce que ce sont des $X_i \sim \text{Normale}$

On sait que $\sigma^{-2} \sum_{i=1}^n (X_i - \bar{X}_m)^2 \sim \chi^2_{n-1}$

et \bar{X}_m est indépendant de $\sum_{i=1}^n (X_i - \bar{X}_m)^2$

Rappel: Si:

$$\textcircled{2} \quad Z \sim N(0, 1)$$

$$\textcircled{3} \quad W \sim \chi^2_a$$

$$\textcircled{4} \quad Z \perp W$$

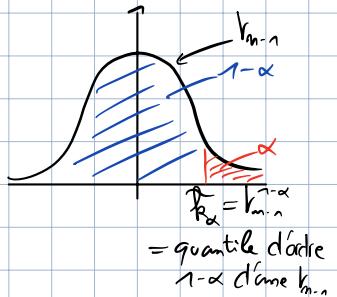
$$\Rightarrow \frac{Z}{\sqrt{W/a}} \sim t_a$$

$$\begin{aligned} \sqrt{n} \frac{\bar{X}_m - \mu_0}{\sigma} &\sim N(0, 1) \\ \sqrt{n} \frac{\bar{X}_m - \mu_0}{\sqrt{S_m^2}} &\sim t_{n-1} \Rightarrow \sqrt{n} \frac{\bar{X}_m - \mu_0}{\sqrt{S_m^2}} \sim t_{n-1} \\ \sqrt{n} \frac{\bar{X}_m - \mu_0}{\sqrt{S_m^2}} &\sim \chi^2_{n-1} \end{aligned}$$

A la base, on cherche k_α tq $P_{\mu_0}(\bar{X}_m > k_\alpha) = \alpha$ équivaut à chercher

$$P_{\mu_0}\left(\sqrt{n} \frac{\bar{X}_m - \mu_0}{\sqrt{S_m^2}} > k_\alpha\right) = \alpha \Rightarrow T_{k_\alpha} = k_{n-1}^{1-\alpha}$$

Si $T \sim t_{n-1}$,



On rejette donc H_0 si

$$\sqrt{n} \frac{\bar{X}_m - \mu_0}{\sqrt{S_m^2}} > k_{n-1}^{1-\alpha}$$

$\textcircled{2} \quad$ On veut tester $H_0: \mu = \mu_0$ contre $H_1: \mu \neq \mu_0$ (test bilatéral)

On ne peut pas faire un test unilatéral plus puissant mais on peut quand même en faire un basé sur le rapport du max de vraisemblance.

Ici, $\textcircled{1} = \{(\mu, \sigma^2) \text{ avec } \mu \in \mathbb{R} \text{ et } \sigma^2 > 0\}$ ← on a (μ, σ^2) paramètres

$\textcircled{2}_0 = \{(\mu_0, \sigma^2) \text{ avec } \sigma^2 > 0\}$ ← que σ^2 paramètre

$\textcircled{2}_1 = \{(\mu, \sigma^2) \text{ avec } \mu \in \mathbb{R} / \{\mu_0, \sigma^2 > 0\}$

On a $\textcircled{2}_1 = \textcircled{2}_0^c$. Le test va être basé sur la zone de rejet

$$W = \left\{ (x_1, \dots, x_m) \in \mathbb{R}^m \mid \begin{array}{l} \sup_{(\mu, \sigma^2) \in \Theta} L(x_1, \dots, x_m, \mu, \sigma^2) \\ \sup_{\sigma^2 \in Q} L(x_1, \dots, x_m, \mu_0, \sigma^2) \end{array} \geq k \right\} = L(x_1, \dots, x_m, \mu_0, \hat{\sigma}^2)$$

Si l'EMV sur Θ est $(\hat{\mu}, \hat{\sigma}^2)$ et l'EMV sur Θ_0 est $\hat{\sigma}^2$

On a déjà vu que $\hat{\mu}_m = \bar{x}_m$ et $\hat{\sigma}_m^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x}_m)^2$ (on estime par MV (μ, σ^2) d'une $X(\mu, \sigma^2)$)

$$\hat{\sigma}_0^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_0)^2 \quad \begin{array}{l} \text{(on estime par MV } \sigma^2 \\ \text{quand } \mu_0 \text{ est connue} \end{array}$$

On sait aussi que $L(x_1, \dots, x_m, \mu, \sigma^2) = (2\pi)^{-m/2} (\sigma^2)^{-m/2} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^m (x_i - \mu)^2\right]$.

$$\begin{aligned} \lambda(x_1, \dots, x_m) &= \frac{\sup_{\Theta} L(x_1, \dots, x_m, \mu, \sigma^2)}{\sup_{\Theta_0} L(x_1, \dots, x_m, \mu_0, \sigma^2)} = \frac{L(x_1, \dots, x_m, \hat{\mu}_m, \hat{\sigma}_m^2)}{L(x_1, \dots, x_m, \mu_0, \hat{\sigma}_0^2)} \\ &= \frac{(2\pi)^{-m/2} (\hat{\sigma}_m^2)^{-m/2} \exp\left[-\frac{1}{2\hat{\sigma}_m^2} \sum_{i=1}^m (x_i - \bar{x}_m)^2\right]}{(2\pi)^{-m/2} (\hat{\sigma}_0^2)^{-m/2} \exp\left[-\frac{1}{2\hat{\sigma}_0^2} \sum_{i=1}^m (x_i - \mu_0)^2\right]} \\ &= \exp\left[-\frac{1}{2} \left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}_m^2} \right)^{\frac{m}{2}} \right] \end{aligned}$$

$$\begin{aligned} \hat{\sigma}_0^2 &= \frac{1}{m} \sum_{i=1}^m (x_i - \mu_0)^2 \\ &= \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x}_m + \bar{x}_m - \mu_0)^2 \\ &= \underbrace{\frac{1}{m} \sum_{i=1}^m (x_i - \bar{x}_m)^2}_{\hat{\sigma}_m^2} + (\bar{x}_m - \mu_0)^2 \end{aligned}$$

$$\text{Si on pose } k_m = \frac{\bar{x}_m - \mu_0}{\sqrt{\hat{\sigma}_m^2}}$$

On a $\lambda(x_1, \dots, x_m)$ est une fonction croissante en $|k_m|$

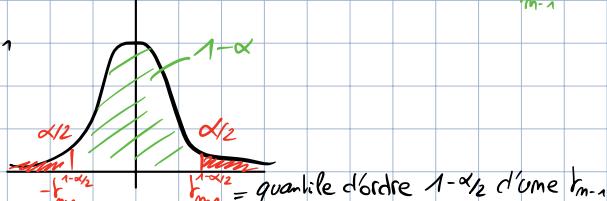
$$\{|\lambda(x_1, \dots, x_m)| > k_\alpha\} \text{ équivaut à } \{|k_m| > \tilde{k}_\alpha\}$$

Sous $H_0 (\mu = \mu_0)$, $T_m = \frac{\bar{x}_m - \mu_0}{\sqrt{\hat{\sigma}_m^2}} \sim k_{m-1} \approx \sqrt{\chi_{m-1}^2}$

Car $T_m = \frac{\sqrt{m} \frac{\bar{x}_m - \mu_0}{\sigma}}{\sqrt{\frac{\sigma^2}{m(m-1)} \sum_{i=1}^m (x_i - \bar{x})^2}} \sim \chi_{m-1}^2$

On cherche \tilde{k}_α tq sous H_0 , $P_{\mu_0}(|T_m| > \tilde{k}_\alpha) = \alpha$

Si $T \sim k_{m-1}$,



On rejette donc H_0 si $|\sqrt{m-1} \frac{\bar{x} - \mu_0}{\sqrt{\hat{\sigma}_m^2}}| > k_{m-1}^{1-\alpha/2}$

$$\begin{aligned} \text{On calcule la p.value comme } & P_{\mu_0} \left(|\sqrt{m-1} \frac{\bar{X}_m - \mu_0}{\sqrt{\hat{\sigma}_m^2}}| > |\sqrt{m-1} \frac{\bar{X}_m - \mu_0}{\sqrt{\hat{\sigma}_m^2}}| \right) \\ & = P_{\mu_0} (|k_{m-1}| \geq |\sqrt{m-1} \frac{\bar{X}_m - \mu_0}{\sqrt{\hat{\sigma}_m^2}}|) \end{aligned}$$

Exemple: Comparaison de moyenne.

On a deux échantillons (X_1, \dots, X_{m_x}) et (Y_1, \dots, Y_{m_y}) indép entre eux tq

$$X_i \sim N(\mu_x, \sigma^2) \text{ et } Y_i \sim N(\mu_y, \sigma^2)$$

On veut tester $H_0: \mu_x = \mu_y$ contre $H_1: \mu_x \neq \mu_y$

On a $\mathcal{Q} = \{(\mu_x, \mu_y, \sigma^2) \text{ avec } \mu_x \in \mathbb{R}, \mu_y \in \mathbb{R} \text{ et } \sigma^2 > 0\}$

L'estimateur du max de vraisemblance (sur \mathcal{Q}) est $\hat{\mu}_x = \bar{X}_m = \frac{1}{m_x} \sum_{i=1}^{m_x} X_i$, $\hat{\mu}_y = \bar{Y}_m = \frac{1}{m_y} \sum_{i=1}^{m_y} Y_i$ et $\hat{\delta} = \frac{1}{m} \left(\sum_{i=1}^{m_x} (X_i - \bar{X})^2 + \sum_{i=1}^{m_y} (Y_i - \bar{Y})^2 \right)$ avec $m = m_x + m_y$

On a $\mathcal{Q}_0 = \{(\mu, \sigma^2), \mu \in \mathbb{R} \text{ et } \sigma^2 > 0\}$

L'EMV sur \mathcal{Q}_0 est $\hat{\mu}_0 = \frac{1}{m} \left(\sum_{i=1}^{m_x} X_i + \sum_{i=1}^{m_y} Y_i \right)$ et $\hat{\delta}_0 = \frac{1}{m} \left(\sum_{i=1}^{m_x} (X_i - \hat{\mu}_0)^2 + \sum_{i=1}^{m_y} (Y_i - \hat{\mu}_0)^2 \right)$

La vraisemblance vaut $L(x_1, \dots, x_{m_x}, y_1, \dots, y_{m_y}, \mu_x, \mu_y, \sigma^2) = (2\pi)^{-m/2} (\sigma^2)^{-m/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^{m_x} (x_i - \mu_x)^2 \right] \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^{m_y} (y_i - \mu_y)^2 \right]$

$$\lambda(x_1, \dots, y_{m_y}) = \frac{\sup_{\mathcal{Q}} L(x_1, \dots, y_{m_y}, \mu_x, \mu_y, \sigma^2)}{\sup_{\mathcal{Q}_0} L(x_1, \dots, y_{m_y}, \mu, \sigma^2)} = \left(\frac{\hat{\delta}_0}{\hat{\delta}_m} \right)^{\frac{m}{2}}$$

$$\text{On pose } T_m = \sqrt{\frac{m_x m_y}{m}} \frac{\bar{X}_m - \bar{Y}_m}{\sqrt{\frac{1}{m_x} \hat{\delta}_m}}$$

On a $T_m \sim t_{m-2}$, on mq $\lambda(x_1, \dots, y_{m_y})$ est une fonction croissante en $|k_m|$

\Rightarrow On rejette si $|k_m| > k_{m-2}^{1-\alpha/2}$ ← quantile d'ordre $1-\alpha/2$ d'une t_{m-2} .

Ref à l'examen