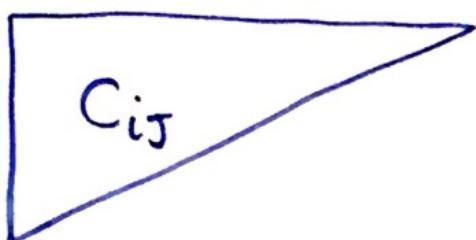


Les x_{ij} sont les réalisations de v.a. X_{ij} (observées au 31/12/m)

MODÈLE DE MACK



Remarque: pour la méthode de Mack, afin de suivre les modifications du papier, on a

$$i = 1, \dots, m$$

$$j = 1, \dots, m$$

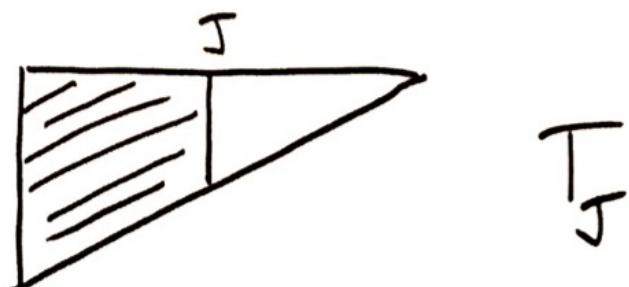
(pas 0 comme pour les méthodes déterministes)

H1) Cette hypothèse pourrait être fausse à mal en cas de changements importants dans la gestion des sinistres ou dans le taux d'inflation puisque ces

changement vont affecter,
par effet calendaire, plusieurs
années d'origine.

Je faudrait travailler avec des
données "as if" - Le montant
"AS IF" d'un sinistre est le
côté de celui-ci s'il surviennent
avec les mêmes caractéristiques
mais dans l'environnement
présent à la date de l'étude.

Mack a montré que sous les hypothèses H1 et H2, le modèle stochastique
donne exactement les mêmes
provisions que la méthode CL
standard.



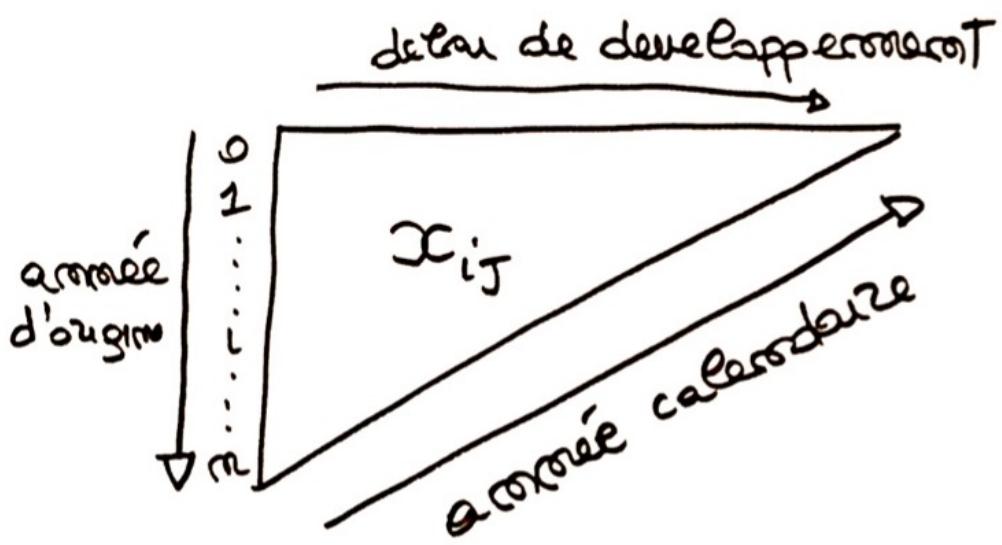
T_J

$$\hat{R}_i = \hat{C}_{im} - C_{i,m-i+1} \quad i=2, \dots, m \quad (3)$$

MSE : MEAN SQUARE ERROR

(EQM : erreur quadratique moyenne)

$$E(C_{i,j+1} | C_{i,1}, \dots, C_{i,j}) = f_j C_{ij}$$



$$\mu_{ij} = \underbrace{\mu + \alpha_1 \frac{1^\alpha}{1}}_{E(x_{ij})} + \dots + \alpha_i \frac{1^\alpha}{i} + \dots + \alpha_m \frac{1^\alpha}{m} + \underbrace{\beta_1 \frac{1^\beta}{1}}_{\Delta=0} + \dots + \beta_j \frac{1^\beta}{j} + \dots + \beta_m \frac{1^\beta}{m} \quad \Delta=1$$

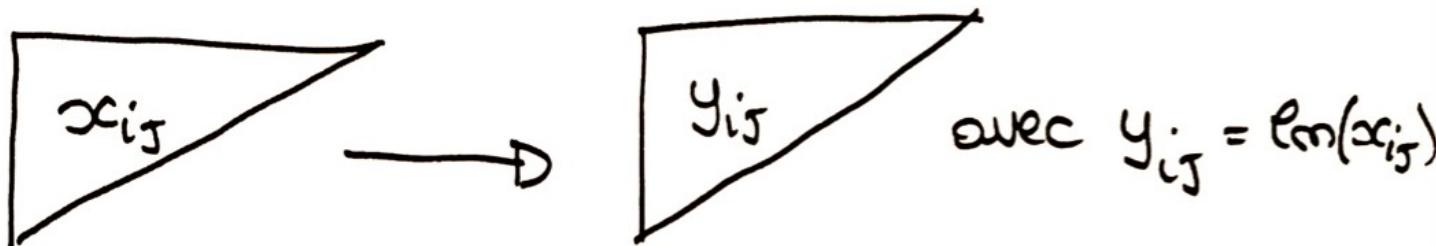
BEST ESTIMATE

$$\hat{E}(R) = \sum_i \sum_{i+j > m} \hat{E}(x_{ij})$$

Rappel: $X \sim LN(\mu, \sigma^2)$

si $Y = \ln(X) \sim N(\mu, \sigma^2)$

REGRESSION LOGNORMALE



→ on estime un modèle de régression

$$y_{ij} = \mu + d_i + \beta_j + \varepsilon_{ij}$$

avec $\varepsilon_{ij} \sim N(0, \sigma^2)$

$$\rightarrow \hat{\mu}, \hat{d}_i, \hat{\beta}_j \rightarrow \widehat{E}(x_{ij})$$

$$\rightarrow \widehat{E}(R) = \sum \sum \widehat{E}(x_{ij})$$

$$Y = M\theta + \varepsilon$$

avec $Y' = (y_0, y_1, \dots, y_m, y_{10}, \dots, y_{1,m-1}, \dots, y_m)$

le vecteur d'ordre $t = \frac{(m+1)(m+2)}{2}$

des éléments du Tracé

pas ligne à ligne.

$1^1_1 \quad 1^1_2 \dots 1^1_1 \dots 1^1_m$

$$M = t \times (2m+1) \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} \begin{matrix} m+1 \\ \text{fois} \\ \\ m \text{ fois} \end{matrix} \quad \left(\text{correlation de regression} \right)$$

$$\Theta = (\mu, \alpha_1, \dots, \alpha_m, \beta_1, \dots, \beta_m)$$

↳ vecteur d'ordre $p = 2m+1$ des paramètres à estimer

$$\varepsilon' = (\varepsilon_{00}, \varepsilon_{01}, \dots, \varepsilon_{m0})$$

↳ vecteur des erreurs

$$\text{d'ordre } t = \frac{(m+1)(m+2)}{2}$$

Du coup, on peut recuperer les résultats de la théorie sur les modèles de régression et écrire par exemple que

$$\hat{\Theta} = (M'M)^{-1} M'Y$$

la EMV de Θ

et aussi

$$S^2 = \frac{1}{t-p} \sum_{i=1}^t \hat{\epsilon}_i^2$$

↳ estimation sans biais de σ^2
(variance de l'erreur)

θ_{ij} : PARAMETRE réel appelé
PARAMETRE CANONIQUE

ϕ : paramètre de DISPERSION

η_{ij} : SCORE ou PREDICTEUR LINEAIRE

$$g(E(X_{ij})) = \mu + \alpha_i + \beta_j$$

Souvent une preuve connue fonction
avec la loi log -

$$V(\mu_{ij}) = b''(\theta_{ij}) \quad \text{FONCTION VARIANCE}$$

↳ dérivée d'ordre 2
de b par rapport à θ_{ij}

LOI PREDICTIVE : loi de la V.Q. R

(provision globale)

La $\text{VaR}_\eta(R)$ peut être interprétée comme la provision suffisante dans $100(1-\eta)\%$ des cas.

1) Si la loi des X_{ij} est additive (par exemple Poisson ou Gaussienne) alors la loi de R s'obtient par convolution directe.

Φ : f.d.r. d'une loi $N(0, 1)$

Une fois que l'on a estimé μ_{ij} et μ_R par MV, on obtient, par plug-in, l'estimateur du MV du quantile:

$$\hat{q}_{1-\eta}^{(p)}(R) = \hat{\mu}_R + \sqrt{\hat{\mu}_R} q_{1-\eta}$$

FFT: fast Fourier Transform

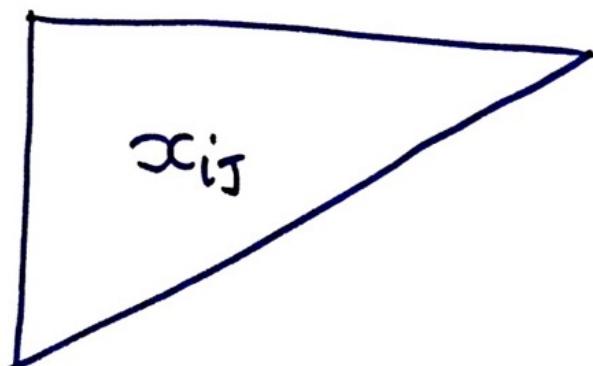
$$\gamma_1 = \frac{\mu_3}{\sigma^3}$$

COEFFICIENT D'ASYMETRIE

avec μ_3 le moment centré d'ordre 3.

L'approximation NP est censée approcher l'approximation gaussienne en prenant en compte γ_1 . Elle est assez précise tant que $0 \leq \gamma_1 \leq 2$; la qualité est de moins en moins bonne à mesure que γ_1 augmente.

Encore une fois, on peut obtenir une estimation par "plug-in" du quantile $q_{1-\eta}^{(NP)}$ (estimation du MV).



X_{ij}

$$\begin{array}{ccc}
 x_{ij} & \xrightarrow{\text{GLM}} & \hat{\mu}_{ij} = g^{-1}(\hat{\mu} + \hat{\alpha}_i + \hat{\beta}_j) \\
 & g(E(x_{ij})) = \mu + \alpha_i + \beta_j & \\
 & \mu_{ij} & \text{valeurs ajustées par le modèle}
 \end{array}$$

résidus de Pearson

$$\tau_{ij}^P = \frac{x_{ij} - \hat{\mu}_{ij}}{\sqrt{V(\hat{\mu}_{ij})}}$$

avec V la fm variance $V(\mu_{ij}) = b''(\theta_{ij})$

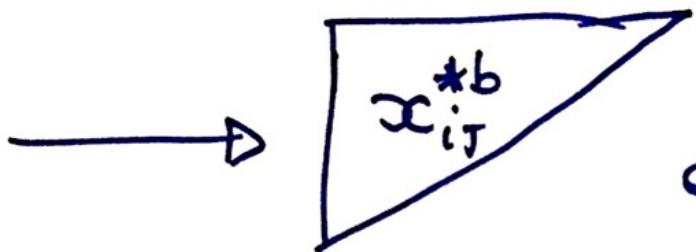
$$\hat{\phi} = \frac{1}{t-p} \sum_{i+j \leq m} (\tau_{ij}^P)^2$$

mb de données (Triangle supérieur)

$$\frac{(m+1)(m+2)}{2}$$

mb de paramètres inconnus
 $2m+1$





avec

$$x_{ij}^{*b} = \hat{\mu}_{ij} + \varepsilon_{ij}^{*b} \sqrt{V(\hat{\mu}_{ij})}$$

GLM



$$\hat{R}^{*b} = \sum_{i+j>m} \mu_{ij}^{*b}$$

$$\hookrightarrow g^{-1}(\hat{\mu} + \hat{\lambda}_i + \hat{\beta}_j)$$

Au final on se retrouve avec un échantillon de Table B d'estimations de la provision globale

$$(\hat{R}^{*1}, \dots, \hat{R}^{*B})$$

ce qui permet d'obtenir les quantités du slide 53.

On rappelle que

$$R = \sum_{i+j>m} X_{ij}$$

$$\text{Var}(R) = \sum_{i+j>m} \text{Var}(X_{ij}) = \phi \underbrace{\sum_{i+j>m} V(\mu_{ij})}_{\hookrightarrow \phi V(\mu_{ij})}$$

Sep: standard error of prediction

La quantité qui va permettre de comparer des modèles est le coefficient de variation :

$$CV(\hat{R}) = \frac{\sqrt{EQMPC(\hat{R})}}{\hat{E}(R)}$$

avec EQMPC : erreur quadratique moyenne de prediction conditionnelle

N.B. De manière générale, le modèle log Gamma (ou Gamma pour les X_{ij} et fonction \ln ou \log) donne des distributions à queue plus épaisse que le modèle log Poisson sundispercé

Remarque : pour la loi de Poisson, $\phi = 1$
et $V(\mu_{ij}) = \mu_{ij}$