

## Chapitre 3: le modèle collectif

### I - Définition

Modèle collectif: montant agrégé des indemnisations à la malle portefeuille ou groupe homogène des contrats...

. le nombre de sinistres sur la période d'exercice est une v.a de comptage  $N$  de loi

$$\mathbb{P}_N(n) = \mathbb{P}(N=n), n=0,1,\dots$$

. les montants de sinistres  $U_1, \dots, U_N$  forment une suite iid de v.a positives de densité  $f_U$  et indépendantes de  $N$

La charge totale est donnée par:

$$X = \sum_{i=1}^N U_i$$

La fonction de répartition de  $X$  n'est pas connue explicitement

## 1/ Distribution de $X$

La mesure de probabilité de  $X$  est mixte au sens où elle admet un atome de proba en  $0$  correspondant à l'événement  $\{N=0\}$

Où a

$$dP_X(x) = p_N(0) \delta_0(x) + f_X^+(x) d\lambda(x)$$

où  $f_X^+$  est la densité de la partie absolument continue de la distribution de  $X$  donnée par

$$f_X^+(x) = \sum_{n=1}^{+\infty} p_N(n) f_0^{*\ k}(x), \quad x \geq 0$$

avec  $f_0^{*\ k}$  est le  $k$ ème produit de convolution de  $f_0$  avec elle-même. Il s'agit de la densité de  $U_1 + \dots + U_k$ .  $f_X^+$  est défaillante au sens

où

$$\int_0^\infty f_X^+(x) dx = 1 - p_N(0)$$

## Exemple 1: (Modèle géométrique - exponentiel)

© Théo Jalabert

HJ  
10

Supposons Un  $\exp(\beta)$  de densité  $f_0(x) = \frac{e^{-x/\beta}}{\beta}$ ,  $x > 0$

et  $N \sim \text{Geom}(p)$  de loi  $P_N(k) = p^k(1-p)$ ,  $k = 0, 1, \dots$

$$S_x^+(x) = \sum_{k=1}^{\infty} p^k(1-p) \frac{\frac{x}{\beta} e^{-x/\beta} x^{k-1}}{\beta^k (k-1)!}$$

$$= (1-p)e^{-x/\beta} \frac{p}{\beta} \sum_{k=1}^{\infty} \left(\frac{x}{\beta}\right)^{k-1} \frac{1}{(k-1)!}$$

$$= (1-p)e^{-x/\beta} \frac{p}{\beta} e^{\frac{x^2}{\beta}} = \frac{(1-p)p}{\beta} e^{-x\left(\frac{1-p}{\beta}\right)}$$

•

Pour tous les autres modèles  $\Rightarrow$  méthodes numériques  
pour calculer la Value at Risk

$$\text{VaR}_x(\alpha) = \inf \{x \geq 0; F_x \geq \alpha\}$$

ou la tail value at Risk

$$TVaR_x(\alpha) = \mathbb{E}[X | X > \text{VaR}_x(\alpha)]$$

ou la prime stop loss en réassurance

$$\Pi_c = \mathbb{E}[(X-c)_+] \quad \text{ou} \quad \Pi_{c,d} = \mathbb{E}[\min(X-c)_+, d]$$

Proposition 1:

1. L'espérance de  $X$  est donnée par

$$\mathbb{E}[X] = \mathbb{E}[N]\mathbb{E}[U]$$

2. La variance est donnée par

$$V(X) = \mathbb{E}[N]V(U) + \mathbb{E}[U]^2 V(N)$$

3. La fonction génératrice des moments est donnée par

$$R_X(s) = \mathbb{E}[e^{sX}] = G_N[R_U(s)], s \in \mathbb{R}$$

où  $G_N(s) = \mathbb{E}[s^N], s \in \mathbb{R}$

Preuve:

$$\begin{aligned} \textcircled{1} \quad \mathbb{E}[X] &= \mathbb{E}[\mathbb{E}[X|N]] = \mathbb{E}\left[\mathbb{E}\left[\sum_{i=1}^N U_i | N\right]\right] \\ &= \mathbb{E}\left[\sum_{i=1}^N \mathbb{E}[U_i | N]\right] \\ &= \mathbb{E}[N \mathbb{E}[U]] = \mathbb{E}[N]\mathbb{E}[U] \end{aligned}$$

$$\begin{aligned} \textcircled{2} \quad V(X) &= \mathbb{E}[V(X|N)] + V[\mathbb{E}[X|N]] \\ &= \mathbb{E}\left[V\left(\sum_{i=1}^N U_i | N\right)\right] + V\left[\mathbb{E}\left(\sum_{i=1}^N U_i | N\right)\right] \\ &= \mathbb{E}\left[\sum_{i=1}^N V(U_i | N)\right] + V\left[\sum_{i=1}^N \mathbb{E}[U_i | N]\right] \end{aligned}$$

$$= \mathbb{E}[V(U)N] + V(N\mathbb{E}[U])$$

$$= V(U)\mathbb{E}[N] + \mathbb{E}[U]^2 V[N]$$

$$\begin{aligned} \textcircled{3} \quad A_x(s) &= \mathbb{E}[e^{sX}] = \mathbb{E}\left[e^s \sum_{i=1}^N U_i\right] \\ &= \mathbb{E}\left[\prod_{i=1}^N e^{sU_i}\right] \\ &= \mathbb{E}\left[\mathbb{E}\left[\prod_{i=1}^N e^{sU_i} | N\right]\right] \\ &= \mathbb{E}\left[\prod_{i=1}^N \mathbb{E}[e^{sU_i} | N]\right] \\ &= \mathbb{E}\left[\prod_{i=1}^N A_U(s)\right] = \mathbb{E}[A_U(s)^N] = G_N(A_U(s)) \end{aligned}$$

Exemple 2: (Modèle poisson gamma)

Supposons  $N \sim \text{Pois}(\lambda)$  de loi  $P_N(k) = \frac{e^{-\lambda} \lambda^k}{k!}$ ,  $k \geq 0$

et  $U \sim \text{Gamma}(\alpha, \beta)$  de densité  $f_U(x) = \frac{x^{\alpha-1} e^{-x/\beta}}{\beta^\alpha \Gamma(\alpha)}$

$$\text{On a } \mathbb{E}[X] = \lambda \alpha \beta$$

$$\mathbb{V}[X] = \lambda \alpha^2 \beta^2 + \alpha \beta^2 \lambda$$

$$A_x(s) = \exp\left\{\lambda \left(\frac{1}{1-\beta}\right)^\alpha - 1\right\}$$

## II - Modèle pour la fréquence des sinistres

### Définition

1.  $N \sim \text{Poiss}(\lambda)$ ,  $\lambda > 0$ , avec  $p_N(k) = \frac{e^{-\lambda} \lambda^k}{k!}$ ,  $k \geq 0$

2.  $N \sim \text{Bin}(n, p)$ ,  $n \in \mathbb{N}^*$ ,  $p \in [0, 1]$ , avec  $p_N(k) = \binom{n}{k} p^k (1-p)^{n-k}$ ,  $k=0, \dots, n$

3.  $N \sim \text{Neg-Bin}(k, p)$ , avec  $\alpha > 0$ ,  $p \in [0, 1]$

$$\text{avec } p_N(k) = \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)\Gamma(k+1)} (1-p)^\alpha p^k, k \geq 0$$

NB: Loi de poisson  $\Rightarrow$  1 seul paramètre = peu de flexibilité  
 loi binomial  $\Rightarrow$  Support fini (pas pratique)

- Poisson = équi-disposé  $E[N] = V[N] = \lambda$
- Binomial = sous-disposé,  $E[N] > V[N]$
- Binomial-negative = sur-disposé  $E[N] < V[N]$

## Definition (Distribution zéro-inflatée)

Soit  $N$  une va de comptage de loi  $p_N$ , la va.  $N_0$  de

loi

$$\mathbb{P}_{N_0}(k) = \begin{cases} p_0 \\ \frac{1-p_0}{1-p_N(0)} p_N(k), \text{ pour } k \geq 1 \end{cases}$$

Le modèle de poisson est souvent utilisé comme point de départ avec un nombre moyen de succès égal à  $\lambda$ .

On peut raffiner le modèle en supposant que  $\lambda = d$  est aléatoire.

- Compenser une erreur d'estimation
- Incorporer de l'information a priori
- Prendre en compte l'hétérogénéité dans le portefeuille
- Accorder la situation  $V(N) > \mathbb{E}[N]$

## Définition (Poisson-mélange)

Soit une va positive, la va  $N$  est une loi

Poisson-mélange  $\pi \text{Poisson}(\lambda)$  avec

$$\text{VP}(N=k) = \int_{\mathbb{R}^+} \frac{e^{-\lambda} \lambda^k}{k!} dP_\lambda(d)$$

$$N|\lambda = \lambda \sim \text{Pois}(\lambda)$$

### Proposition:

$$1. \mathbb{E}[N] = \mathbb{E}[\lambda]$$

$$2. V[N] = \mathbb{E}[V[N|\lambda]] + V[\lambda]$$

$$3. G_N(s) = \mathbb{E}[s^N] = \prod_{\lambda} (\lambda^{s-1})$$

### Preuve

$$\textcircled{1} \quad \mathbb{E}[N] = \mathbb{E}[\mathbb{E}[N|\lambda]] = \mathbb{E}[\lambda]$$

$$\textcircled{2} \quad V[N] = V[\mathbb{E}[N|\lambda]] + \mathbb{E}[V[N|\lambda]] = V[\lambda] + \mathbb{E}[\lambda]$$

$$\textcircled{3} \quad G_N(s) = \mathbb{E}[s^N] = \mathbb{E}[\mathbb{E}[s^N|\lambda]]$$

$$= \mathbb{E}[\exp(\lambda(s-1))] = \prod_{\lambda} (\lambda^{s-1})$$

Exemple 3 (Hétérogénéité dans le  $\mu_{tf}$ )

Deux types de conducteurs:

- Les conducteurs prudent généreront  $\lambda_1$  sinistres en moyenne par période d'exercice
- — moins prudent  $\rightarrow \lambda_2 > \lambda_1$  —

Pour un conducteur  $i \in \{1, \dots, n\}$ , on ne connaît pas sa classe d'appartenance le nombre de sinistre pour ce conducteur

$$\Pi_i = N_1 \Pi_{\lambda_1} + N_2 \Pi_{\lambda_2}$$

où  $N_1 \sim \text{Pois}(\lambda_1)$ ,  $N_2 \sim \text{Pois}(\lambda_2)$  et  $A_i = \{\text{le conducteur } i \text{ est prudent}\}$   
sont des v.a. indép

$$\text{On a } \text{IP}(\Pi_i = m) = \text{IP}(N_1 = m)P(A_i) + \text{IP}(N_2 = m)(1 - P(A_i))$$

En supposant que  $P(A_i) = P(A_j) \quad \forall i, j \in \{1, \dots, n\}$  alors le nombre total de sinistre.

$$N = \sum_{i=1}^n \Pi_i \sim \text{Pois}(\lambda_1 \times k + \lambda_2(n-k)) \quad \text{où } k \sim \text{Bin}(n, p)$$

On part du principe qu'il y a une proportion  $p$  de bon conducteur dans la population. On peut mettre à jour la probabilité  $P(A_i)$  que  $i$  soit un bon conducteur via la règle de Bayes avec  $P(A_i|n_i = p) = \frac{P(A_i = p|A_i)P(A_i)}{P(n_i = p|A_i)P(A_i) + P(n_i = p|A_i^c)P(A_i^c)}$

↳ Ajustement de la prime via un système de Bonus-Malus

$$\text{N} \sim \text{Pois}(\lambda, \sum_{i=1}^t 1_{H_i} + \lambda_2 \sum_{i=1}^t 1_{A_i^c})$$

Exemple: (Incertitude autour du paramètre)

si le nombre moyen de sinistre est donné par  $\hat{\lambda} = \frac{1}{t} \sum_{i=1}^t N_i$  pour  $t$  périodes d'exercice avec  $N_1, \dots, N_t$  les observations.

L'incertitude d'échantillonnage peut être pris en compte en supposant que

$\lambda \sim \text{Unif}([\hat{\lambda} \pm q_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{t}}])$  où  $q_{1-\alpha/2}$  est un quantile de la loi de Student à  $t-1$  degrés de liberté.

## Exemple 5: (Influence Bayésienne de la loi de Poisson)

La stat Bayésienne permet de pallier à un manque d'observation via l'incorporation de l'information a priori sur le paramètre.

Pour un paramètre positif comme  $\lambda$ , un choix classique est la loi gamma  $\lambda \sim \text{Gamma}(\alpha, \beta)$ . Notons  $N_1, \dots, N_t$  les observations du nombre de sinistres en cours des périodes d'exercice.

La loi a posteriori de  $\lambda$  avec

$$P_{\lambda|N}(\lambda|n) = \frac{P_{N|\lambda}(n|\lambda) P_\lambda(\lambda)}{\int P_{N|\lambda}(n|\lambda) dP_\lambda(\lambda)}$$

où  $P_{N|\lambda}(n|\lambda)$  est la vraisemblance des données sachant que  $\lambda = \lambda$ .

L'évaluation du dénominateur pose problème (on évite son évaluation en utilisant un algo NCAC).

Le choix de  $N \sim \text{Pois}(\lambda)$  et  $\lambda \sim \text{Gamma}(\alpha, \beta)$  donne

$$\begin{aligned} \int P_{N|\lambda}(n|\lambda) P_\lambda(\lambda) d\lambda &= \int_{\lambda=1}^{\infty} \frac{e^{-\lambda} \lambda^{n_i}}{n_i!} \frac{e^{-\lambda/\beta} \lambda^{\alpha-1}}{\beta^\alpha \Gamma(\alpha)} d\lambda \\ &= \int_{\lambda=1}^{\infty} \frac{e^{-\lambda(1+\frac{1}{\beta})} \lambda^{\sum n_i}}{\prod n_i!} \frac{e^{-\lambda/\beta} \lambda^{\alpha-1}}{\beta^\alpha \Gamma(\alpha)} d\lambda \end{aligned}$$

$$= \frac{1}{\prod_{i=1}^r n_i! \beta^{n_i} P(\alpha)} \int_0^\infty e^{-\lambda(t+1/\beta)} \lambda^{\sum n_i + d - 1} d\lambda$$

$$= \frac{1}{\prod_{i=1}^r n_i! \beta^{n_i} P(\alpha)} \times \frac{P\left(\sum_{i=1}^r n_i + d\right)}{(t+1/\beta)^{\sum n_i + d}} \underbrace{\int_0^\infty \frac{(t+1/\beta)^{\sum n_i + d} \lambda^{d - 1 - \sum n_i} e^{-\lambda(t+1/\beta)}}{P\left(\sum_{i=1}^r n_i + d\right)} d\lambda}_1$$

Exercise:

$\Lambda \sim \text{Pois}(\lambda)$ ,  $\Lambda \sim \text{Gamma}(d, \beta)$ , member que  $\Lambda \sim \text{Neg-Bin}(\cdot, \cdot)$

### III - Modèles pour les montants de sinistres

#### 1/ les lois classiques

les lois de type gamma ont le problème suivant

$$\mathbb{P}(U > x) \approx e^{-x/\beta}, \quad x \rightarrow +\infty$$

qui entraîne une sous-estimation de la probabilité d'occurrence de montants de sinistres élevés.

On préférera utiliser des distributions de probabilité à queue dite "lourde". En actuariat, la distribution de  $X$  est à queue lourde si  $\mathbb{E}_X(s) = \infty \quad \forall s > 0$   
 $= \mathbb{E}[e^{sx}]$

#### Definition (loi lognormale)

La variable  $U \sim LN(\mu, \sigma^2)$  a pour densité

$$f_U(x) = \frac{1}{x \sqrt{2\pi}} \exp \left[ -\frac{(\ln(x) - \mu)^2}{2\sigma^2} \right], \quad x > 0$$

et sa fonction de survie

$$\bar{F}_U(x) = 1 - \Phi \left( \frac{\ln(x) - \mu}{\sigma} \right)$$

On note que  $U = \exp(\mu + \sigma Z)$ , où  $Z \sim N(0, 1)$

## Proposition

Les moments de  $U \sim LN(\mu, \sigma^2)$  sont donnés par

$$\mathbb{E}[U^k] = \exp\left(k\mu + k^2 \frac{\sigma^2}{2}\right), \quad k=0,1,\dots$$

### NB:

- ① La loi lognormale admet des moments de tout ordre, mais pas de fonction génératrice des moments.
- ② Plus  $\sigma \rightarrow$  plus la loi lognormale est à queue lourde.
- ③ La loi de  $U_1 + U_2$ , pour  $U_1, U_2 \stackrel{iid}{\sim} LN(\mu, \sigma^2)$ , est inconnue.

## Definition (loi de Weibull)

$U \sim \text{Weib}(a, \beta)$  de densité  $f_U(x) = \frac{\alpha}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^\alpha}$   
 et de fonction de survie  $\bar{F}_U(x) = e^{-\left(x/\beta\right)^\alpha}$

NB:  $\alpha$  réagit la queue de la distribution

- $\alpha=1 \Rightarrow$  Exp
- $\alpha < 1 \Rightarrow$  Soc exponential
- $\alpha > 1 \Rightarrow$  Sur exponential

Proposition

les moments de  $U \sim \text{Weil}(\alpha, \beta)$  sont donnés par

$$\mathbb{E}[U^k] = \beta^k \Gamma(1 + \frac{k}{\alpha}), \quad k \geq 0$$

Définition

$U \sim \text{Par}(\alpha, \gamma)$  de densité

$$f_U(x) = \begin{cases} \frac{\alpha \gamma^\alpha}{x^{\alpha+1}}, & \text{si } x \geq \gamma \\ 0, & \text{sinon} \end{cases}$$

$$\text{et } \mathbb{P}(U > x) = \bar{F}_U(x) = \begin{cases} \left(\frac{x}{\gamma}\right)^\alpha, & \text{si } x > \gamma \\ 1, & \text{si } x \leq \gamma \end{cases}$$

NB: 1. Si  $\alpha < 1$ ,  $\mathbb{E}[U] = \infty$

2.  $X = \gamma e^{Y/\alpha}$ ,  $Y \sim \mathcal{E}(1)$

Proposition

Soit  $x_1, \dots, x_n$  un échantillon iid de loi de Pareto, l'estimateur du maximum de vraisemblance est donné par

$$\hat{\gamma} = \min_{i=1, \dots, n} x_i \quad \text{et} \quad \hat{\alpha} = \frac{n}{\sum_{i=1}^n \ln(x_i/\hat{\gamma})}$$

### Exemple

En présence de valeurs extrêmes, une procédure de choix pour le seuil de valeur extrême consiste à grapher la suite

$$\hat{x}_k = \frac{k}{\sum_{i=j+1}^n \ln\left(\frac{x_{n-i+1}}{x_{n-k,n}}\right)}, \quad k=1, \dots, n-1$$

où  $x_{1,n}, \dots, x_{n,n}$  désigne les statistiques d'ordre de l'échantillon  $x_1, \dots, x_n$ .

## 2/ Les modèles composites

### Définition

Soient  $f_1$  et  $f_2$  deux densités de probabilité sur  $\mathbb{R}^+$ , le modèle composite est donnée par

$$f(x) = \begin{cases} r \frac{f_1(x)}{F_1(\alpha)}, & x \leq \alpha \\ (1-r) \frac{f_2(x)}{F_2(\alpha)}, & x > \alpha \end{cases}$$

$\alpha$  est le paramètre de seuil. On impose les conditions de régularité suivantes.

$$f(\alpha^-) = f(\alpha^+) \quad \text{et} \quad f'(\alpha^-) = f'(\alpha^+)$$

## Exemple (Important)

Modèle composite Weib-Par ( $r, k, \beta, \alpha, \theta$ ) comme mélange de la loi de Weibull de densité

$$f_1(x) = \frac{k}{\beta} \left( \frac{x}{\beta} \right)^{k-1} e^{-(x/\beta)^k}, x > 0$$

et de la loi de Pareto

$$f_2(x) = \begin{cases} \frac{x^{\theta}}{x^{\theta+1}}, & x > 0 \\ 0, & \text{si } x \leq 0 \end{cases}$$

Les conditions de régularité  $f(\theta^-) = f(\theta^+)$  et  $f'(\theta^-) = f'(\theta^+)$  conduisent à fixer deux paramètres sur cinq. Par exemple, on peut fixer

$$r = \frac{\frac{\theta}{\alpha} \left[ 1 - \exp\left(-\frac{k+\alpha}{k}\right) \right]}{\frac{k}{\alpha} + \frac{k}{\alpha} \exp\left(-\frac{k+\alpha}{k}\right)} \quad \text{et } \beta = \left(\frac{k}{k+\alpha}\right)^{1/k}$$

$$f(\theta^-) = f(\theta^+) \Leftrightarrow \frac{r}{1-r} = \frac{f_2(\theta^-) f_1(\theta^-)}{f_1(\theta^+)}$$

On note

$$f'_1(x) = f_1(x) \left[ \frac{k-1}{x} - k \frac{x^{k-1}}{\beta^k} \right], \quad x > 0$$

$$\text{et } f'_2(x) = -f_2(x) \frac{\theta+1}{x}$$

$$f'(\alpha^-) = f'(\alpha^+) \Rightarrow \frac{r}{1-r} \frac{f_1'(\alpha)}{f_1(\alpha)} = f_2'(\alpha) \Leftrightarrow \beta = \left( \frac{k}{k+\alpha} \right)^{1/k}$$

puis  $r = \frac{f_2(\alpha) f_1(\alpha)}{f_2(\alpha) f_1(\alpha) + k(\alpha)} = \frac{\frac{\alpha}{\alpha} \left[ 1 - \exp \left( - \frac{k+\alpha}{k} \right) \right]}{\frac{\alpha}{\alpha} + \frac{k}{\alpha} \exp \left( - \frac{k+\alpha}{k} \right)}$

NB: Pour l'inference

1. Fixer  $\alpha$ , puis estimer séparément les paramètres de  $f_1$  et  $f_2$  avec les montants de sinistres  $\leq \alpha$  et  $> \alpha$  respectivement

↳ le choix du seuil ne prend pas en compte la forme de la distribution du centre de la queue de la distribution.

2. Estimation simultanée de tous les paramètres du modèle composite via le maximum de vraisemblance

3. les modèles flexibles

## Définition (Mélange de Erlang)

$X \sim \pi \cdot \text{Erl}(\pi, \beta)$  a pour densité

$$f_X(x) = \sum_{i=1}^m \pi_i \frac{e^{-\pi \beta} \beta^{z_i-1}}{\beta^{2i} (z_i-1)!}$$

Il s'agit d'un modèle de mélange avec une va 2 à valeurs entières  $z_1, \dots, z_n$  de loi  $\pi$  avec  $P(z=z_i) = \pi_i$ ,  $i=1, \dots, n$

$X \sim \text{Gamma}(2, \beta)$

## Théorème

Les lois mélange de Erlang sont denses dans l'ensemble des distribution de  $\mathbb{R}^+$ .

Consequence: On peut en théorie approcher n'importe quelle loi sur  $\mathbb{R}^+$ .

L'inference des mélanges de Erlang s'effectue via un algo itératif de type Expectation - Maximisation (EM).

On initialise la valeur des paramètres avec  $\theta^{(0)} = (\pi_1^{(0)}, \dots, \pi_m^{(0)}, \beta^{(0)})$ .

On souhaite maximiser la vraisemblance des données  $z = (z_1, \dots, z_n)$

$$\text{définie par } p(x, z, \theta) = \prod_{i=1}^n \frac{e^{-x_i \beta^{(0)} z_i}}{\beta^{(0)} z_i^{2-1}}$$

approchée par l'espérance conditionnelle sachant  $z$ .

### ① Etape Espérance (E)

$$\text{on calcul } Q(\theta | \theta^{(0)}) = E_{Z|X, \theta^{(0)}} [\ln(p(x, z, \theta^{(0)}))]$$

$$= \sum_{i=1}^n \sum_{k=1}^n \ln(p(x_k, z_i, \theta^{(0)})) P(z_i = z_i | x_k, \theta^{(0)})$$

### ② Etape Maximisation (M)

$$\theta^{(1)} = \underset{\theta}{\operatorname{arg\max}} Q(\theta | \theta^{(0)}) \text{ sous la contrainte } \sum_{i=1}^n \pi_i = 1$$

on note que

$$P(z_i = z_i | x; \theta^{(0)}) = \frac{p(x, z_i, \theta)}{p(x, \theta)} = \frac{\pi_i^{(0)} \prod_{k=1}^n \frac{e^{-x_k \beta^{(0)} z_i}}{(z_i - 1)! \beta^{(0) 2}}}{\sum_{i=1}^m \pi_i \prod_{k=1}^n \frac{e^{-x_k \beta^{(0)} z_k}}{(z_k - 1)! \beta^{(0) 2}}}$$

$$L(\pi_1, \dots, \pi_m | \beta) = \sum_{i=1}^m \sum_{k=1}^n \ln [p(x_k, z_i, \theta) P(z_i = z_i | x_k, \theta^{(0)})] - \lambda \left( \sum_{i=1}^m \pi_i - 1 \right)$$

$(\pi_1^{(1)}, \dots, \pi_m^{(1)}, \beta^{(1)})$  sont solutions du système

$$\left\{ \begin{array}{l} \frac{\partial L}{\partial \pi_i} (\pi_1, \dots, \pi_n, \beta) = 0 \\ \frac{\partial L}{\partial \beta} (\pi_1, \dots, \pi_m, \beta) = 0 \\ \sum_{i=1}^m \pi_i = 1 \end{array} \right.$$

On résout le système pour trouver

$$\pi_i^{(1)} = \frac{\sum_{k=1}^n P(Z_i = z_i | x_k, \phi^{(0)})}{n} \quad \text{et} \quad \beta^{(1)} = \frac{\frac{1}{n} \sum_{k=1}^n x_k}{\sum_{i=1}^m \pi_i^{(1)} z_i}$$

On réitère les étapes E et P jusqu'à convergence

NB: En pratique, le calibrage de la N-Erf consiste à considérer successivement  $z = 1, z \in \{1, 2, \dots, 2\}, z \in \{1, 2, \dots, n\}$  puis à choisir le modèle qui minimise le Bic, défini par  $BIC(i) = -2 \ln(p(z; \pi_1, \dots, \pi_i; \beta)) + (i+1) \ln(n)$ ,  $i = 1, \dots, n$

NB: Les lois mélanges de Erlang sont des distributions à queue légère. Une solution est d'utiliser la distribution N-Erf comme composante pour la partie atténueuse dans un modèle composite.

Autre solution: phases types généralisées (cf. google scholar)

### III - Méthode d'approximation

#### 1/ Approximation normale et gamma

Définition (Approximation normale)

Supposons que  $N \sim \text{Pois}(\lambda)$ , on note  $\mu = \text{IE}[U]$  et  $\sigma^2 = \text{IV}[U]$

On a donc

$$\text{IE}[X] = \lambda \text{IE}[U] \text{ et } \text{IV}[X] = \lambda(\mu^2 + \sigma^2)$$

L'approximation normale consiste à approcher

$$Z = \frac{X - \lambda \mu}{\sqrt{\lambda(\mu^2 + \sigma^2)}} \sim N(0,1)$$

La fonction de répartition de  $X$  est approché par

$$\text{P}(X \leq z) = \Phi\left(\frac{z - \lambda \mu}{\sqrt{\lambda(\mu^2 + \sigma^2)}}\right) \text{ où } \Phi \text{ est la f.d.r } N(0,1)$$

Cette approximation est d'autant meilleur que  $\lambda \rightarrow \infty$

Définition (Approximation Gamma)

L'approximation gamma de  $X$  consiste à approcher le modèle collectif par une loi gamma translatée.  $V \sim T\text{-Gamma}(\alpha, \beta w_0)$  avec

$$V = w_0 + W, \text{ où } W \sim \text{Gamma}(\alpha, \beta)$$

on fait correspondre les moments de  $X$  et  $V$  jusqu'à l'ordre 3. On a

$$\beta = \frac{\mu_3(x)}{2V(x)} \quad ; \quad \alpha = \frac{4V(x)^3}{\mu_3(x)^2} \quad \text{et} \quad W_0 = \mathbb{E}[x] - 2 \frac{V(x)}{\mu_3(x)}$$

$$\text{où } \mu_3(x) = \mathbb{E}[(x - \mathbb{E}[x])^3]$$

$$\begin{cases} \mathbb{E}(x) = \mathbb{E}[V] \rightarrow \text{exprimer en fonction de } w_0, \alpha \text{ et } \beta \\ V(x) = V[V] \\ \mu_3(x) = \mu_3(V) \end{cases}$$

## 2/ Algorithme de Panjer

### Definition

La distribution d'une v.a de comptage  $N$  appartient à la famille de Panjer si

$$p_N(n) = \left( a + \frac{b}{n} \right) p_N(n-1), \quad n \geq 1 \text{ si } a < 1 \text{ et } b \in \mathbb{R}$$

### Proposition

Si  $N$  est dans la famille de Panjer alors

- $N \sim \text{Pois}(d)$  avec  $a=0$  et  $d=b$
- $N \sim \text{Neg-Bin}(d, p)$  avec  $p=a$  et  $d=1+bp^{-1}$
- $N \sim \text{Bin}(n, p)$  avec  $p=a(a-1)^{-1}$  et  $n=1-ba^{-1}$

### Definition

Si  $U$  est une va de comptage alors  $X$  est aussi une va de comptage dont la loi vérifie

$$p_X(k) = \begin{cases} G_N(p_U(u)), & \text{pour } k=0 \\ \frac{1}{1-a p_U(u)} \sum_{j=1}^k \left( a + b \frac{j}{K} \right) p_U(j) p_X(k-j) & \end{cases}$$

NB: (Discréétisation de la loi des montants de sinistres)

Si  $U$  est une va continue, il est possible d'utiliser l'algorithme de Panjer après avoir discréétisé la loi des montants de sinistres.

Un schéma de discréétisation classique est le suivant

$$p_0(kh) = \begin{cases} f_0(h/2), & \text{si } k=0 \\ f_0(kh+h/2) - f_0(kh-h/2), & h \geq 1 \end{cases}$$

### 3/ Fast Fourier Transform (FFT)

La méthode FFT est motivée par deux faits

1. Accessibilité de la transformée de Fourier  $\mathbb{E}[e^{isX}]$

2. Temps de calcul trop long avec Panjer

La procédure FFT est exacte si les montants de sinistres sont des va discrètes à support fini. Supposons que  $X \in \mathbb{N}$  avec  $X \leq n$

Sa transformée de Fourier est donnée par

$$\Pi_x(is) = \mathbb{E}[e^{isX}] = \sum_{k=0}^n p_x(k) e^{isk}, \quad s \in \mathbb{R}$$

On évalue la transformée de Fourier de  $X$  sur une grille de point

$$s_j = \frac{2\pi j}{n+1}, \quad j=0 \dots n$$

les  $p_x(k)$  sont solutions de

$$\left\{ \begin{array}{l} \Pi_x(s_0) = \sum_{k=0}^n p_x(k) e^{is_0 k} \\ \Pi_x(s_n) = \sum_{k=0}^n p_x(k) e^{is_n k} \end{array} \right.$$

qui se réécrit matriciellement

$$\Pi_x^T = f p_x^T \quad \text{où } \begin{cases} \Pi_x = (\Pi_x(s_0), \dots, \Pi_x(s_n)) \\ p_x = (p_x(0), \dots, p_x(n)) \end{cases}$$

$$\text{et } f = \begin{bmatrix} e^{is_0 \cdot 0} & 1 & \dots & e^{is_n \cdot 0} \\ e^{is_0} & & & \vdots \\ \vdots & & & \vdots \\ e^{is_n} & \dots & & e^{is_n} \end{bmatrix} = (e^{iksf})_{k,f=0 \dots n}$$

$$\text{On a } f^{-1} = \frac{1}{n+1} (e^{-i p_{sk}})_{k,f=0 \dots n}$$