

# Modélisation Charges sinistres

## Chapitre 4: Inférence d'une distribution composée

### I. Problème

Soit  $X = \sum_{i=1}^n U_i$

. N est une variable de comptage de loi  $P_N(\cdot; \theta_N)$

$(U_i)_{i \geq 1}$  forme une suite iid de variables positives indépendantes de N et de loi  $f_U(\cdot; \theta_U)$

Soient  $x_1, \dots, x_t$  un échantillon d'observations iid de X sur t périodes d'exercice

Comment inférer la valeur des paramètres  $\Theta = (\theta_N, \theta_U)$  à partir de ces observations

Il s'agit d'un problème de données incomplète. Les données complètes comprennent la fréquence et les montants de sinistres soit

$$(n_s, \bar{u}_s) = \{n_s, (U_{s,1}, \dots, U_{s,n_s})\}, s=1, \dots, t$$

Supposons que  $N \sim \text{Geom}(q)$  avec  $P(N=k) = (1-q)q^k$ ,  $k \geq 0$   
et  $U \sim \text{Exp}(\delta)$  avec  $f_U(x) = \frac{e^{-x/\delta}}{\delta}$

Méthode par maximum de vraisemblance, méthode des moments.

## II - Approche fréquentiste

### 1/ Maximum de vraisemblance

Fonction de vraisemblance avec  $\mathbf{x} = (x_1, \dots, x_t)$

$$L(x, q, \delta) = (1-q)^{t_0} \prod_{s=1}^{t-t_0} f_x^+(x_s^+), \text{ où } t_0 \text{ est le nombre de zéros dans mes données et } x_1^+, \dots, x_{t-t_0}^+$$

$$f_x^+(\mathbf{x}) = ?$$

$$= \sum_{n=1}^{\infty} P(N=n) f_U^{(n)}(\mathbf{x})$$

$$= \sum_{n=1}^{\infty} (1-q)^n \frac{e^{-\frac{t}{\delta}} \frac{n!}{\delta^n}}{(n-1)! \delta} \quad \left. \begin{array}{l} \text{) Dén' exp } \sum \frac{n!}{n!} \dots \\ \dots \end{array} \right.$$

$$= \frac{(1-q)q}{\delta} e^{-\frac{t}{\delta}} \frac{(1-q)^{t-t_0}}{\delta^{t-t_0}}$$

$$L(x, q, \delta) = (1-q)^{t_0} \left[ \frac{(1-q)q}{\delta} \right]^{t-t_0} \exp \left[ -\frac{1-q}{\delta} \sum_{s=1}^{t-t_0} x_s^+ \right]$$

$$= (1-q)^t \left( \frac{q}{\delta} \right)^{t-t_0} \exp \left[ -\frac{(1-q)}{\delta} \sum_{s=1}^{t-t_0} x_s^+ \right]$$

on cherche à maximiser

$$\begin{aligned} P(x, q, \delta) &= \log(L(x, q, \delta)) \\ &= t \log(1-q) + (t-t_0) \log q + (t-t_0) \log \delta - \frac{(1-q)}{\delta} \sum_{s=1}^{t-t_0} x_s^+ \end{aligned}$$

On résout

$$\begin{cases} \frac{\partial P}{\partial q} = 0 \\ \frac{\partial P}{\partial \delta} = 0 \end{cases} \quad \text{pour trouver } (\hat{q}, \hat{\delta}) = \underset{(q, \delta)}{\text{argmax}} (x, q, \delta)$$

On a

$$\frac{\partial P}{\partial q} = -\frac{t}{1-q} + \frac{t-t_0}{q} + \frac{\sum_{s=1}^{t-t_0} x_s^+}{\delta} = 0 \quad (1)$$

$$\frac{\partial P}{\partial \delta} = \frac{t-t_0}{\delta} + (1-q) \delta^{-2} \sum_{s=1}^{t-t_0} x_s^+ = 0 \quad (2)$$

Cela donne  $\hat{q} = \frac{t-t_0}{T}$  et  $\hat{\delta} = \frac{t_0}{T} - \frac{1}{T-t_0} \sum_{s=1}^{T-t_0} z_s +$

## 2) Approche Bayésienne

(Inference Bayésienne repose sur la loi a posteriori)

$$p(\theta|z) = \frac{L(z, \theta) p(\theta)}{\int L(z, \theta) p(\theta) d\theta} = \frac{L(z, \theta) p(\theta)}{L(z)}$$

de  $\theta$  sachant les données  $z$ . On obtient  $p(\theta|z)$  en mettant  $\theta$  jour la loi a priori  $p(\theta)$  via la vraisemblance  $L(z, \theta)$ .

La constante de normalisation  $L(z)$  est souvent difficile à calculer. On utilise alors des algo de simulation MCMC pour échantillonner la loi a posteriori.

## Nétopolis - Hoshing

Pour  $i = 1, \dots, I$

- ① Initialisation : si  $i = 1$  alors  $\theta_i \sim p(\theta)$  sinon étape 2
- ② Perturbation : si  $i > 1$   $\theta^* = \theta_{i-1} + \epsilon$ , avec  $\epsilon \sim N\text{-Normal}(0, \Sigma)$
- ③ Acceptation / Rejet, soit  $U \sim U(0, 1)$ 
  - Si  $\min\left(1, \frac{L(x, \theta^*) p(\theta^*)}{L(x, \theta_{i-1}) p(\theta_{i-1})}\right) \geq u$  alors  $\theta_i = \theta^*$
  - Sinon  $\theta_i = \theta_{i-1}$

Le résultat est une suite  $\theta_1, \dots, \theta_I$  distribué suivant  $p(\theta, x)$

Prenons des lois a priori uniforme et indépendantes sur les paramètres avec

$$p(\theta) = p(q) p(s) = \frac{1}{b_q - a_q} \mathbb{1}_{[a_q, b_q]} \times \frac{1}{b_s - a_s} \mathbb{1}_{[a_s, b_s]}$$