

## Modèles de durée / Examen du 20 janvier 2012

**Durée 2h – aucun document n'est autorisé**

**Corrigé**

### Problème : mesure de l'incertitude sur des taux de mortalité

On considère une variable aléatoire  $X$  décrivant une durée de vie et on note  $S$  et  $h$  respectivement la fonction de survie et la fonction de hasard associées. On utilise les notations usuelles, ie  $T_i = X_i \wedge C_i$  et  $D_i = 1_{\{X_i \leq C_i\}}$  avec  $C_i$  la variable de censure. On rappelle que l'estimateur de Greenwood de la variance de l'estimateur Kaplan-Meier de la fonction de survie  $S$  est :

$$\hat{V}(\hat{S}(t)) = \hat{S}(t)^2 \gamma(t)^2$$

où  $\gamma(t) = \sqrt{\sum_{T_i \leq t} \frac{d_i}{r_i(r_i - d_i)}}$  avec  $d_i$  le nombre de sorties non censurées observées à l'instant  $T_i$

et  $r_i$  l'exposition au risque. On rappelle également l'approximation de la variance de  $f(X)$  obtenue par la méthode Delta :

$$V(f(X)) \approx \left( \frac{df}{dx}(E(X)) \right)^2 V(X).$$

**Question n°1 (2 points)** : Donner une justification de l'approximation ci-dessus et préciser dans quel cadre elle est valable.

On met  $X$  sous la forme  $X = \mu + \sigma Z$  avec  $Z$  centrée réduite, on remarque que pour une fonction  $x \rightarrow f(x)$  suffisamment régulière, en effectuant le développement limité  $f(\mu + h) \approx f(\mu) + h \frac{df}{dx}(\mu)$ , on trouve que :

$$V(f(X)) \approx V\left(f(\mu) + \sigma Z \frac{df}{dx}(\mu)\right) = \sigma^2 \frac{df}{dx}(\mu)^2.$$

Cette approximation est donc valide lorsque la variance  $\sigma$  est petite.

**Question n°2 (3 points)** : En partant de l'expression suivante de l'estimateur de Kaplan-Meier,  $\hat{S}(t) = \prod_{T_i \leq t} \left(1 - \frac{d_i}{r_i}\right)$ , donner une justification de la formule de Greenwood (on pourra considérer d'abord  $\ln(\hat{S}(t))$ )

| cf. le [support de cours](#) sur les modèles non paramétriques, section 3.2.4.

**Question n°3 (2 points)** : Rappeler le lien entre la probabilité conditionnelle de sortie  $q_x$  et la fonction de survie  $S(x)$ . En déduire un estimateur Kaplan-Meier de la probabilité

conditionnelle de sortie,  $\hat{q}(x)$ . Quel est le lien entre  $q_x$  et la fonction de survie de la variable  $X_x = (X - x) | X > x$  ?

$$\left| \begin{array}{l} q_x = 1 - \frac{S(x+1)}{S(x)} \text{ et donc } \hat{q}_x = 1 - \frac{\hat{S}(x+1)}{\hat{S}(x)}. \text{ On a par ailleurs } 1 - q_x = S_x(1) \text{ en} \\ \text{notant } S_x(t) = \frac{S(x+t)}{S(x)} \text{ la fonction de survie de } X_x. \end{array} \right.$$

**Question n°4 (3 points)** : Déduire des questions précédentes un estimateur de  $\hat{V}(\hat{q}(x))$

$$\left| \begin{array}{l} \hat{q}_x = 1 - \frac{\hat{S}(x+1)}{\hat{S}(x)} ; \text{ on déduit alors de l'égalité } \hat{S}(x) = \prod_{T_i \leq x} \left(1 - \frac{d_i}{r_i}\right) \text{ que} \\ 1 - \hat{q}(x) = \prod_{x < T_i \leq x+1} \left(1 - \frac{d_i}{r_i}\right) \text{ et donc à l'aide de la formule de Greenwood :} \\ \hat{V}(\hat{q}(x)) = (1 - \hat{q}(x))^2 \sum_{x < T_i \leq x+1} \frac{d_i}{r_i(r_i - d_i)} \end{array} \right.$$

**Question n°5 (3 points)** : Comment déduire de la question précédente un intervalle de confiance (asymptotique) au niveau  $\alpha$  pour  $q_x$ ? Donner l'expression explicite d'un tel intervalle.

$$\left| \begin{array}{l} \text{En utilisant la normalité asymptotique de l'estimateur de Kaplan-Meier, on trouve les bornes suivantes de l'intervalle de confiance au niveau } \alpha : \\ \hat{q}_{\pm}(x) = 1 - (1 - \hat{q}(x)) \times \left( 1 \pm u_{\frac{1-\alpha}{2}} \times \sqrt{\sum_{x < T_i \leq x+1} \frac{d_i}{r_i(r_i - d_i)}} \right) \\ \text{avec } u_{\alpha} \text{ le quantile d'ordre } \alpha \text{ de la loi normale centrée réduite.} \end{array} \right.$$

On considère maintenant le nombre de sorties par décès sur  $[x, x+1]$ , que l'on note  $D_x$  et l'exposition au risque  $E_x$ .

**Question n°6 (2 points)** : Rappelez la définition (mathématique) de  $E_x$  et le lien qui existe entre  $E_x$  et  $D_x$ .

| cf. le [support de cours](#) sur les modèles non paramétriques, section 5.2.

**Question n°7 (3 points)** : Proposer dans ce cadre un estimateur non paramétrique de  $q_x$ , dont on calculera l'espérance et la variance. Quelle est la loi asymptotique de cet estimateur lorsque  $E_x$  est grand ?

On pose  $\tilde{q}_x = \frac{D_x}{E_x}$  (estimateur de Hoem) qui est sans biais puisqu'on a vu à la question précédente que  $E(D_x) = E_x \times q_x$ . Comme  $D_x$  suit une loi binomiale de paramètres  $(E_x, q_x)$ , on en déduit que La variance est  $V(\tilde{q}_x) = \frac{q_x(1-q_x)}{E_x}$ . Par ailleurs on peut approcher la loi binomiale de  $D_x$  par une loi normale lorsque  $E_x$  tend vers l'infini et on en déduit que  $\sqrt{\frac{E_x}{q_x(1-q_x)}}(\tilde{q}_x - q_x) \rightarrow N(0,1)$  la convergence étant en loi.

**Question n°8 (2 points)** : Déduire de la question précédente un intervalle de confiance (asymptotique) au niveau  $\alpha$  pour  $q_x$ .

D'après la question précédente on a :

$$\tilde{q}_{\pm}(x) = \tilde{q}(x) \pm u_{1-\frac{\alpha}{2}} \times \sqrt{\frac{q_x(1-q_x)}{E_x}}$$

et on peut montrer avec quelques calculs<sup>1</sup> qu'en remplaçant dans la variance du terme de droite  $q_x$  qui est inconnu par son estimateur  $\tilde{q}(x)$  que l'intervalle obtenu est asymptotiquement du même niveau.

---

<sup>1</sup> Voir par exemple Saporta G. [1990] Probabilités, Analyse des données et Statistique, Paris : Technip.