

Annexe type:

① Rappeler les définitions des termes: censure aléatoire droite, censure non informative, troncature gauche

Censure aléatoire droite: Soit un échantillon de durées de vie (X_1, \dots, X_n) et un second échantillon indépendant composé de variables positives (C_1, \dots, C_n)

On dit qu'il y a censure aléatoire droite si au lieu d'observer directement (X_1, \dots, X_n) on observe $(T_1, D_1), \dots, (T_n, D_n)$

$$\text{avec } T_i = X_i \wedge C_i \text{ et } D_i = \mathbb{1}_{X_i < C_i}$$

Censure non informative: Cela signifie que la loi de censure est indép du paramètre θ .

\Leftrightarrow les lois de X et C n'ont pas de paramètre commun.

\rightarrow Exemple de censure qui n'est pas non informative : Censure au n ème décès $\Rightarrow C = X_{(n)}$

Troncature gauche: On dit qu'il y a troncature gauche lorsque la variable d'intérêt n'est pas observable lorsqu'elle est inférieure à un seuil $E_i > 0$

$$\rightarrow X_i \rightarrow X_i | X_i > E_i$$

\rightarrow Vraisemblances:

Dans le cas de la censure aléatoire droite on a :

$$\begin{aligned} P(T_i > t_i, D_i = 1) &= P(X_i \wedge C_i > t_i, X_i \leq C_i) \\ &= P(X_i > t_i, X_i \leq C_i) \\ &= P(t_i < X_i \leq C_i) \\ &= \mathbb{E}[P(t_i < X_i \leq c) | C_i = c] \\ &= \int_{t_i}^{\infty} \left(\int_c^c f_X(u) du \right) f_C(c) dc \quad \begin{array}{l} \text{Fubini} \\ \text{visez la case} \end{array} \\ &= \int_{t_i}^{\infty} f_C(c) \int_c^{\infty} f_X(u) du dc \\ &= \int_{t_i}^{\infty} f_C(c) S_X(u) du = S_C(t_i) S_X(t_i) \end{aligned}$$

$$\Rightarrow -\frac{d}{dt_i} P(T_i > t_i, D_i = 1) = f_C(t_i) S_X(t_i)$$

$$\text{De même, } -\frac{d}{dt_i} P(T_i > t_i, D_i = 0) = f_C(t_i) S_X(t_i)$$

$$\Rightarrow \mathcal{L}(\theta) = \prod_{i=1}^n \left[f_X(t_i) S_C(t_i) \right]^{D_i} \left[f_C(t_i) S_X(t_i) \right]^{1-D_i}$$

Avec l'hypothèse de censure non informative, X et C n'ont pas de paramètre commun.

$$\Rightarrow \mathcal{L}(\theta) = \text{cte} \times \prod_{i=1}^n f_X(t_i; \theta)^{D_i} S_X(t_i; \theta)^{1-D_i}$$

\nwarrow combiner les info relatives à la censure.

De plus, $f_X(t) = h_X(t) S_X(t)$

$$\Rightarrow \mathcal{L}(\theta) = \text{cte} \times \prod_{i=1}^n h_X(t_i; \theta)^{D_i} S_X(t_i; \theta)^{1-D_i}$$

Avec l'hypothèse de troncature gauche $h_{X|C_i}(t_i; \theta) = h_X(t_i; \theta)$ et $S_{X|C_i}(t_i; \theta) = \frac{S_X(t_i; \theta)}{S_X(E_i; \theta)}$

$$\Rightarrow \mathcal{L}(\theta) = cste \times \prod_{i=1}^m h_x(l_i; \theta) \stackrel{D}{=} \frac{S_x(l_i; \theta)}{S_x(e_i; \theta)}$$

© Théo Jalabert

$$\Rightarrow \ln(\mathcal{L}(\theta)) = \text{cste} + \sum_{i=1}^m [d_i \ln(h_x(l_i; \theta)) + \ln(S_x(l_i)) - \ln(S_x(e_i))]$$

② Si la fonct° de hasard est de sur $[x; x+1]$ donner vraisemblance et constantes e_i, l_i :

$$\begin{aligned} \text{Fonct° de hasard } \mu_x &\text{ est de sur } [x; x+1] \Rightarrow \forall t \in [x; x+1], \mu_x(t) = 0 \Rightarrow S_x(t) = e^{\int_x^t \mu_x(u) du} = e^{-\theta t} \\ \Rightarrow \ln(\mathcal{L}(\theta)) &= \sum_{i=1}^m [d_i \ln(\theta) - \theta(l_i(x) - e_i(x))] \\ &= d_x \ln(\theta) - \theta E_x \end{aligned}$$

$$\text{avec } d_x = \sum_{i=1}^m d_i \text{ et } E_x = \sum_{i=1}^m (l_i(x) - e_i(x)).$$

Tout se passe comme si: $D_x \sim \mathcal{D}(\theta E_x)$

Et $e_i(x) = e_i$ v.a. et $l_i(x) = l_i \wedge (x+1)$

On considère la spécifit° suivante:

$$\mu(x, t) = Z_t \mu_0(x)$$

$$\text{avec } \ln(\mu_0(x, t)) = \alpha_x + \beta_x t$$

Z_t des chocs en moyenne constants $E[Z_t] = 1$

③ Identifier les coefficients du modèle

* α_x : niveau moyen du log des taux constraintes à chaque âge (ils sont généralement \uparrow sauf aux âges jeunes).

* β_x : Ils décrivent l'évolut°, en log, de la mortalité au cours du temps. Les coeff's β_x sont globalement $\gg 0$ et suivent une tendance approximativement linéaire. Cette évolut° du coeff traduit l'accroissement régulier de l'espérance de vie avec le temps (améliorat° de l'hygiène, du syst. de santé...)

* β_x : Sensibilité par âge de cette tendance d'évolut° (coeff β_x + souvent positifs).

④ Contraintes et pourquoi?

Sous sa formulat° mon contrainte, le modèle étudié n'est pas identifiable.

En effet, la modification $(\alpha_x, \beta_x, h_r) \rightarrow (\alpha_x + c\beta_x, \frac{\beta_x}{d}, d(h_r - c))$ n'affecte pas la valeur de $\mu(x, t)$. ($d, c \in \mathbb{R}$).

Nous devons alors imposer les contraintes $\sum_{x=x_m}^{x_M} \beta_x = 1$ et $\sum_{r=r_m}^{r_M} h_r = 0$

⑤ Poser le problème d'optimisat° considéré dans le modèle tradici°nel de Lee-Carter (i.e $\mu(x,t) = \exp(\alpha_x + \beta_x k_t)$) pour déterminer les paramètres (α, β, k) . Inconvénient majeur de cette approche? → Reformulat° pour corriger cet inconvénient?

Ici on fait pas nombreux critères pour garantir l'unicité

$$\Rightarrow (\hat{\alpha}_x, \hat{\beta}_x, \hat{k}_t) = \arg \min_{(\alpha_x, \beta_x, k_t)} \sum_{x=20m}^{2m} \sum_{t=m}^m (\ln(\hat{\mu}(x,t)) - (\alpha_x + \beta_x k_t))^2$$

→ Approche classique : décomposit° en valeurs singulières
Newton-Raphson possible

Inconvénient → s'appuie sur l'hyp d'homoscedasticité des erreurs. En pratique pas vérifié.

→ On utilise la loi log → $D_{x,t} \sim P(E_{x,t}, \mu(x,t))$

↳ facteur de l'exposition au risque
de la population étudiée.

→ On peut utiliser Newton-Raphson multivarié pour estimat° des params.

On considère donc $D_{x,t} \sim P(E_{x,t}, \mu(x,t)) \Rightarrow D_{x,t} \sim P(Z_t | \lambda_{x,t})$ avec $\lambda_{x,t} = E_{x,t} \mu(x,t)$

$$\Rightarrow P(D=d|Z) = e^{-\lambda_Z} \frac{\lambda^d}{d!} Z^d$$

$$\Rightarrow P(D=d) = E[P(D=d|Z)] = \int e^{-\lambda_Z} Z^d \frac{\lambda^d}{d!} dF_Z(z)$$

On fait le choix que $Z \sim \Gamma(a, b)$

⑥ Donne l'expression de $P(D=d)$ sachant que $Z \sim \Gamma(a, b)$

$$Z \sim \Gamma(a, b) \rightarrow f_Z(z) = \frac{b^a}{\Gamma(a)} z^{a-1} e^{-bz}$$

$$\Rightarrow P(D=d) = \int_0^\infty e^{-\lambda_Z} Z^d \frac{\lambda^d}{d!} \times \frac{b^a}{\Gamma(a)} z^{a-1} e^{-bz} dz$$

$$= \frac{\lambda^d}{d!} \frac{b^a}{\Gamma(a)} \int_0^\infty z^{(a+d)-1} e^{-(\lambda+b)z} dz$$

$$\begin{aligned} u &= (\lambda+b)z \\ du &= (\lambda+b)dz \end{aligned}$$

$$= \frac{\lambda^d}{d!} \left(\frac{1}{\lambda+b} \right)^{a+d} \int_0^\infty u^{(a+d)-1} e^{-u} du$$

$$= \frac{\lambda^d}{d!} \left(\frac{1}{\lambda+b} \right)^{a+d} \frac{b^a}{\Gamma(a)} \frac{\Gamma(a+d)}{\Gamma(d+1)\Gamma(a)}$$

$$\Rightarrow h(P(D=d)) = g(a, b) + d h(\lambda) + (a+d) h(\lambda+b) \quad \text{avec } g(a, b) = h\left(b^a \frac{\Gamma(a+d)}{\Gamma(d+1)\Gamma(a)}\right)$$

$$\Rightarrow \mathcal{L}(\alpha_x, \beta_x, k_t) = h(P(D_{x,t} = d_{x,t}))$$

7) Dérivées partielles $\frac{\partial l}{\partial r^i}$ aux \neq^k paramètres.

© Théo Jalabert

Soit $p \in \{\alpha_x, \beta_x, \beta_r\}$, on a:

$$\begin{aligned} \frac{\partial}{\partial p} l(P(D=d)) &= dx \frac{1}{\lambda} \frac{\partial \lambda}{\partial p} - (d+a) \times \frac{1}{\lambda+b} \frac{\partial \lambda}{\partial p} \\ &= \left[\frac{d}{\lambda} - \frac{d+a}{\lambda+b} \right] \frac{\partial \lambda}{\partial p} \end{aligned}$$

$$\text{où } \frac{\partial \lambda}{\partial p} = \begin{cases} \lambda & \text{si } p = \alpha_x \\ b\lambda & \text{si } p = \beta_x \\ b\lambda & \text{si } p = \beta_r \end{cases}$$

$$\text{On a donc conditionnellement à } (a, b), \quad l(\mathcal{L}) = \sum_{x=x_m}^{x_n} \sum_{b=b_m}^{b_n} l(P(D=d|(a, b))) = \sum_{x=x_m}^{x_n} \sum_{b=b_m}^{b_n} [l_{x,b} l(\lambda_{x,b}) - (d_{x,b} + a) l(\lambda_{x,b} + b)]$$

Il s'agit donc de maximiser $l(\mathcal{L})$ en (α, β, b) sous les contraintes.

8) Estimez les paramètres

* Estimat° du paramètre de fragilité Z_r

→ On a supposé que $Z_r \sim \Gamma(a, b)$. De plus $E[Z_r] = 1$

$$\Rightarrow E[Z_r] = \frac{a}{b} = 1 \Rightarrow a = b \Rightarrow Z_r \sim \Gamma(a, a)$$

$$\text{De plus } V[Z_r] = \frac{a}{b^2} = \frac{1}{a}$$

Donc le paramètre de contrôle de la perturbation Z est l'inverse de la variance $a = (\hat{\sigma}_Z^2)^{-1}$

$$\text{De plus } \mu_{Z_r(t)} = Z_r \mu_0(Z_r(t)) \Rightarrow Z_r = \frac{\mu_0(Z_r(t))}{\mu_0(Z_r)}$$

On peut directement estimer ce paramètre en observant que les intensités cumulées moyennes sont tq:

$$\bar{\mu}(t) = Z_r \bar{\mu}_0(t) \quad \text{avec } \bar{\mu}_0(Z_r(t)) = \frac{\sum_{x=x_m}^{x_n} E_{x,r} \text{Molar}(x)}{\sum_{x=x_m}^{x_n} E_{x,r}}$$

$$\Rightarrow E[\bar{\mu}(t)] = \bar{\mu}_0(t)$$

$$V[\bar{\mu}(t)] = V[Z_r] \bar{\mu}_0(t)^2$$

$$\Rightarrow V[Z_r] = \frac{V[\bar{\mu}(t)]}{E[\bar{\mu}(t)]^2}$$

$$\Rightarrow \hat{\sigma}_Z^2 = \frac{1}{b_n - b_m + 1} \sum_{b=b_m}^{b_n} \left(\bar{\mu}(t) - \frac{1}{b_n - b_m + 1} \sum_{b=b_m}^{b_n} \hat{\mu}(t) \right)^2$$

$$\text{avec } \hat{\mu}(t) = \frac{\sum_{x=x_m}^{x_n} E_{x,r} \hat{\mu}_0(x)}{\sum_{x=x_m}^{x_n} E_{x,r}} \quad \text{et } \hat{\mu}_0(x) = \frac{D_{x,r}}{E_{x,r}} \text{ l'estimateur de Hœm.}$$

* Estimat° de $(\alpha_x, \beta_x, \beta_r)$ solut° des CPO:

$$\rightarrow \frac{\partial}{\partial \alpha_x} l(\mathcal{L}) = \sum_{b=b_m}^{b_n} \left[\frac{d}{\lambda_{x,b}} - \frac{d+a}{\lambda_{x,b}+b} \right] \lambda_{x,b} = 0$$

$$\rightarrow \frac{\partial}{\partial \beta_x} l(\mathcal{L}) = \sum_{b=b_m}^{b_n} \left[\frac{d}{\lambda_{x,b}} - \frac{d+a}{\lambda_{x,b}+b} \right] \beta_x \lambda_{x,b} = 0$$

$$\rightarrow \frac{\partial}{\partial \beta_r} l(\mathcal{L}) = \sum_{b=b_m}^{b_n} \left[\frac{d}{\lambda_{x,b}} - \frac{d+a}{\lambda_{x,b}+b} \right] \beta_r \lambda_{x,b} = 0$$

Ce syst est non linéaire.

→ recours à Newton-Raphson multivarié.

$$\partial_{i+1} = \partial_i - \left[\frac{\partial^2 L(x_0)}{\partial \theta_i \partial \theta_j} \right]^{-1} \frac{\partial L(x_0)}{\partial \theta_i}$$

③ Calculer $e(x,t)$ l'espérance de vie prospective.

$$e(x,t) = \sum_{i \geq 0} \prod_{j=0}^i \mathbb{E}[e^{\mu_{x,t}}]$$

$$\text{Ici } \mu_{x,t} = 2 + \mu_0(x,t) \quad \text{avec } Z_t \sim \Gamma(a, b)$$

$$\Rightarrow \mathbb{E}[e^{Z_t}] = \left(\frac{b}{b+a} \right)^a \quad (\text{transformée de Laplace d'une } \Gamma(a, b))$$

$$\Rightarrow \mathbb{E}[e^{-\mu_{x,t}}] = \mathbb{E}[e^{-\mu_0(x,t)Z_t}] = \left(\frac{b}{b+\mu_0(x,t)} \right)^a = \exp\left(-a \ln\left(1 + \frac{\mu_0(x,t)}{b}\right)\right) *$$

$$\Rightarrow e(x,t) = \sum_{i \geq 0} \prod_{j=0}^i \left(\frac{b}{b+\mu_0(x,t)} \right)^a$$

Donc par *, lorsque $b=a \rightarrow \infty$, $\mathbb{E}[e^{-\mu_{x,t}}] = e^{-\mu_0(x,t)}$

$$\Rightarrow \text{lorsque } b=a \rightarrow \infty \quad e(x,t) = \sum_{i \geq 0} \prod_{j=0}^i e^{-\mu_0(x,t)}$$