

## Censure de type I : censure fixe

Soit un échantillon de durée de survie  $(X_1, \dots, X_n)$  et  $C > 0$  fixe ; la vraisemblance du modèle associé aux observat°  $(T_i, D_i), \dots, (T_n, D_n)$  avec :

$$T_i = X_i \wedge C \quad \text{et} \quad D_i = \begin{cases} 1 & \text{si } X_i \leq C \\ 0 & \text{si } X_i > C \end{cases}$$

possède une composante continue et une discrète elle s'écrit.

$$\mathcal{L}(\theta) = \prod_{i=1}^n f_\theta(T_i)^{D_i} S_\theta(C)^{1-D_i}$$

observat° de la  
durée avant censure : prob de survie à la date  
de la censure si l'événement n'a pas  
eu lieu  
densité discrète qui intervient

Preuve :

Il suffit de calculer  $P(T_i \in [l_i, l_i + dl_i], D_i = d_i)$ . Comme  $D_i \in \{0, 1\}$ , on calcule sur  $[0, C]$

$$\begin{aligned} P(T_i \in [l_i, l_i + dl_i], D_i = 1) &= P(X_i \wedge C \in [l_i, l_i + dl_i], X_i \leq C) \\ &= P(X_i \in [l_i, l_i + dl_i]) = f_\theta(l_i) dl_i \end{aligned}$$

paramètres à X on peut toujours supposer  $dl_i$  suffisamment petit pour que  $l_i + dl_i \leq C$ .

$$\text{et } P(T_i \in [l_i, l_i + dl_i], D_i = 0) = P(X_i \wedge C \in [l_i, l_i + dl_i], X_i > C) \\ = P(X_i > C) \\ = S_\theta(C)$$

On peut donc écrire  $P(T_i \in [l_i, l_i + dl_i], D_i = d_i) = f_\theta(l_i)^{d_i} S_\theta(C)^{1-d_i}$

On peut retrouver cette express° par  $P(T_i > l_i, D_i = 1) = P(X_i > l_i, X_i \leq C)$

$$= \int_{l_i}^C f_\theta(u) du$$

et dans le cas  $D_i = 0$  comme alors  $T_i = C \Rightarrow$  pas de densité mais  $P = S_\theta(C)$

$$\Rightarrow \mathcal{L}(\theta) = \prod_{i=1}^n f_\theta(T_i)^{D_i} S_\theta(1 - D_i)$$

$$\begin{aligned} \text{Autrement: } P(T_i > l_i, D_i = 1) &= P(X_i \wedge C > l_i, X_i \leq C) \\ &= P(X_i > l_i, X_i \leq C) \\ &= P(l_i < X_i \leq C) \\ &= \int_{l_i}^C f_X(u) du = F_X(c) - F_X(l_i) \\ &= 1 - S_X(c) - (1 - S_X(l_i)) \\ &= S_X(l_i) - S_X(c) \\ \Rightarrow -\frac{d}{dl_i} P(T_i > l_i, D_i = 1) &= f_X(l_i) \end{aligned}$$

$$\text{On a } \mathcal{L}(\theta) = \prod_{i=1}^n f_\theta(T_i)^{D_i} S_\theta(T_i)^{1-D_i}$$

$$\Rightarrow \mathcal{L}(\theta) = \prod_{i=1}^n S_\theta(T_i) h_\theta(T_i)^{D_i} \quad \text{car } f = hS$$

$$\Rightarrow \ln(\mathcal{L}(\theta)) = \sum_{i=1}^m [\bar{D}_i \ln(h_{\theta}(T_i)) + \ln(S_{\theta}(T_i))]$$

### Censure de type III : censure aléatoire

$$T_i = X_i \wedge C_i \quad D_i = \mathbb{1}_{X_i < C_i}$$

$$\begin{aligned} P(T_i > t_i, D_i = 1) &= P(X_i \wedge C_i > t_i, X_i < C_i) \\ &= P(X_i > t_i, X_i < C_i) \\ &= P(t_i < X_i \leq C_i) \\ &= E[P(t_i < X_i \leq C_i | C_i = c] \stackrel{\text{Fubini}}{=} \int_{t_i}^{\infty} \int_{c}^{\infty} f_X(u) f_C(c) du dc \\ &= \int_{t_i}^{\infty} \left( \int_c^{\infty} f_X(u) du \right) f_C(c) dc = \int_{t_i}^{\infty} f_X(u) S_C(u) du = S_X(t_i) S_C(t_i) \\ \Rightarrow -\frac{d}{dt_i} P(T_i > t_i, D_i = 1) &= f_X(t_i) S_C(t_i) \end{aligned}$$

$$\text{De même, } -\frac{d}{dt_i} P(T_i > t_i, D_i = 0) = f_C(t_i) S_X(t_i)$$

$$\Rightarrow \mathcal{L}(\theta) = \prod_{i=1}^m [f_X(T_i, \theta) S_C(T_i, \theta)]^{D_i} [f_C(T_i, \theta) S_X(T_i, \theta)]^{1-D_i}$$

$$\begin{aligned} \Rightarrow \mathcal{L}(\theta) &\propto \prod_{i=1}^m f_X(T_i)^{D_i} S_C(C_i)^{1-D_i} \quad \text{Lorsque } D_i = 0 \text{ alors } T_i = C_i \\ &\propto \prod_{i=1}^m S_C(T_i) p_{\theta}(T_i)^{D_i} \end{aligned}$$

### La prise en compte de covariates (pour censure de type III)

Lorsque le modèle comporte  $p$  variables explicatives (covariates)  $Z = (Z_1, \dots, Z_p)$  on fait l'hyp que la loi conditionnelle de  $X$  sachant  $Z$  dépend d'un paramtre  $\theta$ .

L'échantillon observe délivrant une séquence de triplets  $(T_i, D_i, Z_i)$ ; on reprend l'hyp de la censure non informative; on suppose de plus que  $X$  et  $C$  sont indép conditionnellement à  $Z$  et que  $C$  est non informative pour les paramètres de la loi conditionnelle de  $X$  sachant  $Z$ .

On suppose enfin que  $Z$  admet une densité qui dépend d'un paramtre  $\phi$ ,  $f_Z(z, \phi)$ .

Dans ces cas, l'expression de la vraisemblance devient:

$$\mathcal{L}(\theta) = \prod_{i=1}^m h_{\theta|Z}(T_i)^{D_i} S_{\theta|Z}(T_i) p_Z(Z_i, \phi)$$

Lorsque la loi de  $T$  sachant  $Z$  et la loi de  $Z$  n'ont pas de paramtre commun, on retrouve simplement ce qu'il y a au-dessus dans laquelle la loi de  $X$  est remplacée par la loi conditionnelle de  $X$  sachant  $Z$ .

Se généralise facilement au cas de covariates dépendant du temps.

Un autre type de censure : "arrêt au  $n^{\text{ème}}$  décès" (censure de type II)

On se place dans le cas où la date de fin d'observation n'est pas définie à l'avance mais on s'arrête à la  $n^{\text{ème}}$  sortie.

→ Date de fin d'exp est aléatoire et égale à  $X_n$

On dit qu'il y a censure de type II si au lieu d'observer directement  $(X_1, \dots, X_m)$  on observe  $(T_1, D_1), \dots, (T_n, D_n)$  avec:

$$T_i = X_i \wedge X_{m+1} \quad \text{et} \quad D_i = \begin{cases} 1 & \text{si } X_i = T_i \\ 0 & \text{si } X_i < T_i \end{cases} = \mathbf{1}_{X_i \leq X_{m+1}}$$

avec  $X_{m+1}$  la  $(m+1)^{\text{ème}}$  sorte d'ordre de l'échantillon  $(X_1, \dots, X_m)$ .

Pour la vraisemblance, il convient donc de choisir les instants de  $n$  sorties parmi les  $m$  observées

$$\Rightarrow L(\theta) = \frac{m!}{(m-n)!} \left[ \prod_{i=1}^n h_\theta(X_{i:n}) \right] S_\theta(X_{m+1})^{m-n}$$

$$= \frac{m!}{(m-n)!} \prod_{i=1}^n h_\theta(T_i)^{D_i} S_\theta(T_i)^{1-D_i} = \frac{m!}{(m-n)!} \prod_{i=1}^n h_\theta(T_i)^{D_i} S_\theta(T_i)$$

$$\text{Si la loi de référence est la loi exponentielle} \Rightarrow L(\theta) = \frac{m!}{(m-n)!} \theta^n e^{-\theta T} \quad \text{avec } T = \sum_{i=1}^n T_{i:n} + (m-n)T_{m+1}$$

### Tromature

On dit qu'il y a tromature gauche (resp droite) lorsque la variable d'intérêt n'est pas observable lorsqu'elle est inférieure à un seuil  $c > 0$  (resp supérieure à un seuil  $C > 0$ )

La distrib observée dans ce cas est donc la loi conditionnelle à l'evt  $\{c < T < C\}$

La fact<sup>o</sup> de survie tronquée s'écrit donc:

$$S(t|c < T < C) = \begin{cases} 1 & \text{si } t < c \\ \frac{S(t)-S(c)}{S(C)-S(c)} & \text{si } c \leq t \leq C \\ 0 & \text{si } t > C \end{cases}$$

La fact<sup>o</sup> de hasard a également le support  $\{c < t < C\}$  et s'écrit  $R(t|c < T < C) = R(t) \frac{S(t)}{S(t)-S(c)}$  ce qui montre que l'expr<sup>o</sup> de  $R$  ne dépend pas de  $c$ .

La troncature droite augmente la fact<sup>o</sup> de hasard, et s'il n'y a que de la troncature gauche (i.e.  $C = +\infty$ )  $\Rightarrow R$  pas modifiée.

Synthèse : troncature gauche et censure aléatoire droite.

Les individus ne sont en général pas observés depuis l'origine mais depuis l'âge (ou âge mortel) atteint au début de la période d'observation motrice  $E_i$ .

La censure ( $i$ ) peut être inférieure à l'âge atteint à fin de période d'observation si sortie anticipée (résilidé par ex)

$$\rightarrow L(\theta) = \prod_{i=1}^n h_{\theta, E_i}(l_i) S_{\theta, E_i}(l_i)$$

$$\rightarrow \ln(L(\theta)) \propto \sum_{i=1}^n d_i \ln(h_\theta(l_i)) + h_\theta(S_\theta(l_i)) - \ln(S_\theta(e_i))$$

Comme  $h_{\theta, E_i}(l_i) = h_\theta(l_i)$  et  $S_{\theta, E_i}(l_i) = \frac{S_\theta(l_i)}{S_\theta(e_i)}$

Si tous les individus sont observés depuis l'origine  $e_i = 0 \Rightarrow \ln(L(\theta)) \propto \sum_{i=1}^n d_i \ln(h_\theta(l_i)) + h_\theta(S_\theta(l_i))$

$$\rightarrow \text{Cas Weibull pour exemple} \quad f(t) = \lambda t^{\alpha-1} e^{-\lambda t^\alpha}$$

© Théo Jalabert

Cas particulier du modèle exponentiel, lien avec modèle de Poisson.

On considère  $m$  individus pour lesquels on fait l'hyp que sur  $[t_0, t_1]$  la fréq de hasard sous-jacente est cte.

$$\Rightarrow \partial_{\theta} \ln(L(\theta)) = \sum_{i=1}^m [d_i \ln(\theta) - \delta(t_i - e_i)] = d_{t_1} \ln(\theta) - \delta E_{t_1}$$

avec  $d_{t_1} = \sum_{i=1}^m d_i$  et  $E_{t_1} = \sum_{i=1}^m (t_i - e_i)$

On rq que tout se passe comme si  $D_{t_1}$  qui compte le nb de sorties sur  $[t_0, t_1]$   $\sim \mathcal{P}(\theta E_{t_1})$

En effet, dans ce cas,  $\ln(P(D_{t_1}=d)) = d \ln(\theta) + d_{t_1} \ln(\theta) - \delta E_{t_1}$ .