

16/09/23

SÉRIES TEMPORELLES

TD + TP

Logiciel R

- examen écrit
- partie théorique
- mémoire (= projet)
 - partie application (on aura une BDD)
 - groupe de 3 ou 4 personnes
 - faire des prédictions
 - proposer une démarche cohérente de projection

important

Chapitre 5 pour le mémoire surtout pour le début

Chapitre 1 Introduction aux séries temporelles définitions et exemples

dates mensuelles pas équidistantes car pas le même nb de jours par mois, il faut rapporter la suite de var aux nb de jours suivants pour avoir des données équidistantes NB var = variables i.i.d

On n'est plus dans le cadre i.i.d
ex processus de Markov = processus à mémoire réduite

ts d'ordre 1 : on a besoin que de la dernière valeur connue pour prédire la loi de la prochaine

ex processus stochastique ≠ avec ce cours c'est qu'on est en temps continu alors qu'en i.i.d on sera en temps discret

ex processus ponctuels ⇒ les dates ne sont pas forcément équidistantes et sont elles mêmes aléatoires
ici on fera que avec des dates déterministes

Σ temp = variable aléatoire

série temporelle caractérisée par sa distribution (fonction de répartition,

$\left\{ \begin{array}{l} \text{si elle est } \mathbb{R}, \Rightarrow \text{transformée de Laplace} \\ \text{si elle } \in \mathbb{N} \Rightarrow \text{fonction caractéristique} \end{array} \right.$

variables aléatoires
f

ici on sera avec des v.a multivariée ex (X, Y)

sa loi : fonction de répartition, densité, fonct caractéristique
 $H_{x,y}$ $P(X \leq x, Y \leq y)$ $f(x,y)(x,y)$

Ici on aura un vecteur de v.a infini et dénombrable

$$(\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow \mathbb{R}^{\mathbb{Z}}$$

$$(X_t)_{t \in \mathbb{Z}}$$

Comment caractériser la loi d'un vecteur de taille ∞ ?

$$\text{car } \underset{\infty}{\underset{\text{d'événements}}{\cap}} = \left\{ \begin{array}{l} \Omega \\ \text{ou} \\ \emptyset \end{array} \right.$$

donc fonction de répartition donnera toujours 0

On va passer par le thm de Kolmogorov

$$\forall n \in \mathbb{N}^*, \forall t_1 < \dots < t_n \in \mathbb{Z}^n$$

on doit connaître la loi du vecteur

$(X_{t_1}, \dots, X_{t_n})$ pour connaître la loi du vecteur de taille ∞ . On doit donc caractériser toutes les lois des vecteurs de v.a extraits du vecteur ∞ .

$X_t(\omega) = x_t \leftarrow$ réalisation de la série temporelle
 $=$ trajectoire

Pour une suite de réalisations indépendantes, sa rep graphique sera une ligne brisée \textcircled{G}
 important pour le mémoire

d'grandes natures


- de niveau ou d'état ou de stock
 - de flux = variation du système
- par la même modélisation (stationnaire vs non stationnaire)

Ici on a besoin que d'1 seule réalisation pour avoir notre Σ temporelle

NB: on a plus l'hyp d'1
 $=$ indépendance

Exemples

* Evolution concentr' CO₂ Hawaii




Comment dire ce qui va se passer en 2030?

Structure de croissance
comment est la croissance?
quadratique, cubique, linéaire?


On assume ce qui se passera dans le futur en se basant sur le passé : on a envie de continuer la tendance croissante

pente de la droite + saisonnalité = déterminer le futur

* Evolution PIB France (va d'état)



* Variat° du PIB (va du flux)




pas constant au cours du temps
composante de trend constante
par morceaux "—"

Comment déterminer ces constantes?

* Rentabilité log du CAC 40

rentabilité prix $\frac{P_t - P_{t-1}}{P_{t-1}}$ = $\frac{P_t}{P_{t-1}} - 1 \in [-1, +\infty[$

rentabilité log $\ln\left(\frac{P_t}{P_{t-1}}\right)$ $\hat{\in}$ ordre de grandeur quand petit distribution + symétrique avec les gains et les pertes



→ pas de trend → pas saisonnière

{ niveau moyen nul

{ rentabilité moyenne nulle


variance rentabilité : aléatoire

S&P 500



variabilité augmente de la même façon que CAC 40
on a une corréation à une date fixée probable entre les 2
marchés spatiale

* Températures moyennes journalières à Paris



1995 2010

forte saisonnalité (chaud en été, froid hiver)

trend ? évolution moyenne ?

difficile à lire pour interpréter
il faudrait effectuer un filtrage

Sous R nb de n.a

nt(250, df = 10)

/ random Student nb de degrés de libertés

quelle valeur donner à la 251^e observation

251^e obs ? ici iid

donc ne dépend pas des 250^e

observations précédentes

On va lui donner comme valeur moyenne de Student = 0 loi symétrique

De plus, l'E minimise la perte quadratique

1.2 Problèmes statistiques

Description écriture de la Σ temp + identification de la trend et de la saisonnalité

+ aléatoire

Prévision jusqu'à l'instant t , que va-t'il se passer en $t+1$
 $t+2, \dots$?

Pour ça il faut choisir un bon modèle ('à définir)

Filtrage Σ temp pas assez satisfaisante (erreurs d'enregistrement, valeurs aberrantes) Il y aura forcément des "bouts" de la Σ à enlever car ils ne seront pas bons.

Traitement reconstruire valeurs manquantes à partir de leur passé et leur futur observé

des données manquantes

Détection de rupture

le niveau trend, l'intensité de la saisonnalité sont déterminantes mais il peut y avoir des cassures et dans ce cas il faut les réagyster (pas étudié dans ce cours)

Gausalité va multivariée : l'influence d'une composante sur une autre

1.3 Modélisation de la Σ temporelle

Plusieurs remarques 3 plusieurs approches

⇒ 3 plusieurs modèles (il peut avoir un modèle meilleur que les autres, à définir avec un critère (prédict à 1 mois, 2 mois, ...))

Plusieurs composantes sous-jacentes peuvent être déterministes mais il y aura toujours une composante aléatoire qui ne dépend pas du passé

À partir d'un nb d'obs finies on doit estimer une fonction α .

⇒ il faudra imposer des contraintes

Schéma décomposition additive en 3 termes

$$x_t = m_t + s_t + y_t$$

trend ↓ saisonnalité ↓ aléatoire
(determ) (determ) mais aura une composante stable dans le temps

il faut lui donner une structure (à y_t) pour modéliser sa loi

⇒ stable dans le temps

Rmg On suppose que cette décomposition existe, il est fort probable qu'il faille transformer la Σ temporelle pour qu'elle rentre dans notre cadre

Le choix de la transformation dépend de notre expérience

$$Y_t = h(Y_{t-1}, \dots, Y_{t-p}, \varepsilon_t, \dots, \varepsilon_{t-q})$$

modélisation de Y

Y_t est une fonction du passé

on utilise une information passée limitée

ε c'est l'innovation

d'appelle une information qui n'appartient pas au

imprévisible passé

soit d

On va supposer que

Y_t est une CL des va passées et les innovations

1.4 Processus stationnaires

stationnaire fort = même

soit la loi est la \tilde{m} au cours du temps

soit invariante par translation en loi

Dans la définition h entier relatif, $h \in \mathbb{Z}$

Définition stationnaire faible

au second ordre

h impose des conditions sur

les moments d'ordre 1 et 2

(cela suppose que ces moments existent)

(ex pour la loi de Cauchy ils n'existent pas)

$$\mathbb{E}[X_t^2] < +\infty \quad \forall t$$

$$\mu_X(t) = \mathbb{E}(X_t) \quad \text{variance } \text{Var}(X_t) = \gamma_X(r, n)$$

$$\text{covariance } \gamma_X(r, s) = \text{Cov}(X_r, X_s)$$

i) $t \mapsto \mu_X(t)$ $\perp\!\!\!\perp$ de t , $\forall t \in \mathbb{Z}$ $\{\mu_X(t) = \mu$

ii) $t \mapsto \gamma_X(t, t+h)$ $\perp\!\!\!\perp$ de t , $\forall h$ $\{\gamma_X(t, t+h) = \gamma_X(h)$

h est l'écart temporel entre les 2 v.a
[constante au cours du temps]

exemple :

processus stationnaire fort = v.a iid

faible = v.a iid si moments existent

fort \Rightarrow faible qd $\exists \mathbb{E}(X), \mathbb{E}[X^2]$

faible : v.a $\perp\!\!\!\perp$

contre exemple $X_{2k} \sim N(0, 1)$ \mathbb{E} est nulle

$X_{2k+1} \sim \Gamma(0, 1)$ covariance nulle car $\perp\!\!\!\perp$

\Rightarrow faible

mais pas fort

Définition pour X_t stationnaire faible

autocovariance de (X_t) $\gamma_X(h) = \text{Cov}(X_t, X_{t+h})$

$\forall h \in \mathbb{Z}$

autocorrélation de (X_t) $\rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)}$

$$= \text{Corr}(X_t, X_{t+h})$$

Propriétés

Rappel cov bilinéaire symétrique

$\gamma_X(-h) = \text{cov}(X_t, X_{t-h})$ X_t stationnaire
faible donc $\perp\!\!\!\perp$ de t

par symétrie $\text{cov}(X_{t-h}, X_t) = \gamma_X(t-h, t) = \gamma_X(t-h+h, t+h)$

$$= \text{cov}(X_t, X_{t+h}) = \gamma_X(h)$$

$$\gamma_X(0) \geq 0 \text{ car } \text{Var} \geq 0$$

$$|\gamma_X(h)| = |\mathbb{E}[(X_t - \mathbb{E}[X_t])(X_{t+h} - \mathbb{E}[X_{t+h}])]|$$

$$\leq (\mathbb{E}[(X_t - \mathbb{E}[X_t])^2])^{1/2} (\mathbb{E}[(X_{t+h} - \mathbb{E}[X_{t+h}])^2])^{1/2}$$

Hölder

Cauchy

$$\leq (\gamma_X(0) \gamma_X(0))^{1/2}$$

$$\leq \gamma_X(0)$$

$$\left| \frac{\gamma_X(h)}{\gamma_X(0)} \right| = |p_X(h)| \leq 1$$

$p_X(h) = 1 \Leftrightarrow \exists$ relat° affine \nearrow

$= -1 \Leftrightarrow \exists$ relat° affine \searrow

{ qd $p_X(h) = 0 \cancel{\Rightarrow} \perp\!\!\!\perp$ } mais $\{ \perp\!\!\!\perp \Rightarrow p_X(h) = 0 \}$

contre-exemple $Z \sim N(0, 1)$

$$\begin{aligned} X &= Z \\ Y &= Z^2 \text{ par } \perp\!\!\!\perp \end{aligned}$$

mais

$$\text{cov}(X, Y) = \underbrace{\mathbb{E}[XY]}_{=0} - \underbrace{\mathbb{E}[X]\mathbb{E}[Y]}_{=0} = 0$$

cov impair

$p_X(0) = 1$ car relat° linéaire parfaite
entre moi et moi - \hat{m}

$$X = \begin{pmatrix} X_{t_1} \\ \vdots \\ X_{t_n} \end{pmatrix} \quad t_1 + \dots + t_n \in \mathbb{Z}$$

$$\mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_{t_1}] \\ \vdots \\ \mathbb{E}[X_{t_n}] \end{pmatrix}_{(n, 1)} = \begin{pmatrix} \mu_X(t_1) \\ \vdots \\ \mu_X(t_n) \end{pmatrix}$$

$$\mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])(X' - \mathbb{E}[X'])]$$

$$= \left(\text{cov}(X_{t_i}, X_{t_j}) \right)_{(n, n)}$$

$$= \left(\gamma_X(t_i, t_j) \right)_{(n, n)}$$

\Rightarrow symétrique

$$\begin{aligned}
 & (*) a' W[X] a = \left(\sum_{i=1}^n a_i X_{t_i} \right)^2 \geq 0 \\
 & a \in \mathbb{R}^n \\
 & \text{et } W[a' X] = a' W[X] a = \sum_{i=1}^n a_i^2 \gamma_X(t_i, t_i) = \sum_{i=1}^n a_i^2 \gamma_X(t_i, t_i) \\
 & \text{on sait } W[a' X] \geq 0 \\
 & \text{et } W[a' X] = a' W[X] a = \sum_{i,j} a_i a_j \gamma_X(t_i - t_j) \geq 0 \\
 & \Rightarrow \text{definie positive} \\
 & \text{Ex avec } t_1 = 1 \dots t_n = n \quad \text{avec } t = t_j
 \end{aligned}$$

$$W[X] = \begin{pmatrix} \gamma_X(0) & \gamma_X(1) & \gamma_X(2) & \dots & \gamma_X(n-1) \\ \vdots & \ddots & \gamma_X(2) & & \\ & & \gamma_X(1) & & \\ & & & \ddots & \gamma_X(0) \end{pmatrix} = V_n$$

matrice d'auto covariance

$$R[X] = \frac{W[X]}{\gamma_X(0)} = \begin{pmatrix} 1 & p_X(1) & p_X(2) & \dots & p_X(n-1) \\ p_X(1) & 1 & & & \\ p_X(2) & & 1 & & \\ \vdots & & & \ddots & \\ p_X(n-1) & & & & 1 \end{pmatrix} = R_n$$

matrice d'autocorrelat


$$\det R_n \geq 0$$

$$\det R_2 = \begin{vmatrix} 1 & p_X(1) \\ p_X(1) & 1 \end{vmatrix} = 1 - p_X^2(1) \geq 0$$

$$\det R_3 = \begin{vmatrix} 1 & p_X(1) & p_X(2) \\ p_X(1) & 1 & p_X(1) \\ p_X(2) & p_X(1) & 1 \end{vmatrix} \stackrel{> 0}{=} (1 - p_X^2(2)) \times$$

$$\begin{aligned}
 & \stackrel{> 0}{=} (1 - p_X^2(2)) \times [1 + p_X(2) - 2p_X^2(1)] > 0 \\
 & C_1 \leftarrow C_1 - C_3
 \end{aligned}$$

$$= \begin{vmatrix} 1 - p_X(2) & p_X(1) & p_X(2) \\ 0 & 1 & p_X(1) \\ p_X(2) - 1 & p_X(1) & 1 \end{vmatrix} \text{ puis on développe selon la 1ere colonne}$$



$p_X(1)$ proche de $1 \Rightarrow p_X(2)$ proche de 1

$p_X(2)$ nul $\Rightarrow p_X(1)$ ne pourra jamais être égal à 1 ou -1 , il se balade là

Rmg

* fort + $\text{IE}(X^2) < +\infty \Rightarrow$ faible

* \sum temp gaussienne \Leftrightarrow tous les sous vecteurs extraits sont gaussiens
 \Leftrightarrow pour tout sous vecteur fini, toute U des composantes est gaussienne

\Rightarrow fort = faible

Exemples de processus stationnaires

Définitions d'un bruit blanc :
parasite notre observation

- forte suite va iid entrées et de variance fixe
 $\text{BBF}(0, \sigma^2)$

fort \Rightarrow faible mais ~~pas~~


- faible suite va entrées, de variances fixes et constantes et non corrélatées

$$\text{IE}[\varepsilon_t] = 0, \text{Var}[\varepsilon_t] = \sigma^2, \text{Cov}(\varepsilon_t, \varepsilon_{t+h}) = 0 \quad \forall t \neq t'$$

$$\text{BB}(0, \sigma^2) \quad \text{autocovariance } \gamma_\varepsilon(h) = \begin{cases} \sigma^2 & h=0 \\ 0 & h \neq 0 \end{cases}$$

$$\gamma_{\varepsilon}(\pm 1) = 0$$

$$\Rightarrow \gamma_{\varepsilon}(\pm n) = 0 \text{ (pour } n \neq 0)$$



$$p_{\varepsilon}(h) = \begin{cases} 1 & \text{qd } h=0 \\ 0 & \text{qd } h=\pm n \end{cases}$$

noté MA(1)

Définition d'un processus moyenne mobile d'ordre 1

$$\varepsilon_t \sim BB(0, 6^2)$$

$$X_t = m + \varepsilon_t + \theta \varepsilon_{t-1}, \quad \theta \in \mathbb{R} \quad X_t \text{ est une } \Sigma \text{ temp}$$

- $E[X_t] = m$ ne dépend pas du temps ✓


- $V[X_t] = (1+\theta^2)6^2$ ne dépend pas de t ✓
 $V(a'X)$

- $\text{cov}(X_t, X_{t+1}) = \text{cov}(m + \varepsilon_t + \theta \varepsilon_{t-1}, m + \varepsilon_{t+1} + \theta \varepsilon_t)$
 $= \theta 6^2$ ne dépend pas de t ✓

- $\text{cov}(X_t, X_{t+2}) = \text{cov}(m + \varepsilon_t + \theta \varepsilon_{t-1}, m + \varepsilon_{t+2} + \theta \varepsilon_{t+1})$
 $= 0$

- $\forall t, \forall n \quad \text{cov}(X_t, X_{t+n}) = 0$ ne dépend pas de t ✓
 NB: X_t est bien stationnaire faible

- d'où $\gamma_X(h) = \begin{cases} (1+\theta)6^2 & \text{pour } h=0 \\ \theta 6^2 & \text{pour } h=\pm 1 \\ 0 & \text{pour } h=\pm n \text{ pour } n \notin \{-1, 0, 1\} \end{cases}$



$$|0| \leq 1 \quad p_X(h) = \begin{cases} 1 & h=0 \\ \frac{\theta}{1+\theta^2} & h=\pm 1 \\ 0 & h=\pm n \end{cases}$$

noté AR(1)

Définition d'un processus autorégressif d'ordre 1

$$(\varepsilon_t)_{t \in \mathbb{Z}} \sim BB(0, b^2)$$

$$X_t = \varphi X_{t-1} + \varepsilon_t$$

- $|\varphi| < 1$
- $\text{Cov}(\varepsilon_t, X_{t-i}) = 0 \quad \forall i \geq 1$
- X_t non corrélé au passé de X_t
- (X_t) est stationnaire faible

* $\mathbb{E}[X_t] = \varphi \mathbb{E}[X_{t-1}] = \varphi \mathbb{E}[X_t]$ car faible

$$\Rightarrow (1 - \varphi) \mathbb{E}[X_t] = 0$$

$$\Rightarrow \mathbb{E}[X_t] = 0 \quad \text{car } |\varphi| < 1 \quad \mathbb{E} \text{ ne dépend pas de } t$$

* $\mathbb{V}[X_t] = \mathbb{V}[\varphi X_{t-1} + \varepsilon_t]$

$$= \varphi^2 \mathbb{V}[X_{t-1}] + \underbrace{\mathbb{V}[\varepsilon_t]}_{= b^2} + 2 \text{Cov}(\varphi X_{t-1}, \varepsilon_t)$$

$$= \varphi^2 \mathbb{V}[X_{t-1}] + b^2 + 2 \varphi \times 0$$

$$= \varphi^2 \mathbb{V}[X_t] + b^2$$

par hyp
car faible

$$\Rightarrow (1 - \varphi^2) \mathbb{V}[X_t] = b^2 \Leftrightarrow \mathbb{V}[X_t] = \frac{b^2}{1 - \varphi^2}$$

$|\varphi| < 1$ $\mathbb{V}[X_t]$ ne dépend pas de t

$$\text{Cov}(X_t, X_{t-1}) = \text{Cov}(\varphi X_{t-1} + \varepsilon_t, X_{t-1})$$

$$= \varphi \mathbb{V}[X_{t-1}] + \underbrace{\text{Cov}(\varepsilon_t, X_{t-1})}_{= 0}$$

$$= \varphi \frac{b^2}{1 - \varphi^2}$$

$$\text{Cov}(X_t, X_{t-2}) = \text{Cov}(\varphi X_{t-1} + \varepsilon_t, X_{t-2})$$

$$= \varphi \text{Cov}(X_{t-1}, X_{t-2}) + 0$$


$$= \text{Cov}(X_t, X_{t-1}) \quad \text{NB: c'est le même calcul}$$

$$\Rightarrow \text{cov}(X_t, X_{t-2}) = \varphi^2 \frac{\sigma^2}{1 - \varphi^2}$$

$$\text{cov}(X_t, X_{t-k}) = \varphi^k \frac{\sigma^2}{1 - \varphi^2} \quad \text{ne dépend pas de } t$$

$k \geq 1$

$$\gamma_X(h) = \begin{cases} \frac{\sigma^2}{1 - \varphi^2} & \text{qd } h=0 \\ \varphi^{|h|} \frac{\sigma^2}{1 - \varphi^2} & \text{pour } h \neq 0 \end{cases}$$



$$\begin{aligned} \text{Rmq } X_t &= \varphi X_{t-1} + \varepsilon_t \\ &= \varphi(\varphi X_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \varphi^2 X_{t-2} + \varphi \varepsilon_{t-1} + \varepsilon_t \\ &\stackrel{\text{...}}{=} \varphi^k X_{t-k} + \sum_{i=0}^{k-1} \varphi^i \varepsilon_{t-i} \end{aligned}$$

qd $k \rightarrow +\infty$

$$X_t = \sum_{i=0}^{\infty} \varphi^i \varepsilon_{t-i}$$

mais toute cette remarque manque de précision et de définition mathématique

$$\text{et } \left\{ \begin{array}{l} \mathbb{E}[X_t] = 0 \\ \mathbb{V}[X_t] = \dots \end{array} \right.$$

$$\mathbb{V}[X_t] = \sum_{i=0}^{\infty} \varphi^{2i} \sigma^2 = \frac{\sigma^2}{1 - \varphi^2}$$

Définition d'une marche aléatoire

$X_0 = 0$ condition initiale

$$X_t = X_{t-1} + \varepsilon_t = \sum_{i=1}^t \varepsilon_i$$

$$\mathbb{E}[X_t] = 0$$

$\mathbb{V}[X_t] = t \sigma^2$ dépend de $t \rightarrow$ pas stationnaire

$$\text{cov}(X_t, X_{t-1}) = (\varphi)^2 \sigma^2 \text{ dépend de } t \uparrow$$

pour AR(1) $X_t = \varphi X_{t-1} + \varepsilon_t$ et $|\varphi| < 1$
si $\varphi = 1$ donc processus non stationnaire

21/09/23


Séries temporelles

2 exemples à réperer pour la non stationnarité:

* Marche aléatoire

la variance est linéaire en t

bs on donne une condition initiale et on regarde où le processus va

il croise une ∞ de fois 0

il balaye tout l'espace

Comment le "stationnariser" = rendre stationnaire le processus ? Noté $(X_t)_{t \in \mathbb{N}}$
on fait la déférence (vu en TD 1)

$$Y_t = \Delta X_t = X_t - X_{t-1} = \varepsilon_t \sim BB(0, \sigma^2_\varepsilon)$$


* Modèle avec tendance et variance fonction du temps

Avec la tendance et la variance qui sont fonction du temps

On est sur du non stationnaire déterministe
on voit un processus hétéroscléastique

$$X_t = m(t) + k(t) \varepsilon_t \quad \mathbb{E}[X_t] = m(t)$$

$$\text{deterministes} \quad \mathbb{V}[X_t] = k^2(t) \sigma^2_\varepsilon$$



commentaires

double structure : + et \times et variance \uparrow au cours du tempsStationnarisation de $(X_t)_{t \in \mathbb{N}}$

On centre réduit

$$Y_t = \frac{X_t - m(t)}{k(t)} = \varepsilon_t$$

on identifie $m(t)$ dans les données puis on le retranche à X_t
De même pour $s(t)$

Fin du chapitre 1, à savoir

- * stationnarité faible, * Bruit Blanc Fort et faible
- * identifier 2 formes de non stationnarité

Chapitre 2 Trend et saisonnalité

$$\underline{\text{Hyp}} \quad X_t = m_t + s_t + y_t \quad \begin{matrix} \text{dans ce} \\ \text{chapitre} \end{matrix}$$

m_t trend déterministe	s_t saisonnalité déterministe périodique	y_t Bruit (Blanc) aléatoire
on a donc d valeurs à trouver pour connaître totalement s_t	$S_t = S_t + d$ avec $d \in \mathbb{N}$	$E[Y_t] = 0$ $V(Y_t) = G_y^2$ $\text{cov}(Y_t, Y_{t'}) = 0$ $t \neq t'$
	connu	

On a 1 observation de notre série temporelle
avec un nb fini d'observations temporelles
à une réalisation de notre série

On veut estimer par moindres carrés, sans savoir
les lois mais en ayant des informations sur les
moments, & composantes m_t et s_t
(on trouve le bruit en retranchant m_t et s_t
à l'observation)

méthodes de régression

- régression globale** vs **régression locale**
- 1 régression
sur les données
- plusieurs modèles de
régression sur plusieurs parties
de l'échantillon
ça permet d'avoir une erreur
plus faible mais

on ne pourra pas prédire à long terme, seulement
à court terme / au voisinage de la dernière
observation étudiée

méthodes de filtrage

par des opérateurs (comme en TS)

pour se débarrasser de le trend ou la
saisonalité et trouver l'autre composante

2.1 Régression

Bleys Ballot

de période T dorénavant

$$X_t = \underbrace{m_t}_{\substack{\text{décomposition} \\ \text{additive}}} + \underbrace{s_t}_{\substack{\text{fonctions} \\ \text{connues}}} + \underbrace{y_t}_{\substack{\text{l'valeur} \\ \text{à trouver}}} + \underbrace{\sum_{j=1}^l c_j s_t^{(j)}}_{\substack{\text{fonctions} \\ \text{périodiques} (T) \\ \text{connues}}}$$

paramètre à estimer

Exemple

m_t = polynôme quadratique

s_t = périodique de période 4

$$\begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix}$$

$$X_{(T, 1)} = \begin{pmatrix} x_1 \\ | \\ x_T \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 \\ | & | & | \\ 1 & T & T^2 \\ | & | & | \\ 1 & T & T^2 \end{pmatrix}$$

$$+ \begin{pmatrix} S_1 & S_2 & S_3 & S_4 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \end{pmatrix} + \begin{pmatrix} y_1 \\ | \\ y_T \end{pmatrix}$$

On va noter

$$X_{(T,1)} = M_{(T,k)} \cdot b_{(k,1)} + S_{(T,l)} c_{(l,1)} + \gamma_{(T,1)}$$

$$X_{(T,1)} = D\theta + \gamma_{(T,1)} \quad \text{avec } D = (M, S) \quad \begin{matrix} \text{on met les} \\ \text{paramètres} \\ \text{à estimer} \\ \text{dans le même} \\ \text{vecteur } \theta \end{matrix}$$

$$\theta = \begin{pmatrix} b \\ c \end{pmatrix}$$

$$\mathbb{E}[\gamma] = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}_{(T,1)} \quad \mathbb{V}[\gamma] = \sigma^2 \mathbf{I}_d \quad (T,T)$$

On a X et D on cherche θ .

Est-ce que le modèle est identifiable ?

A partir des observations, on trouve un θ unique pour nos observations X

Avec 2 $\theta \neq$ on obtient 2 modèles \neq

$$\left\{ \theta_1 \neq \theta_2 \Rightarrow \mathbb{E}_{\theta_1}(X) \neq \mathbb{E}_{\theta_2}(X) \right.$$

$$\Leftrightarrow D\theta_1 \neq D\theta_2$$

Par contre posé

$$\left\{ D\theta_1 = D\theta_2 \Rightarrow \theta_1 = \theta_2 \right.$$

$$\Leftrightarrow D(\theta_1 - \theta_2) = 0 \Rightarrow \theta_1 - \theta_2 = 0 \quad \Leftrightarrow \ker D = 0$$

$$\Leftrightarrow \text{rg}(D) = k+l$$

$\Leftrightarrow D^T D$ est inversible

On a écrit la condition d'identifiabilité

on a la somme des colonnes de $S = 1^{\text{re}}$ colonne de M

donc D n'est pas de plein rang

donc le modèle n'est pas identifiable

D'où la contrainte d'identifiabilité

$$\sum_{j=1}^l c_j = 0 \Rightarrow c_l = -\sum_{j=1}^{l-1} c_j \quad \begin{matrix} \text{par effet} \\ \text{de saisonnalité?} \end{matrix}$$

un effet moyen à cycle nul

$$\text{d'én } S_t = \sum_{j=1}^l c_j S_t^{(j)}$$

$$= \sum_{j=1}^{l-1} c_j \left(\underbrace{S_t^{(j)} - S_t^{(k)}}_{= \tilde{S}_t^{(j)}} \right)$$

on réduit d'une dimension

$$\tilde{S}_1 \quad \tilde{S}_2 \quad \tilde{S}_3$$

D'où


$$\tilde{S}_{(T, l-1)} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -1 & -1 & -1 \\ 1 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 1 & 0 & 0 \end{pmatrix}$$

$$c_{(l-1, 1)} = \begin{pmatrix} c_1 \\ c_2 \\ c_3 \end{pmatrix}$$

$$X = \tilde{D} \tilde{\theta} + Y \quad \tilde{\theta} = \begin{pmatrix} b \\ c_1 \\ \vdots \\ c_{l-1} \end{pmatrix} \quad \tilde{D} = (M, \tilde{S})$$

But réécrire pour rentrer dans un cadre classique de minimisation par moindres carrés

X^T = espace d'observation



projection orthogonale de X sur \tilde{D}

\tilde{D} = ev générée par les colonnes de \tilde{D}

$$= \mathbb{R}^{k+l-1}$$

on cherche la C.L qui minimise

la distance
entre X_t et

la CL des fonctions M_t et S_t

$$\text{donc } \hat{\tilde{\theta}} = \underset{\mathbb{R}^{k+l-1}}{\operatorname{argmin}} \| X - \tilde{D} \tilde{\theta} \|^2 = MCO$$

$$\text{MO} \Leftrightarrow \tilde{\mathbf{D}}' (\mathbf{X} - \tilde{\mathbf{D}} \hat{\boldsymbol{\theta}}) = \mathbf{0} \quad \begin{matrix} \text{condition} \\ \text{d'orthogonalité} \end{matrix}$$

$\uparrow \quad \underbrace{\quad}_{(k+l-1, T)} \quad \nwarrow \quad (T, 1)$

$$\text{D'où } \hat{\boldsymbol{\theta}} = (\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}' \mathbf{X}$$

inversible

\Rightarrow cela assure l'unauté et la
bonne définition de $\hat{\boldsymbol{\theta}}$
 \Rightarrow identifiabilité

Propriétés $\hat{\boldsymbol{\theta}}$ BLUE

sans biais et de variance minimale
parmi les estimateurs sans biais

$$\hat{\boldsymbol{\theta}} = (\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}' (\tilde{\mathbf{D}} \hat{\boldsymbol{\theta}} + \mathbf{y})$$

$$= (\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}' \tilde{\mathbf{D}} \hat{\boldsymbol{\theta}} + (\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}' \mathbf{y}$$

$$= \hat{\boldsymbol{\theta}} + (\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}' \mathbf{y}$$

$$\Rightarrow \mathbb{E}[\hat{\boldsymbol{\theta}}] = \hat{\boldsymbol{\theta}} + \underbrace{(\tilde{\mathbf{D}}' \tilde{\mathbf{D}})^{-1} \tilde{\mathbf{D}}'}_{\text{deterministe}} \mathbb{E}[\mathbf{y}] \underset{\text{car bruit}}{=} \mathbf{0}$$

Avantages

On projette au delà de T
sensible par rapport à m_t

2.3 Exemples



- Série 1 nos observations
- Série 2 fond quadratique
- Série 3 fonction périodique
- Série 4 bruit

Série 4 = série 1 - série 2 - série 3
EST que la série 4 est bien du bruit

$$\mathbb{E} = 0 \text{ OK}$$

\mathbb{V} constante OK

Bruit Blanc ? NON

on a pas l'indépendance


on a une autocorrélation forte

$qd > 0$, le terme d'après a bcp de chances
d'être ≥ 0

Tandis que en II, on s'attend à $X_n > 0 \Rightarrow X_{n+1} > 0$

ou ≤ 0 avec autant
de probas


températures à Paris
On suppose trend linéaire décroissant



on alterne beaucoup plus fréquemment dans le bruit
il est plus blanc que l'exemple du CO₂

mais pour la projection on va pas utiliser ce
modèle, d'où l'idée de faire des régressions locales

Méthode STL (régression locale)



avec STL

pour CO_2

trend


Bruit + Blanc

constantes de bruit > 0 se suivent mais pas

autant, donc + d'alternance

pour températures à Paris

trend



projection difficile à imaginer

Bruit bcp d'alternance
donc bien blanc

2.2 Méthodes par moyenne mobile (filtrage)

filtrage linéaire $\Psi: \mathbb{R}^{\mathbb{Z}} \rightarrow \mathbb{R}^{\mathbb{Z}}$
 $(X_t) \mapsto \Psi(X_t)$

Ψ est une transformation
d'une Σ temporelle en

une autre Σ temporelle

$$\Psi(\lambda X_t + \mu Y_t)$$

$$= \lambda \Psi(X_t) + \mu \Psi(Y_t)$$

Pour la structure additive, on peut donc
travailler composante par composante

On va devoir donc trouver les filtres

en sachant qu'on cherche un filtre qui va annuler
/ effacer une composante pour étudier l'autre

Estimation de la saisonnalité

$$\Psi(X_t) = \Psi(m_t) + \Psi(s_t) + \Psi(y_t)$$

$$= o + s_t + \text{on réduit invariant à } 0$$

Ψ_1 ^{le filtre}

NB: j'utilise Σ
comme
raccourci pour
dire « série ».
Ce n'est pas
une notation
du prof.

Estimation du trend

$$\Psi(X_t) = \Psi(m_t) + \Psi(s_t) + \Psi(y_t)$$

$$= m_t + o + o \underset{\approx}{\sim}$$

invariant


Ψ est un 2^e filtre

NB: il est impossible d'annuler le bruit

il sera réduit à 0 / diminué le plus possible.

~~bruit à rendement négatif~~

trend



~~corrélation h 2d avec~~
~~l'émission~~

~~Corrélation entre processus et son filtre~~

$$(P_y + X^T P) \Psi = 2 \quad \text{puisque} \quad P \Psi = 0$$

~~(P\Psi, C\Psi) = 0~~ ~~puisque P est ortho~~

~~puisque P est orthogonal~~

~~puisque P est orthogonal~~

~~puisque P est orthogonal~~

~~puisque P est orthogonal~~

$$(X\Psi + (C\Psi + P\Psi)) = (X\Psi)$$

$$h_{11} \Psi + h_{12} + 0 =$$

~~est de~~ Ψ 0.3 ~~émission~~

11110123

Séries temporelles

Slides 41 / 285

→ 68 / 285

Rappel

$$X_t = m_t + S_t + Y_t$$

trend saisonnalité bruit

déterministe déterministe aléatoire $E[Y_t] = 0$

$\exists d \in \mathbb{N}^*$ $V[Y_t] = \sigma_y^2$

$S_t+d = S_t$ $\text{cov}(Y_t, Y_{t'}) = 0 \quad t \neq t'$

2.2 Méthodes par moyenne mobiles ou de filtrage

$\Psi: \mathbb{R}^{\mathbb{Z}} \rightarrow \mathbb{R}^{\mathbb{Z}}$ opérateur linéaire

$$\hookrightarrow \Psi(\lambda X_t + \mu Y_t) = \lambda \Psi(X_t) + \mu \Psi(Y_t)$$

Objectifs: → Estimation du trend

$$\begin{aligned} \Psi(X_t) &= \Psi(m_t) + \Psi(S_t) + \Psi(Y_t) \\ &= m_t + 0 + \approx 0 \end{aligned}$$

elimine réduit fortement
saisonnalité (impossible éliminer
l'aléatoire)

→ Estimation de la saisonnalité

$$\Psi(X_t) = 0 + S_t + \approx 0$$

M comme moyenne mobile $M: \mathbb{R}^{\mathbb{Z}} \rightarrow \mathbb{R}^{\mathbb{Z}}$

$$MX_t = \sum_{i=-m_1}^{m_2} \alpha_i X_{t+i}$$

entrée = autant de coefficients dans le passé que dans le futur avec autant de poids pour le passé que le futur (pondération uniforme)

$\text{Ker } M = \{(X_t)_{t \in \mathbb{Z}} \mid MX_t = 0\}$ espace vectoriel
sous espace propre associé
à la valeur propre 0

les invariants

$$\text{Inv}(M) = \{(x_t)_{t \in \mathbb{Z}}, Mx_t = x_t\} \quad \underline{\hspace{1cm}} \quad 1$$

$$= \text{Ker}(\underbrace{M - \text{Id}}_{\text{aussi une moyenne mobile}})$$

aussi une moyenne mobile

Comment trouver le noyau d'une moyenne mobile ?

$$\text{Ker } M = \{(x_t)_{t \in \mathbb{Z}}, \sum_{i=-m_1}^{m_2} \theta_i x_{t+i} = 0 \quad \forall t \in \mathbb{Z}\}$$

$$\underbrace{\qquad}_{i=-m_1}$$

$$\theta_{-m_1} x_{t-m_1} + \dots + \theta_{m_2} x_{t+m_2} = 0$$

$$\Leftrightarrow \alpha_0 z_n + \alpha_1 z_{n+1} + \dots + \alpha_p z_{n+p} = 0 \quad \forall n$$

Rappels

$$p=1 \quad \alpha_0 z_n + \alpha_1 z_{n+1} = 0 \quad \Leftrightarrow z_{n+1} = \frac{\alpha_0}{\alpha_1} z_n$$

$$= \beta z_n = \beta^{n+1} z_0$$

$$p=2 \quad \alpha_0 z_n + \alpha_1 z_{n+1} + \alpha_2 z_{n+2} = 0$$

Polynôme associé $P(z) = \alpha_0 + \alpha_1 z + \alpha_2 z^2 \quad p=1$

$$P(z) = 0 \quad \text{pour } p=1$$

$$P(z) = \alpha_0 + \alpha_1 z + \alpha_2 z^2 \quad p=2$$

$\Delta > 0$ β_1, β_2 racines réelles

$$\alpha_0 z^n + \alpha_1 z^{n+1} + \alpha_2 z^{n+2} = z^n (\alpha_0 + \alpha_1 z + \alpha_2 z^2)$$

$$z_n = c_1 \beta_1^n + c_2 \beta_2^n \quad c_1, c_2 \in \mathbb{R} \quad \text{avec les conditions initiales}$$

espace des solutions est pour trouver c_1 et c_2

de dimension 2.

$$z_0 = c_1 + c_2$$

$$z_1 = c_1 \beta_1 + c_2 \beta_2$$

$$\Delta = 0 \quad \beta \text{ racine double} \quad z_n = (c_1 + c_2 n) \beta^n, c_1, c_2 \in \mathbb{R}$$

$\Delta < 0$ racines complexes conjuguées
 $\beta_2 = \overline{\beta_1} = \bar{\beta}$ multiplicité 1

$$\beta = p e^{i\theta} \text{ avec } p > 0 \quad \theta \in [0, 2\pi[$$

$$\begin{aligned} \text{et } \bar{\beta} = p e^{-i\theta} \\ z_n = c \beta^n + \bar{c} \bar{\beta}^n \quad c \in \mathbb{C} \quad c = \mu e^{i\omega} \quad \text{des solutions} \\ = d \operatorname{Re}(c \beta^n) = 2 \mu p^n \cos(n\theta + \omega) \\ = p^n (A \cos n\theta + B \sin n\theta) \quad A, B \\ \cos a+b \\ \cos a \cos b + \sin a \sin b \quad \in \mathbb{R} \end{aligned}$$

Multiplicité $p > 1$ $z_n = \text{polynôme} \times p^n (A \cos n\theta + B \sin n\theta)$

Invariant

Prop 1) Si $\sum_{i=-m_1}^{m_2} \theta_i = 1 \Rightarrow (a) \in \operatorname{Inv} M$ a série temporelle

$$\text{NB } X_t = a \quad \forall t \quad M.a = \left(\sum_{i=-m_1}^{m_2} \theta_i \right) a = a$$

Dans l'invariant on a les constantes les constantes sont conservées

2) Si M symétrique $(\Leftrightarrow m_1 = m_2)$

$$\text{et } \sum \theta_i = 1 \quad \theta_1 = \theta_{-1}$$

M conserve les constantes \Rightarrow les droites sont dans l'invariant

conservées

c'est à dire

$$\Rightarrow M.t = t$$

on considère la série temporelle (t)

$$(X_t = t \quad \forall t)$$

$$\text{d'où } M.X_t = \sum \theta_i X_{t+i}$$

$$= \sum \theta_i (t+i)$$

$$M.t = \sum_{i=-m}^m \theta_i (t+i)$$

$$= t + \sum_{i=-m}^m i \theta_i$$

$$\begin{aligned} \text{on a } & -i \theta_{-i} \\ & = -(i \theta_{-i}) \\ & = -(i \theta_i) \end{aligned}$$

impair donc la $\sum = 0$

Donc $M.t = t$

BBF après passage du filtre

on veut $\frac{6^2 M \epsilon}{6^2 \epsilon}$ le plus petit possible c'est à dire $\sum_{j=-m_1}^{m_2} \theta_j^2$

quelle est la moyenne mobile qui

- conserve les constantes
- conserve les droites
- réduit le + possible

$$\frac{6^2 M \epsilon}{6^2 \epsilon}$$

$$\theta_j^2$$

elle qui satisfait pb d'optimisation suivant

$$\begin{aligned} & \min_{\theta} \sum_{j=-m}^m \theta_j^2 \\ & \text{s.t.} \\ & \sum_{j=-m}^m \theta_j = 1 \end{aligned}$$

$$\text{c'est } \theta_j = \frac{1}{2m+1} \quad \forall j \in [1, m]$$

La moyenne mobile arithmétique MMA

$$M X_t = \frac{1}{2m+1} \sum_{i=-m}^m X_{t+i} \quad \text{Ker } M?$$

$$\frac{1}{2m+1} X_{t-m} + \dots + \frac{1}{2m+1} X_{t+m} = 0$$


$$\begin{aligned} P(z) &= \frac{1}{2m+1} (1 + z + \dots + z^{2m}) \\ &= \frac{1}{2m+1} \frac{1-z^{2m+1}}{1-z} \quad \left(= \frac{Q(z)}{R(z)} \right) \end{aligned}$$

$$Q(z) = 0 \Leftrightarrow z^{2m+1} = 1 \Leftrightarrow z = e^{i \frac{2\pi j}{2m+1}}, \quad j \in [0, 2m]$$

$$\text{d'où } P(z) = 0 \Leftrightarrow j \in [1, 2m]$$

on aura m racines

et m racines conjuguées



$$\text{donc } z_n = \sum_{j=1}^m \left(\alpha_j \cos\left(\frac{2\pi j}{2m+1} n\right) + \beta_j \sin\left(\frac{2\pi j}{2m+1} n\right) \right)$$

\Rightarrow ∀ les fonctions périodiques de période $2m+1$

MMA élimine les fonctions périodiques de période impaire.

Comment éliminer celles de période paire ?

avec une moyenne de moyenne mobile arithmétique
qui conserve les droites et annule les fonctions périodiques de période paire.

→ devient symétrique

Lissage

trend polynôme de degré 2 ok

si $\geq \deg 2$ on veut lisser le plus possible.

- (4) output produit pour le trend soit le - erratique
- 5) simplicité des coefficients = nb de calculs
+ m est grand, + on perd de l'information au début et à la fin

slide 531-285

gênant car on veut faire de la prévision

En pratique

construction successive moyenne mobile pour éliminer le trend et la saisonnalité

$$\hat{m}_t \text{ estimateur après le passage de MM} \\ = M_0 X_t \quad (m_t + \approx \text{bruit})$$

$I_d - M_0$ appliquée à m_t
puis à X_t
pour retrouver la constante

Exemple nb termes $\theta_2 \quad \theta_1$
 ordre 4 $\Rightarrow m=2$ J $\theta_{-2} \quad \theta_{-1} \quad \theta_0$
 choix naturel $\{[5], \frac{1}{8}[1, 2, 2]\}$

$$\begin{aligned} & \frac{1}{4} (0,5x_{t-2} + x_{t-1} + x_t + x_{t+1} + 0,5x_{t+2}) \\ & = \frac{1}{6} 0,5 (x_{t-2} + 2x_{t-1} + 2x_t + 2x_{t+1} + x_{t+2}) \\ & = \frac{1}{8} (—) \end{aligned}$$

MM de Henderson (la meilleure pour le biseage)

12/10/23 Série temporelle

slides 69/285
à 115/285

Chapitre 3 Procédés linéaires

Objectif : autre caractérisation des séries temporelles

 $\mathcal{X}^2 = \{x \text{ de carré intégrable}$

$$= \{x : \mathbb{E}[x^2] < +\infty\}$$

3.1 L'espace $L^2(\Omega, \mathcal{A}, \mathbb{P})$: définition et propriétésEspace vectoriel $x, y \in \mathcal{L}^2$

$$\mathbb{E}[(x+y)^2] = \underbrace{\mathbb{E}[x^2]}_{<+\infty} + \underbrace{\mathbb{E}[y^2]}_{<+\infty} + 2 \underbrace{\mathbb{E}[xy]}_{<+\infty}$$

$$|\mathbb{E}[xy]| \leq \sqrt{\mathbb{E}[|xy|]} \leq \sqrt{\mathbb{E}[x]\mathbb{E}[y]} < +\infty$$

Norme $\|x\| = \sqrt{\mathbb{E}[x^2]}$

1) $\|x\| = 0 \Rightarrow x = 0$ ps

2) $\|\lambda x\| = |\lambda| \|x\|$

3) $\|x+y\|^2 \leq \|x\|^2 + \|y\|^2 + 2\sqrt{\|x\|^2\|y\|^2}$

$$\leq (\|x\| + \|y\|)^2 \text{ inégalité triangulaire}$$

On a donc un espace vectoriel normé

$d(x, y) = \|x - y\|$ distance

$\langle x | y \rangle = \mathbb{E}[xy]$ produit scalaire

orthogonal à

$X \perp Y \text{ si } \mathbb{E}[XY] = 0$

- i) bilinéaire symétrique on
ii) définie positive

 \mathcal{X}^2 est donc un espace vectoriel normé complet (Banach) $x_n \xrightarrow[n \rightarrow +\infty]{L^2} x$ si $\|x_n - x\| \rightarrow 0$ ($\Rightarrow x \in \mathcal{L}^2$)
 $\xrightarrow{\text{def}}$ de la convergence L^2 $X_n = \sum_{i=1}^n y_i$, $y_i \in \mathcal{L}^2$ quelle est la limite de X_n ?

Toute série absolument convergente est convergente

$$\sum_{i=1}^{\infty} \|y_i\| < +\infty \Rightarrow \sum_{i=1}^n y_i \in \mathcal{X}^2$$

$y = \sum_{j \in \mathbb{Z}} a_j x_j$ bien définie si $\sum_{j \in \mathbb{Z}} |a_j| |x_j| < +\infty$

avec $(a_j)_{j \in \mathbb{Z}} \in \mathbb{R}^{\mathbb{Z}}$

$$= \sum_{j \in \mathbb{Z}} |a_j| |x_j|$$

Rmq $(X_t)_{t \in \mathbb{Z}}$ stationnaire (faible)

$$\|X_j\| = \sqrt{\mathbb{E}[X_j^2]} = \sqrt{\mathbb{V}[X_j] + \mathbb{E}[X_j^2]} \\ = \|X\|$$

y existe si $\sum_{j \in \mathbb{Z}} |a_j| < \infty$

Definition moyenne mobile

$$(X_t)_{t \in \mathbb{Z}} \xrightarrow{(a_j)_{j \in \mathbb{Z}} / \sum_{j \in \mathbb{Z}} |a_j| < +\infty} (Y_t)_{t \in \mathbb{Z}}$$

$$Y_t = \sum_{j \in \mathbb{Z}} a_j X_{t-j}$$

en t on utilise ce qui se passe dans

le futur (j négatif) X_{t+1}, X_{t+2}, \dots

or on a que l'information dans le passé!

$(X_t)_{t \in \mathbb{Z}}$ stationnaire faible $\mathbb{E}[X_t] = \mu_x$

$$\text{IT+Fubini } \text{Cov}(X_t, X_{t-h}) = Y_X(h)$$

$$\mathbb{E}[Y_t] \leq \sum_{j \in \mathbb{Z}} |a_j| \underbrace{\mathbb{E}[|X_{t-j}|]}_{\text{ne dépend pas du temps}} < +\infty \text{ par hypothèse sur les } a_j$$


on peut donc permute \mathbb{E} et $\sum_{j \in \mathbb{Z}}$ par Fubini

$$\mathbb{E}[Y_t] = \sum_{j \in \mathbb{Z}} a_j \mathbb{E}[X_{t-j}] = \left(\sum_{j \in \mathbb{Z}} a_j \right) \mu_x$$

$$\text{Cov}(Y_t, Y_{t-h}) = \text{Cov}\left(\sum a_j X_{t-j}, \sum a_i X_{t-h-i}\right)$$

$$= \sum_j \sum_i a_j a_i \gamma_x(h+i-j)$$

3.2 Régression linéaire au sens théorique sur un nombre fini de retards Fubini



$\exists ! X^* \in H /$

$$\min_{Y \in H} \|X - Y\| = \|X - X^*\|$$

$Y \in \text{Vect}(z_1, z_2, \dots, z_n)$

$Y = \sum a_j z_j$

$$\text{avec } X^* = \sum a_j^* z_j \quad | \quad \forall j \quad (X - X^*) \perp z_j$$

$$\Leftrightarrow \mathbb{E}[(X - X^*) z_j] = 0$$

On va trouver les a_j^*

$$H = \text{Vect}(z_0, z_1, \dots, z_n) \quad Z = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix} \in \mathbb{R}^n \quad \overset{j=1}{z_0 \text{ est une constante}} \quad (\forall = 0)$$

$$X^* = \sum_{j=0}^n a_j^* z_j$$

Conditions d'orthogonalité ($n+1$)

$$\begin{aligned} i=0 \quad \mathbb{E}[(X - X^*) 1] &= 0 \quad (\Rightarrow \mathbb{E}[X] = \mathbb{E}[X^*]) \\ &= a_0^* + \sum_{j=1}^n a_j^* \mathbb{E}[z_j] \\ &\stackrel{(1)}{=} a_0^* + (a^*)' \mathbb{E}[Z] \end{aligned}$$

$$i \in [1, n] \quad \mathbb{E}[(X - X^*) z_i] = 0 \quad (\Rightarrow \mathbb{E}[X z_i] = \mathbb{E}[X^* z_i])$$

$$\stackrel{(2)}{=} a_0^* \mathbb{E}[z_i] + \sum_{j=1}^n a_j \mathbb{E}[z_j z_i]$$

$$(2) = \mathbb{E}[z_i] (1)$$

$$\Leftrightarrow \text{Cov}(X, z_i) = \sum_{j=1}^n a_j^* \text{Cov}(z_i, z_j)$$

$$\Leftrightarrow \underbrace{\text{Cov}(X, z)}_{(n, 1)} = \underbrace{\mathbb{V}[z]}_{(n, n)} \underbrace{a^*}_{(n, 1)}$$

$$\Leftrightarrow a^* = \mathbb{V}[z]^{-1} \text{Cov}(z, X)$$


$$\begin{aligned} X^* &= a_0^* + (a^*)' z = \mathbb{E}[X] - (a^*)' \mathbb{E}[z] + a^* z \\ &= \mathbb{E}[X] + (a^*)' (z - \mathbb{E}[z]) \\ &= \mathbb{E}[X] + \text{Cov}(X, z) \mathbb{V}[z]^{-1} (z - \mathbb{E}[z]), \end{aligned}$$

Rmq $\mu = \mathbb{E}(z_1, \dots, z_n)$ (sans la constante)

$X^* = \text{Cov}(X, z) \mathbb{V}[z]^{-1} z$

si elles sont centrées pas besoin de la constante

ce qui on fera tout le temps ensuite



$$\mu = \mathbb{E}(X_{t-1}, \dots, X_{t-p})$$

$$X = \begin{pmatrix} X_t \\ | \\ X_{t-1} \\ | \\ X_{t-p} \end{pmatrix}_{(p, 1)}$$

$$X_t^* = \mathbb{E}[X_t | X_{t-1}, \dots, X_{t-p}]$$

$$Z = \begin{pmatrix} X_{t-1} \\ | \\ X_{t-p} \end{pmatrix}$$

$$\mathbb{V}[z] = \begin{pmatrix} \gamma_X(0) & \gamma_X(1) & \dots & \gamma_X(p-1) \\ \gamma_X(1) & \gamma_X(0) & & \\ & \ddots & \ddots & \\ & & \gamma_X(p) & \end{pmatrix}_{(p, p)}$$

$$\text{Cov}(X, Z) = \begin{pmatrix} \gamma_X(1) \\ | \\ \gamma_X(p) \end{pmatrix}$$

$(X_t) = (\varepsilon_t)$ Bruit Blanc Faible

non corrigée

$$\mathbb{E}[\varepsilon_t] = 0$$

= pas d'information

$$\mathbb{V}[\varepsilon_t] = \sigma^2_\varepsilon$$

disponible du passé

$$\text{Cov}(\varepsilon_t, \varepsilon_{t'}) = 0 \quad \forall t \neq t'$$

$$\mathbb{E}L[\varepsilon_t | \varepsilon_{t-1}, \dots, \varepsilon_{t-p}] = 0 \quad \text{et pas prévisible ! (bruit)}$$

3.3 Régression linéaire théorique sur un nombre ∞ de retards

Notations tout le passé

$$\underline{X_{t-1}} = \text{ev}(X_{t-1}, X_{t-2}, X_{t-3}, \dots)$$

$$\mathbb{E}L[X_t | \underline{X_{t-1}}] = \sum_{j=1}^{\infty} a_j^* X_{t-j}$$

$$\text{car } \lim_{p \rightarrow +\infty} \mathbb{E}L[X_t | X_{t-1}, \dots, X_{t-p}] = \sum_{j=1}^{\infty} a_j^* X_{t-j}$$

(preuve non démontrée)


par Banach

$$\text{car } \sum_{j=1}^{\infty} |a_j| < +\infty$$

Déf

$$\varepsilon_t = X_t - \mathbb{E}L[X_t | \underline{X_{t-1}}]$$

erreur de prévision



ε_t est l'innovation de $(X_t)_{t \in \mathbb{Z}}$ à la date t .

- est "non prévisible à partir du passé"

Prop i) $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc faible

ii) $\varepsilon_t \perp \underline{X_{t-1}}$ (voir ^{voir} _{demin})

on ne peut rien apprendre du passé ni on a fait la meilleure prédition

iii) Théorème de WOLD

tout processus non linéaire a une repr linéaire
on peut donc toujours travailler en linéaire

$m_x + \sum_{k=0}^{\infty} a_k \varepsilon_{t-k}$ mise à jour uniquement sur
le passé !!

coefficients d'autocorrélation partielle

car on enlève de l'information

$$\tilde{X}_t = X_t - \text{IEL}[X_t | X_{t-1}, \dots, X_{t-k-1}]$$

car on enlève l'information intermédiaire entre X_{t-k} et X_t

$$\rho(k) = \text{Cor}(\tilde{X}_t, \tilde{X}_{t-k}) \quad (\text{Rappel } p_X(k) = \text{Cor}(X_t, X_{t-k}))$$

$k=1$ il n'y a rien entre $t-1$ et t
donc on projette sur rien

$$\rho_X(1) = p_X(1)$$

$$\rho_X(k) = \frac{\begin{vmatrix} p_X(0) & p_X(1) & \cdots & p_X(k-1) \\ p_X(1) & p_X(0) & \cdots & \vdots \\ \vdots & \vdots & \ddots & p_X(1) \\ p_X(k-1) & \vdots & \cdots & p_X(0) \end{vmatrix}}{\begin{vmatrix} p_X(0) & p_X(1) \\ p_X(1) & p_X(0) \end{vmatrix}}$$


même matrice
sauf pour la
dernière colonne

$k=2$

$$\rho_X(2) = \frac{\begin{vmatrix} p_X(0) & p_X(1) & p_X(0) \\ p_X(1) & p_X(2) & p_X(1) \\ p_X(0) & p_X(1) & p_X(0) \end{vmatrix}}{\begin{vmatrix} p_X(0) & p_X(1) \\ p_X(1) & p_X(0) \end{vmatrix}}$$

$$\text{IEL}[X_t | X_{t-1}, \dots, X_{t-k-1}, X_{t-k}] = \sum_{j=1}^k a_j X_{t-j}$$

Prop $a_k = \rho(k)$



$$(1) \quad X_t = \sum_{j=1}^k a_j X_{t-j} + \varepsilon_t$$

projection (linéaire)

$$(2) \quad \text{LEL}[X_t | X_{t-1}, \dots, X_{t-k-1}] = \sum_{j=1}^{k-1} a_j X_{t-j} + a_k \text{LEL}[X_{t-k} | X_{t-1}, \dots, X_{t-k-1}]$$

+ 0

(car ε_t orthogonal à n'importe quel élément sur lequel on projette CL de l'espace n'importe quelle

$$(1) - (2) \quad \tilde{X}_t = a_k \tilde{X}_{t-k} + \varepsilon_t$$

on multiplie par \tilde{X}_{t-k} puis on applique l'IE

$$\text{Cov}(\tilde{X}_t, \tilde{X}_{t-k}) = a_k \mathbb{V}(\tilde{X}_{t-k}) + 0$$

$$\Rightarrow a_k = \frac{\text{Cov}(\tilde{X}_t, \tilde{X}_{t-k})}{\mathbb{V}(\tilde{X}_t)^{1/2} \mathbb{V}(\tilde{X}_{t-k})} = \text{Cor}(\tilde{X}_t, \tilde{X}_{t-k})$$

$\text{cov}(\varepsilon_t, \tilde{X}_{t-k})$
CL de
 $X_{t-1}, \dots, X_{t-k-1}$

$$\mathbb{V}[\tilde{X}_t] = \mathbb{V}[\tilde{X}_{t-k}]$$

et $\varepsilon_t \perp X_{t-1} \dots X_{t-k-1}$

$(X_t) = (\varepsilon_t)$ Bruit Blanc Faible

$$\tilde{\varepsilon}_t = \varepsilon_t - \underbrace{\mathbb{E}[\varepsilon_t | \varepsilon_{t-1}, \dots, \varepsilon_{t-k-1}]}_0$$

$$\tilde{\varepsilon}_{t-k} = \varepsilon_{t-k} - \underbrace{\mathbb{E}[\varepsilon_{t-k} | \varepsilon_{t-1}, \dots, \varepsilon_{t-k-1}]}_0$$

$$\gamma_X(k) = \text{Cov}(\tilde{\varepsilon}_t, \tilde{\varepsilon}_{t-k}) = \text{Cor}(\tilde{\varepsilon}_t, \tilde{\varepsilon}_{t-k}) = 0 \quad \forall k \geq 1$$

C'est une autre façon de caractériser le bruit blanc faible
Seul lui a une covariance partielle nulle
corrélation

3.4 Densité spectrale et autocorrelations inverses

On prend $\mathbb{E}[X_t] = 0$

donc $\forall X_t$, on peut écrire $X_t = \sum_{j \in \mathbb{Z}} a_j \varepsilon_{t-j}$

avec $(\varepsilon_t) \sim \mathcal{B}B(0, \sigma^2_\varepsilon)$

$$\sum_{j \in \mathbb{Z}} |a_j| < \infty.$$

* $\mathbb{E}[X_t] = 0$

* $\gamma_X(h) = \text{Cov}(X_t, X_{t-h})$
 $= \text{Cov}\left(\sum_j a_j \varepsilon_{t-j}, \sum_i a_i \varepsilon_{t-h-i}\right)$

$$= \sum_j \sum_i a_j a_i \text{Cov}(\varepsilon_{t-j}, \varepsilon_{t-h-i})$$

$$= \sum_j \sum_i a_j a_i \underbrace{\gamma_\varepsilon(h+i-j)}_{=0 \text{ sauf si } h+i-j=0} = \sum_i a_i a_{h+i} \sigma^2_\varepsilon$$

ou plus haut
haut
(sa donne la variance)

on somme sur \mathbb{Z} ici

$$\sum_h |\gamma_x(h)| = \sum_h \left| \sum_i a_i a_{i+h} \right|^2 \sigma_\varepsilon^2$$

$$\leq \left(\sum_{i,h} |a_i| |a_{i+h}| \right) \sigma_\varepsilon^2$$

$$= \left(\sum_i |a_i| \right)^2 \sigma_\varepsilon^2 < +\infty$$

CDV $i+h = j$

puis on sépare
les sommes

$$f_x(\omega) = \frac{1}{2\pi} \sum_{h \in \mathbb{Z}} \gamma_x(h) e^{i\omega h} \quad \omega \in]-\pi, \pi[$$

$$|f_x(\omega)| \leq \frac{1}{2\pi} \sum_{h \in \mathbb{Z}} |\gamma_x(h)| < +\infty.$$

donc f_x est bien définie

f_x est réelle.

$$f_x(x) = \frac{1}{2\pi} \sum_{h \in \mathbb{Z}} \underbrace{\gamma_x(h)}_{\substack{\text{pair} \\ \text{pair}}} (\cos(\omega h) + i \sin(\omega h))$$

$\sum_{h \in \mathbb{Z}} \gamma_x(h) i \sin(\omega h) = 0$
vont s'annuler

car impaire

$$f_x(\omega) = f_x(-\omega)$$

on peut donc juste la définir sur $[0, \pi[$

(sur $]-\pi, 0[$ on aura
en faisant $-\omega$)

$$\text{Prop } \gamma_x(h) = \left[\int_{-\pi}^{\pi} f_x(\omega) \cos(\omega h) d\omega \right] + \int_{-\pi}^{\pi} i f_x(\omega) \sin(\omega h) d\omega$$


$$\text{Preuve } (*) = \int_{-\pi}^{\pi} f_x(\omega) e^{i\omega h} d\omega = 0 \text{ car impair}$$

$$= \int_{-\pi}^{\pi} f_x(\omega) e^{-i\omega h} d\omega \quad \text{CDV } x = -\omega \text{ mais } f \text{ paire}$$

$$= \int_{-\pi}^{\pi} \left(\frac{1}{2\pi} \sum_k \gamma_x(k) e^{ik\omega} \right) e^{-i\omega h} d\omega$$

$$= \frac{1}{2\pi} \sum_k \gamma_x(k) \int_{-\pi}^{\pi} e^{i\omega(k-h)} d\omega$$

$$= \frac{1}{2\pi} 2\pi \gamma_x(h) = \gamma_x(h) \quad = 0 \text{ quand } k \neq h \\ = 2\pi \text{ quand } k = h \blacksquare$$



on a $\int_{-\pi}^{\pi} e^{i\omega(k-h)} dw = 0$
 quand $k \neq h$ car
 les intégrales
 en \cos et \sin
 sont nulles

sinus:

$$\int_{-\pi}^{\pi} = \text{aire sous la courbe}$$

$$\int_{-\pi}^{\pi} = \oplus + \ominus = 0$$

cosinus

$$\int_{-\pi}^{\pi} = \text{aire sous la courbe} = \oplus + \ominus + \ominus = 0$$

à droite de 0 à gauche de 0

Exemple 1

$$(X_t) = (\varepsilon_t) + (\varepsilon_t) BB(\text{faible})$$

$$\gamma_{\varepsilon}(h) = 0 \quad h \neq 0$$

$$f_X(w) = \frac{1}{2\pi} \sum_h \gamma_{\varepsilon}(h) \cos(wh)$$

$$= \frac{1}{2\pi} \gamma_{\varepsilon}(0) = \frac{6\varepsilon^2}{2\pi} \text{ ne dépend pas de } \omega !$$

Seul le bruit blanc faible a une densité spectrale constante

Exemple 2

$$MA(1) \quad X_t = \varepsilon_t + \theta \varepsilon_{t-1} \quad (\varepsilon_t) \sim BB(0, \sigma^2_{\varepsilon})$$

$$\gamma_X(0) = (1 + \theta^2) \sigma^2_{\varepsilon}$$

$$\gamma_X(1) = \theta \sigma^2_{\varepsilon}$$

$$\gamma_X(2) = 0 \quad \text{car pas de terme en commun}$$

$$\gamma_X(h) = 0 \quad h > 2$$

$$f_X(w) = \frac{1}{2\pi} (\gamma_X(0) + \gamma_X(1) 2 \cos(w))$$

$$= \frac{1}{2\pi} \sigma^2_{\varepsilon} ((1 + \theta^2) + 2\theta \cos w)$$

$$= A + B \cos w.$$

Seule une MA(1) a une densité spectrale

$$A + B \cos w.$$

Exemple 3

$$(X_t) \xrightarrow{(a_i)} Y_t = \sum_{j \in \mathbb{Z}} a_j X_{t-j} \text{ avec } \sum_{j \in \mathbb{Z}} |a_j| < +\infty$$

$f_X \xleftarrow{\text{relations?}} f_Y$

on peut écrire γ_Y

$$\gamma_X \xrightarrow[\text{en fonction de } \gamma_X]{\quad} \gamma_Y(h) = \sum_{i,j} a_i a_j \gamma_X(h+j-i)$$

$$f_Y(\omega) = \frac{1}{2\pi} \sum_h \gamma_Y(h) e^{i\omega h}$$

$$= \frac{1}{2\pi} \sum_h \sum_l \sum_j a_l a_j \gamma_X(h+j-l) e^{i\omega h} e^{i\omega(j-l)} \\ \times e^{-i\omega j} \times e^{i\omega l}$$

$$= \frac{1}{2\pi} \sum_h \left[\sum_l \sum_j a_l a_j \gamma_X(h+j-l) e^{i\omega(h+j-l)} \right] e^{-i\omega j} e^{i\omega l}$$

$$= f_X(\omega) \underbrace{\sum_l a_l e^{i\omega l}}_z \underbrace{\sum_j a_j e^{-i\omega j}}_{\bar{z}}$$

$z \times \bar{z} \rightarrow \text{avec } z \in \mathbb{C} : z\bar{z} = |z|^2$

$$= f_X(\omega) \left| \sum_l a_l e^{i\omega l} \right|^2$$

on pose
 $A(u) = \sum_l a_l u^l$

$$= f_X(\omega) |A(e^{i\omega})|^2$$

en série entière

Application MA(1) $X_t = \varepsilon_t + \theta \varepsilon_{t-1}$

$$a_0 = 1 \quad a_1 = \theta \quad a_j = 0 \text{ sinon}$$

détails :

$$f_X(\omega) = f_\varepsilon(\omega) \left| 1 + \theta e^{i\omega} \right|^2$$

$(1 + \theta \cos \omega)^2 + \theta^2 \sin^2 \omega$

$$= \frac{\sigma_\varepsilon^2}{2\pi} \left((1 + \theta \cos \omega)^2 + \theta^2 \sin^2 \omega \right)$$

$= 1 + 2\theta \cos \omega + \theta^2 \cos^2 \omega + \theta^2 \sin^2 \omega = \theta^2$

$$= \frac{\sigma_\varepsilon^2}{2\pi} (1 + 2\theta \cos \omega + \theta^2)$$

slides
84 / 285
à
129 / 285

25/10/23

Séries temporelles.

3. 4) Densité spectrale et autocorrélation inverses

innovation = erreur de prédiction basée sur tout l'historique du processus

c'est la ϵ entre la prédiction et toutes les informations du passé

transformée de Fourier = densité spectrale du processus stationnaire

on peut avoir la densité spectrale de X

quand $X_t = \sum \psi_j Y_{t-j}$ avec $(Y_t)_{t \in \mathbb{Z}}$ de densité spectrale f_Y

$$f_X(u) = |\Psi(e^{i\omega})|^2 f_Y(\omega) \quad \Psi(u) = \sum_j \psi_j u^j$$

(norme au carré)

auto régresif d'ordre 1

Exemples

a) AR(1) $X_t = \varphi X_{t-1} + \varepsilon_t$ avec $(\varepsilon_t)_{t \in \mathbb{Z}} \sim \mathcal{N}(0, \sigma_\varepsilon^2)$

$$\mathbb{E}[X_t] = 0$$

$$\gamma_X(h) = \varphi^{|h|} \frac{\sigma_\varepsilon^2}{1-\varphi^2} \Rightarrow f_X(u) = \frac{1}{2\pi} \sum_{h \in \mathbb{Z}} \gamma_X(h) e^{iwh}$$

(calcul à faire !)

on inverse le rôle entre

le bruit et le processus $\varepsilon_t = X_t - \underbrace{\varphi X_{t-1}}_{\phi_0=1 \quad \phi_1=-\varphi}$ on crée une série avec un nombre de termes défini

$$\phi(u) = 1 - \varphi u \quad (\varphi \text{ avec 2 termes : } \phi(u) = \sum_j \phi_j u^j)$$

$$\begin{aligned} f_\varepsilon(u) &= \underbrace{|\phi(e^{i\omega})|^2}_{\text{norme}} f_X(u) \Rightarrow f_X(u) = \frac{\sigma_\varepsilon^2}{2\pi} \frac{1}{1 - 2\varphi \cos \omega + \varphi^2} \\ &= \frac{\sigma_\varepsilon^2}{2\pi} \frac{1}{1 - 2\varphi \cos \omega + \varphi^2} \end{aligned}$$

la densité spectrale caractérise AR(1)

Définition Autocorrelations inverses

$$(X_t)_{t \in \mathbb{Z}} \Leftrightarrow (\gamma_X(h))_{h \in \mathbb{Z}} \Leftrightarrow f_X(\omega) = \frac{1}{2\pi} \sum_{h \in \mathbb{Z}} \gamma_X(h) e^{i\omega h}$$

$$(Y_t)_{t \in \mathbb{Z}} \Leftrightarrow \gamma_Y(h) = \int_{-\pi}^{\pi} f_Y(\omega) e^{-i\omega h} d\omega \Leftrightarrow f_Y(\omega) = \frac{1}{f_X(\omega)}$$

$$\rho_Y(h) = \text{Corr}(Y_t, Y_{t-h}) = \rho_X^i(h)$$

autocorrélation inverse.

Exemple

MA(1)

$$X_t = \varepsilon_t + \theta \varepsilon_{t-1} \Leftrightarrow$$

$$\begin{cases} \gamma_X(0) = (1+\theta^2)\sigma_\varepsilon^2 \\ \gamma_X(1) = \gamma_X(-1) = \theta \sigma_\varepsilon^2 \\ \gamma_X(h) = 0 \text{ sinon} \end{cases}$$

$$\Leftrightarrow f_X(\omega) = \frac{\sigma_\varepsilon^2}{2\pi} (1 + 2\theta \cos \omega + \theta^2)$$

$$f_Y(\omega) = \frac{1}{f_X(\omega)} = \underbrace{\frac{1}{2\pi}}_{\substack{\uparrow \\ \text{on a un AR(1)}}} \frac{(2\pi)^2}{\sigma_\varepsilon^2} \frac{1}{1 + 2\theta \cos \omega + \theta^2}$$

on fait apparaître 2π au dénominateur

on a un AR(1)

en identifiant

$$\varphi = -\theta$$

$$Y_t = \varphi Y_{t-1} + \eta_t = -\theta Y_{t-1} + \eta_t$$

$$\Rightarrow Y_t = -\theta Y_{t-1} + \eta_t \text{ où } (\eta_t) \sim \mathcal{N}(0, \sigma_\eta^2) \text{ en identifiant } \sigma_\eta^2 = \frac{(2\pi)^2}{\sigma_\varepsilon^2}$$

$$\text{D'où } \rho_X^i(h) = \rho_Y(h) = (-\theta)^{|h|}$$

fonction

d'autocorrélation d'un AR(1)

La fonction d'autocorrélation inverse caractérise le processus
(si $\rho_X^i(h) = c \text{e}^{-|h|} \Rightarrow X \text{ MA(1)}$)

MA(1)

En pratique, comment on fait ?

(X_t) IID $\mathbb{E}[X_t] = \mu_x$? on a nos observations

$$x_1, \dots, x_T$$

notre estimateur sera la moyenne empirique

$$\hat{\mu}_{x,T} = \frac{1}{T} \sum_{t=1}^T X_t$$

SB $\Rightarrow \mathbb{E}[\hat{\mu}_{x,T}] = \mu_x$
converge $\Rightarrow \mathbb{V}[\hat{\mu}_{x,T}] \xrightarrow[T \rightarrow +\infty]{} 0$

$$\mathbb{V}[\hat{\mu}_{x,T}] = \frac{1}{T} \mathbb{V}[X_1] \text{ car iid.}$$

$$\xrightarrow[T \rightarrow +\infty]{} 0. \text{ (bien convergent)}$$

$$\sqrt{T}(\hat{\mu}_{x,T} - \mu_x) \xrightarrow[T \rightarrow +\infty]{\mathcal{L}} N(0, \mathbb{V}[X_1]) \text{ par TCL.}$$

résultat utile pour les intervalles de confiance et les tests d'égalité.

Rappel

erreur de 1^{er} espèce on accepte H_1 alors que c'est H_0 qui est vraie
erreur de 2^{er} espèce on accepte H_0 alors que c'est H_1 qui est vraie

tout cela repose sur l'hyp iid

puissance du test = $1 - \underbrace{\alpha}_{\text{risque}} = 1 - \text{erreur de 2^{er} espèce}$

alors que nous

on sera pas indépendant avec nos séries temporelles

3.5 Estimation de la moyenne et des autocovariances pour des processus linéaires

$$X_t = \sum_j a_j \varepsilon_{t-j} \text{ avec } \sum_j |a_j| < +\infty \text{ et } (\varepsilon_t)_{t \in \mathbb{Z}} \sim BB(0, 6\varepsilon)$$

On a nos observations x_1, \dots, x_T

$$\bar{X}_T = \frac{1}{T} \sum_{t=1}^T X_t \xrightarrow[T \rightarrow +\infty]{\mathcal{L}} 0 \Leftrightarrow \mathbb{V}[\bar{X}_T] \xrightarrow[T \rightarrow +\infty]{} 0$$

(éclatement)

$$\mathbb{V}[\bar{X}_T] = \frac{1}{T^2} \left(\sum_{t=1}^T \mathbb{V}[X_t] + 2 \sum_{1 \leq t \leq t' \leq T} \text{cov}(X_t, X_{t'}) \right)$$

matrice de variance covariante

$$\mathbb{V} \begin{pmatrix} X_1 \\ | \\ X_T \end{pmatrix} = \begin{pmatrix} \gamma_X(0) & \gamma_X(1) & \gamma_X(2) & \dots & \gamma_X(T-1) \\ \vdots & \ddots & & & \gamma_X(2) \\ & & \ddots & & \gamma_X(1) \\ & & & \ddots & \gamma_X(0) \end{pmatrix}$$

on somme
en colonne

$$\text{D'où } T\mathbb{V}[\bar{X}_T] = \gamma_X(0) + \frac{2}{T} \sum_{k=1}^T (T-k)\gamma_X(k)$$

$$= \gamma_X(0) + \frac{2}{T} \sum_{h=1}^{T-1} \sum_{j=1}^k \gamma_X(j)$$

$$\text{on pose } \beta_k = \sum_{j=1}^k \gamma_X(j) \xrightarrow[k \rightarrow +\infty]{} \sum_{j=1}^{+\infty} \gamma_X(j)$$

$$\text{D'où } T\mathbb{V}[\bar{X}_T] \xrightarrow{k \rightarrow +\infty} \gamma_X(0) + \frac{2}{T} \sum_{h=1}^{T-1} \beta_h \xrightarrow{T \rightarrow +\infty} \gamma_X(0) + 2\beta_\infty$$

c'est le lemme de Cesaro.

[si une Σ converge alors la moyenne des Σ
aussi et vers la même limite]

$$\text{avec } \beta_\infty = \sum_{h \in \mathbb{Z}} \gamma_X(h)$$

$$\Rightarrow \mathbb{V}[\bar{X}_T] \underset{T \rightarrow +\infty}{\sim} \frac{1}{T} \sum_{h \in \mathbb{Z}} \gamma_X(h) \underset{T \rightarrow +\infty}{\rightarrow} 0 \quad \text{vitene en } \frac{1}{T}$$

on a donc un TCL

$$\sqrt{T}(\bar{X}_T - 0) \xrightarrow[T \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \sum_{h \in \mathbb{Z}} \gamma_X(h))$$

$$\text{on a } \gamma_X(h) = \sum_j a_j a_{j-h} \sigma_\varepsilon^2$$

$$\Rightarrow \sum_{h \in \mathbb{Z}} \gamma_X(h) = \sum_{h \in \mathbb{Z}} \sum_{j \in \mathbb{Z}} a_j a_{j-h} \sigma_\varepsilon^2 = \left(\sum_{j \in \mathbb{Z}} a_j \right)^2 \sigma_\varepsilon^2$$

Exercice $X_t = \varepsilon_t - \varepsilon_{t-1}$

$$\frac{1}{T} \sum_{t=1}^T X_t = \frac{1}{T} (\varepsilon_T - \varepsilon_0) \quad \mathbb{V}\left[\frac{1}{T} \sum_{t=1}^T X_t\right] = \frac{1}{T^2} 2\sigma_\varepsilon^2$$

vitene en $\frac{1}{T^2}$

L'estimateur de l'autocovariance n'est pas sans biais.

Exemples avec des processus stationnaires.

Exemples d'identification avec autocovariance partielle

autocovariance

autocorrélation

* BBF (Font)

auto-corrélogramme ACF

en 0 ça fait 1 OK

ailleurs nul théoriquement OK

La quasi totalité des valeurs calculées sont entre les pointillés bleus (intervalles de confiance) donc on accepte statistiquement que c'est nul.

autocorrelation partielle (pas défini en 0)

Partial ACF que 0. c'est normal

$H_0 : (\neq 0)$ on accepte H_0 car dans les pointillés bleus.

* MA(1)

ACF

1 en 0 OK

$\neq 0$ en 1 et -1 OK

nul ailleurs statistiquement vrai donc OK

Partial ACF

croissance exponentielle

en pratique nul partout sauf 0.

alors qui on est censé être \neq de 0.

* AR(1) \Rightarrow 1 seul bâton significatif dans Partial ACF

AIF décaissante exponentielle

$$= \varphi$$

Partial ACF \neq en 0 : doit être égal à $\overline{0,5}$ ($\text{rx}(1) = \varphi$)

le reste est nul (statistiquement vrai) OK

Exemples avec des

processus non stationnaires

1) marche aléatoire

on rend stationnaire en faisant la différence

2) $m_t + K_t \varepsilon_t$ on centre et réduit pour stationnarisier

L'autocorrélogramme peut servir sur l'indication de la stationnarité.

méthode Buys Ballot

trend on décroît

lentement

méthode STL

→ il reste trend

on a des vagues

il reste une saisonnalité !

il y a une dépendance

au temps qui perdure

(pendant au moins 2

périodes)

on a pas bien éliminé

la saisonnalité.

Exemples séries réelles

variance change au cours du temps

modèle hétérosédastique.

Rentabilité log

ACF → on voudrait conclure

BBF

Partial ACF → statistiquement nul

on fait log au carré

ACF valeurs significatives & décroissance lente

→ dépendance forte et longue

c'est la volatilité des marchés financiers qui persiste

Conclusion

BB faible en regardant log et log au carré

Chapitre 6 Processus ARMA,

ARIMA, SARIMA.

6.1) Polynômes retard et avancé

Opérateur retard L : $LX_t = X_{t-1}$

opérateur avancé F : $FX_t = X_{t+1}$

$$L = F^{-1} \Leftrightarrow L^{-1} = F \Leftrightarrow L \circ F = \text{Id}$$

$$L^k X_t = X_{t-k} \quad F^k X_t = X_{t+k}$$

coefficients réels.

$$\begin{aligned} \text{Polynôme associé à } L \\ P(z) = \sum_{k=0}^P a_k z^k \end{aligned} \quad \Rightarrow P(L) = \sum_{k=0}^P a_k L^k$$

$$A(L) = \sum_{k \in \mathbb{Z}} a_k L^k$$

$$A(L) X_t = \sum_{k \in \mathbb{Z}} a_k X_{t-k} \quad (X_t)_t \text{ stationnaire}$$

$$\text{existe } n \text{ tel que } \sum_{k \in \mathbb{Z}} |a_k| < +\infty.$$

Produit de 2 polynômes retards infinis

$$A(L)$$

est un polynôme retard infini

$$B(L)$$

$$A(L) B(L) = C(L) = \sum_{k \in \mathbb{Z}} c_k L^k \quad (\Delta c_k = a_k b_k)$$

$$\text{Preuve} \quad \text{On a } A(L) B(L) = \sum_k a_k \sum_l b_l L^{k+l}$$

$$= \sum_j \left(\underbrace{\sum_k a_k b_{j-k}}_c \right) L^j \quad \text{produit de convolution}$$

▷ Inversibilité des polynômes en L

$$A(L) = \sum_{k=0}^p a_k L^k \quad \exists B(L) / A(L) B(L) = B(L) A(L) = \text{Id}$$

Coefficients réels \Rightarrow on peut factoriser par des monômes.

$$A(L) = a_p \prod_{k=1}^p (L - \mu_k) = a_0 \prod_{k=1}^p (1 - \lambda_k L)$$

μ_k racines

$$\text{avec } \lambda_k = \frac{1}{\mu_k}$$

On doit maintenant regarder si les monômes sont inversibles.
 $Q = (1 - \lambda L)$ inversible ($\Rightarrow \exists B(L) (1 - \lambda L) B(L) = \text{Id}$)

(cas 1) $|\lambda| < 1$

on cherche " $(1 - \lambda L)^{-1}$ " = $\frac{1}{1 - \lambda L} = \sum_{k=0}^{\infty} \lambda^k L^k$

on développe

sur les termes
partis

bien défini
 $\text{car } \sum |\lambda|^k < +\infty$.

$$\text{et } (1 - \lambda L) \sum_{k=0}^{\infty} \lambda^k L^k = \sum_{k=0}^{\infty} \lambda^k L^k - \sum_{k=1}^{\infty} \lambda^k L^k = \lambda^0 L^0 = 1.$$

L'inverse existe et c'est 5

(cas 2) $|\lambda| > 1$

$$(1 - \lambda L) = -\lambda L \left(1 - \frac{1}{\lambda} F\right)$$

inversible irreversible

$$|\frac{1}{\lambda}| < 1$$

$$\Rightarrow (1 - \lambda L)^{-1} = -\frac{1}{\lambda} F \sum_{k=0}^{\infty} \frac{1}{\lambda^k} F^k = -\sum_{k=1}^{\infty} \frac{F^k}{\lambda^k} = -\sum_{k=1}^{\infty} \frac{L^{-k}}{\lambda^k}$$

ici on développe sur le futur.

Ex 3 $|\lambda| = 1$ non inversible

Exercice à faire par raisonnement par l'absurde quand $\lambda = 1$.

$A(L)$ est inversible si toutes ses racines sont de module \neq de 1.

$$\text{Rmq : } A(L) = a_0 \prod_{k=1}^p (1 - \lambda_k L)$$

Si toutes les racines sont de module > 1

$$(|\lambda_k| < 1)$$

$$A^{-1}(L) = \sum_{k=0}^{\infty} b_k L^k \quad \text{avec } \sum |b_k| < \infty.$$

$k \in \mathbb{N}$

S'il existe une racine de module > 1 et 1 de module < 1

$$A^{-1}(L) = \sum_{k \in \mathbb{Z}} b_k L^k$$

on regarde dans le futur
mais on a pas les observations du futur

Ne pas retenir Méthode 1

la méthode de calculer l'inverse de chaque monôme et d'en faire le produit
 \Rightarrow trop de produits de convolution à identifier.

Méthode 2 on identifie les coefficients.

on connaît les ϕ_i

$$a_1 = -\phi_1$$

$$a_2 = -\phi_2 + \phi_1^2$$

\vdots

\vdots

Méthode 3 ne marche qu'en multiplié 1

4.2) Processus MA(q).

$(\varepsilon_t) \sim \text{BB}(0, \sigma_\varepsilon^2)$ bruit blanc faible.

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \dots - \theta_q \varepsilon_{t-q}$$

on a q retards

on augmente la dépendance temporelle de X_t .

$X_t, X_{t-1}, \dots, X_t, X_{t-q}$ corrélés (2 à 2)

Processus stationnaire par construction

$$X_t = \underbrace{\Phi(L)}_{\text{definition d'un polynôme retard}} \varepsilon_t \quad \text{avec } \Phi(u) = 1 - \theta_1 u - \dots - \theta_q u^q$$

definition d'un polynôme retard

(ε_t) est-il le processus des innovations de (X_t) ?

$$\text{aid } \varepsilon_t = \mathbb{E}_L[X_t | \underline{X_{t-1}}] \quad \text{avec}$$

projection
linéaire.

$$\underline{X_{t-1}} = \text{en } \{X_{t-1}, X_{t-2}, X_{t-3}, \dots\}$$

ensemble du passé du processus

$X_t \in \underline{\varepsilon_t}$ car \mathbb{E}_L des $\varepsilon_t, \varepsilon_{t-1}, \dots$
par définition

$$\text{et } X_{t-1} \in \underline{\varepsilon_{t-1}} \subset \underline{\varepsilon_t} \quad \text{donc } \underline{X_t} \subset \underline{\varepsilon_t}$$

Hypothèse les racines de Φ sont de module > 1

$$\Rightarrow \Phi^{-1}(L) = \sum_{k \in \mathbb{N}} b_k L^k$$

$$\varepsilon_t = \Phi^{-1}(L) X_t = \sum_{k \in \mathbb{N}} b_k X_{t-k} \Rightarrow \varepsilon_t \in \underline{X_t}$$

$$\varepsilon_{t-1} \in \underline{X_{t-1}} \subset \underline{X_t}$$

$$\Rightarrow \underline{\varepsilon_t} \subset \underline{X_t}$$

$$\Rightarrow \underline{\varepsilon_t} = \underline{X_t}$$

changement de base

$$\mathbb{E} L [X_t | \underline{X_{t-1}}] = \mathbb{E} L [X_t | \underline{\varepsilon_{t-1}}]$$

↑ base orthogonale
car non corrélé 2 à 2.

$$= \mathbb{E} L [\varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} | \underline{\varepsilon_{t-1}}]$$

$$\varepsilon_t \perp \varepsilon_k$$

$$k \in [t-1, \dots]$$

$$\mathbb{E} [\varepsilon_{t-1} | \underline{\varepsilon_{t-1}}]$$

$= \varepsilon_{t-1}$ invariant
car dans
l'espace

$$= 0 - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

$$= X_t - \varepsilon_t.$$

$$\text{donc on a bien } \varepsilon_t = X_t - \mathbb{E} L [X_t | \underline{X_{t-1}}]$$

Et c'est le processus d'innovation de X_t .

29/11/23 SERIES TEMPORELLES

$$MA(q) : X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

$$\varepsilon_t = X_t - \text{IEL}[X_t | \underline{X_{t-1}}] ?$$

Définition $\varepsilon_t = X_t - \text{IEL}[X_t | \underline{X_{t-1}}]$

si (ε_t) est l'innovation.

Dans ce cas, $X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$ est l'écriture canonique.

$\Theta(L) = 1 - \theta_1 L - \dots - \theta_q L^q$ est le polynôme retard

Prop L'écriture canonique existe si les racines de Θ sont de module > 1

Preuve

Soient μ_i les q racines de Θ , $\lambda_i = \frac{1}{\mu_i}$

$$\Rightarrow \Theta(L) = \prod_{i=1}^q (1 - \lambda_i L)$$

Comme $|\mu_i| > 1 \Leftrightarrow |\lambda_i| < 1 \Rightarrow (1 - \lambda_i L)^{-1} = \sum_{k=0}^{\infty} \lambda_i^k L^k$

$$\Rightarrow \Theta(L) = \sum_{k=0}^{\infty} a_k L^k$$

$$\text{On a } X_t = \Theta(L) \varepsilon_t \quad \mathcal{L}(X_t) \subset \mathcal{L}(\underline{\varepsilon_t})$$

$$\Rightarrow \mathcal{L}(X_t) \subset \mathcal{L}(\underline{\varepsilon_t})$$

NB
 $\underline{\varepsilon} = \text{Historique}$
 Histoire

$$\varepsilon_t = \Theta^{-1}(L) X_t = \sum_{k=0}^{\infty} a_k X_{t-k} \quad \mathcal{L}(\varepsilon_t) \subset \mathcal{L}(X_t)$$

$$\Rightarrow \mathcal{L}(\underline{\varepsilon_t}) \subset \mathcal{L}(X_t)$$

$$\text{D'où } \mathcal{L}(\underline{\varepsilon_t}) = \mathcal{L}(X_t)$$

$$\text{IEL}[X_t | \underline{X_{t-1}}] = \text{IEL}[X_t | \underline{\varepsilon_{t-1}}]$$

$$= \text{IEL}\left[\underbrace{\varepsilon_t}_{\notin \underline{\varepsilon_{t-1}}} - \theta_1 \underbrace{\varepsilon_{t-1}}_{\in \underline{\varepsilon_{t-1}}} - \dots - \theta_q \varepsilon_{t-q} \mid \underline{\varepsilon_{t-1}}\right]$$

$$= 0 - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

$$\text{D'où } X_t - \mathbb{E}[X_t | \underline{X_{t-1}}] = \varepsilon_t$$

Maintenant on considère que

$$\textcircled{n}(L) = \prod_{|\lambda_i| < 1} (1 - \lambda_i L) \prod_{|\lambda_i| > 1} (1 - \lambda_i L) \\ |\mu_i| > 1 \quad |\mu_i| < 1$$

$$\textcircled{n}^*(L) = \prod_{|\lambda_i| < 1} (1 - \lambda_i L) \prod_{|\lambda_i| > 1} \left(1 - \frac{1}{\lambda_i} L\right)$$

Proposition

On se retrouve avec 2 écritures équivalentes

$$X_t = \textcircled{n}(L) \varepsilon_t \quad \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

$$X_t = \textcircled{n}^*(L) \eta_t \quad \eta_t \sim BB(0, \sigma_\eta^2)$$

$$\sigma_\eta^2 = \sigma_\varepsilon^2 \prod_{|\lambda_i| > 1} |\lambda_i|^2$$

Preuve

$$X_t = \textcircled{n}(L) \varepsilon_t \Rightarrow f_X(\omega) = |\textcircled{n}(e^{i\omega})|^2 \frac{\sigma_\varepsilon^2}{2\pi}$$

X est une transformation linéaire
de ε_t qui est stationnaire

$$X_t = \textcircled{n}^*(L) \eta_t \Rightarrow f_X(\omega) = |\textcircled{n}^*(e^{i\omega})|^2 \frac{\sigma_\eta^2}{2\pi}$$

$$(*) = \prod_{|\lambda_j| < 1} |1 - \lambda_j e^{i\omega}|^2 \prod_{|\lambda_j| > 1} |1 - \lambda_j e^{i\omega}|^2$$

$$(**) = \prod_{|\lambda_j| < 1} |1 - \lambda_j e^{i\omega}|^2 \prod_{|\lambda_j| > 1} |1 - \frac{1}{\lambda_j} e^{i\omega}|^2$$

On regarde pour $|\lambda_j| > 1$, ce que vaut $\frac{|1 - \lambda_j e^{i\omega}|^2}{|1 - \frac{1}{\lambda_j} e^{i\omega}|^2}$

$$= \frac{|1 - \lambda_j e^{i\omega}|^2}{\left|\frac{1}{\lambda_j} e^{i\omega}\right|^2 |1 - \lambda_j e^{-i\omega}|^2} = \frac{1}{\left|\frac{1}{\lambda_j} e^{i\omega}\right|^2} = |\lambda_j|^2 \text{ indépendant de } \omega$$

sont conjugués
donc égaux en module

$$\text{en posant } \sigma_{\eta}^2 = \sigma_{\varepsilon}^2 \pi |\lambda_j|^2$$

On a bien que nos 2 échelles spectrales pour X sont égales.

D'où (η_t) est l'innovation

$\Rightarrow X_t = \Phi^*(L)\eta_t$ est l'échelle canonique

$$\Rightarrow \eta_t = (\Phi^*(L))^{-1}X_t = \sum_{k=0}^{\infty} a_k X_{t-k}$$

4.3 Processus auto-régressifs d'ordre p : AR(p)

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \varepsilon_t$$

avec $(\varepsilon_t)_{t \in \mathbb{Z}} \sim BB(0, \sigma_{\varepsilon}^2)$

$$\Leftrightarrow \phi(L)X_t = \varepsilon_t \text{ avec } \phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$$

Rmq $X_t = \mu + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t$

Si (X_t) est stationnaire alors

$$\begin{aligned} \mathbb{E}[X_t] &= \mu + \phi_1 \underbrace{\mathbb{E}[X_{t-1}]}_{= \mathbb{E}[X_t]} - \dots - \phi_p \underbrace{\mathbb{E}[X_{t-p}]}_{= \mathbb{E}[X_t]} + 0 \\ &\quad \text{car stationnaire} \quad \mathbb{E}[\varepsilon_t] = 0 \quad \text{car } BB \end{aligned}$$

$$\Rightarrow \mathbb{E}[X_t] = \frac{\mu}{1 - \phi_1 - \dots - \phi_p} \quad \text{si } 1 - \phi_1 - \dots - \phi_p \neq 0$$

si 1 n'est pas racine de ϕ

$$(X_t) \text{ existe si } X_t = \underbrace{\phi^{-1}(L)}_{= \sum_{k \in \mathbb{Z}} b_k L^k} \varepsilon_t$$

$$= \sum_{k \in \mathbb{Z}} b_k L^k \text{ avec } \sum_{k \in \mathbb{Z}} |b_k| < \infty.$$

\Leftrightarrow toutes les racines de ϕ sont de module $\neq 1$

Exemple $X_t = X_{t-1} + \varepsilon_t \quad \phi_1 = 1$

$$\Leftrightarrow (1-L) X_t = \varepsilon_t$$

$$\phi(L) = 1 - L \quad \text{racine } = 1$$

ϕ est non inversible donc (X_t) non stationnaire

On peut le rendre stationnaire en faisant la différence.

Proposition $\phi(L) X_t = \varepsilon_t$ est l'écriture canonique

$$\Leftrightarrow \varepsilon_t = X_t - \mathbb{E} L[X_t | \underline{X_{t-1}}] \quad (\varepsilon_t \text{ est l'innovation})$$

\Leftrightarrow les racines de ϕ sont de module > 1

Preuve

$$\varepsilon_t = \phi(L) X_t \Rightarrow \mathcal{L}(\varepsilon_t) \subset \mathcal{L}(X_t)$$

$$\Rightarrow \mathcal{L}(\underline{\varepsilon_t}) \subset \mathcal{L}(\underline{X_t})$$

$$X_t = \phi^{-1}(L) \varepsilon_t \Rightarrow \mathcal{L}(X_t) \subset \mathcal{L}(\underline{\varepsilon_t}) \rightarrow \mathcal{L}(\varepsilon_t)$$

$$= \sum_{k=0}^{\infty} b_k \varepsilon_{t-k} \Rightarrow \mathcal{L}(X_t) \subset \mathcal{L}(\underline{\varepsilon_t}) \rightarrow \mathcal{L}(X_t) = \mathcal{L}(\underline{\varepsilon_t})$$

racines module $\neq 1$
et même module > 1
d'où l'inverse est

$$\mathbb{E} L[X_t | \underline{X_{t-1}}] = \mathbb{E} L[\phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t | \underline{X_{t-1}}]$$

$$= \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + 0$$

$$\mathbb{E} [\varepsilon_t | \underline{X_{t-1}}]$$

$$= \mathbb{E} [\varepsilon_t | \underline{\varepsilon_{t-1}}]$$

$$= 0 \quad \text{car } \varepsilon_t \text{ B.B}$$

donc ε_t à $\underline{X_{t-1}}$ orthogonale

D'où $X_t - \mathbb{E} L[X_t | \underline{X_{t-1}}] = \varepsilon_t$
Conclusion $(\varepsilon_t)_t$ est l'innovation.

Proposition $\phi(L)X_t = \varepsilon_t \quad \phi^*(L)X_t = \eta_t$

$$\phi(L) = \prod_{|\lambda_i| < 1} (1 - \lambda_i L) \prod_{|\lambda_i| > 1} (1 - \frac{1}{\lambda_i} L)$$

$$\phi^*(L) = \prod_{|\lambda_i| < 1} (1 - \lambda_i L) \prod_{|\lambda_i| > 1} (1 - \frac{1}{\lambda_i} L)$$

Pour que la densité spectrale soit identique

$$\sigma_\eta^2 = \frac{1}{\pi \sum_{|\lambda_i| > 1} |\lambda_i|^2} \sigma_\varepsilon^2$$

$\phi(L)X_t = \varepsilon_t$ forme canonique ($\mathbb{E}[X_t] = 0$)

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t$$

$\Rightarrow \mathbb{E}[X_t]$
et on prend \mathbb{E}

$$\mathbb{E}[X_t] = \gamma_X(0) = \phi_1 \gamma_X(1) + \dots + \phi_p \gamma_X(p) + \underbrace{\mathbb{E}[X_t \varepsilon_t]}_{= \text{Cov}(X_t, \varepsilon_t)}$$

on fait $\times \varepsilon_t$ et on prend l' \mathbb{E}

$$\mathbb{E}[X_t \varepsilon_t] = \phi_1 \underbrace{\mathbb{E}[X_{t-1} \varepsilon_t]}_{= 0} + \dots + \phi_p \underbrace{\mathbb{E}[X_{t-p} \varepsilon_t]}_{= 0} + \underbrace{\mathbb{E}[\varepsilon_t^2]}_{= \mathbb{V}(\varepsilon_t)} = \mathbb{V}(\varepsilon_t) = \sigma_\varepsilon^2$$

car $\varepsilon_t \perp \!\!\! \perp X_{t-1}$
par la forme canonique
car (ε_t) est l'innovation

$$\Rightarrow \mathbb{E}[X_t \varepsilon_t] = \sigma_\varepsilon^2$$

on fait $\times X_{t-h}$ et on prend l' \mathbb{E}

$$\mathbb{E}[X_t X_{t-h}] = \gamma_X(h) = \phi_1 \gamma_X(h-1) + \phi_2 \gamma_X(h-2)$$

$$+ \dots + \phi_p \gamma_X(h-p) + \underbrace{\mathbb{E}[\varepsilon_t X_{t-h}]}_{= 0}$$

Equation de récurrence linéaire

$$-\phi_p \gamma_X(h-p) - \phi_{p-1} \gamma_X(p-h+1) - \dots - \phi_1 \gamma_X(h-1) + \gamma_X(h) = 0$$

$$\alpha_0 z_n + \dots + \alpha_p z_{n+p} = 0$$

Le polynôme associé est $P(z) = -\phi_p - \phi_{p-1}z - \dots - \phi_1 z^{p-1} + z^p$

$$\Rightarrow -\phi_p - \phi_{p-1}z - \dots - \phi_1 z^{p-1} + z^p = z^p \phi(z^{-1})$$

Les racines de P sont les inverses des racines de ϕ donc elles sont de module < 1 de module > 1 car forme canonique

Conclusion $\gamma_X(h) \xrightarrow[h \rightarrow 0]{} 0$

$\gamma_X(h)$ converge exponentiellement vite vers 0

\Rightarrow il n'y aura plus de cov entre X_t et X_{t-h}

\Rightarrow on aura pas besoin de revenir loin en arrière dans l'historique pour faire de la prévision

La dépendance dérouté exponentiellement vite vers 0.

On écrit sous forme matricielle les équations de récurrence linéaire

$$\begin{pmatrix} \gamma_X(1) \\ \gamma_X(2) \\ \vdots \\ \gamma_X(p) \end{pmatrix} = \begin{pmatrix} \gamma_X(0) & \gamma_X(1) & \gamma_X(2) & \dots & \gamma_X(p-1) \\ \gamma_X(1) & \gamma_X(0) & \gamma_X(1) & \dots & \gamma_X(p-2) \\ \vdots & & & & \\ \gamma_X(p) & & & & \end{pmatrix} \begin{pmatrix} \phi_1 \\ | \\ | \\ | \\ \phi_p \end{pmatrix} \quad \forall h.$$

matrice d'autocovariance connue à partir de nos données et inversible

Système de Yule Walker

Autocorrélation partielle de $(X_t)_{t \in \mathbb{Z}}$

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t$$

$$\text{IEL}[X_t | X_{t-1}, \dots, X_{t-k}] \quad \text{avec } k > p$$

$$= \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + 0$$

car ε_t est
l'innovation

$$r_X(k) = 0 \quad \text{car le coefficient devant } X_{t-k} \text{ est } 0$$

$$k = p \quad r_X(p) = \phi_p$$

Autocorrélation inverse de $(X_t)_{t \in \mathbb{Z}}$

$$\phi(L) X_t = \varepsilon_t$$

$$|\phi(e^{i\omega})|^2 f_X(\omega) = f_\varepsilon(\omega)$$

$$\Rightarrow f_X(\omega) = \frac{\sigma_\varepsilon^2}{2\pi} \frac{1}{|\phi(e^{i\omega})|^2}$$

$$\Rightarrow \frac{1}{f_X(\omega)} = \frac{2\pi}{\sigma_\varepsilon^2} |\phi(e^{i\omega})|^2 = \frac{1}{2\pi} \frac{(2\pi)^2}{\sigma_\varepsilon^2} |\phi(e^{i\omega})|^2$$

$$= f_Y(\omega)$$

$$\text{avec } Y_t = \phi(L) \eta_t \quad \text{avec } (\eta_t) \sim \text{BB}(0, \frac{(2\pi)^2}{\sigma_\varepsilon^2})$$

$$Y_t \sim \text{MA}(p)$$

Conclusion $r_X^i(h) = f_Y(h) = 0$ pour $|h| > p$.

Exemple AR(1) $X_t = \phi_1 X_{t-1} + \varepsilon_t$

$$\phi(L) = 1 - \phi_1 L$$

- $|\phi_1| < 1$ forme canonique

$$X_t = \underbrace{\phi^{-1}(L)}_{|\phi_1| \neq 1} \varepsilon_t = \left(\sum_{k=0}^{\infty} \phi_1^k L^k \right) \varepsilon_t = \sum_{k=0}^{\infty} \phi_1^k \varepsilon_{t-k}$$

donc inversible

- $|\phi_1| > 1$ module $\neq 1$ donc inversible

$$X_t = \phi^{-1}(L) \varepsilon_t = - \left(\sum_{k=1}^{\infty} \phi_1^{-k} L^{-k} \right) \varepsilon_t$$

$$\text{car } (-\varepsilon_t)_t \text{ BB}(0, \sigma^2_\varepsilon) \stackrel{?}{=} \sum_{k=1}^{\infty} \phi_1^{-k} \varepsilon_{t+k} = F^{\text{inv}}$$

NB : si $(\varepsilon_t)_t$ BB
(0, σ^2_ε)

on change pour obtenir la forme canonique

$$\phi^*(L) = 1 - \phi_1^{-1} L$$

$$X_t = \phi_1^{-1} X_{t-1} + \eta_t \quad \text{avec } \sigma^2_\eta = \frac{\sigma^2_\varepsilon}{\phi_1^2}$$

$(-\varepsilon_t)_t$ BB aussi

$$\mathbb{E}[-\varepsilon_t] = 0$$

$$\mathbb{V}(-\varepsilon_t) = \mathbb{V}(\varepsilon_t) = \sigma^2_\varepsilon$$

$$\begin{aligned} \text{Cov}(-\varepsilon_t, -\varepsilon_s) &= \text{Cov}(\varepsilon_t, \varepsilon_s) \\ &= 0 \end{aligned}$$

- $|\phi_1| < 1$

$$\mathbb{E}[X_t] = 0$$

$$\mathbb{V}[X_t] = \frac{1}{1 - \phi_1^2} \sigma^2_\varepsilon$$

$$= \frac{1}{\phi_1^2 - 1} \sigma^2_\varepsilon$$

- $|\phi_1| > 1$

$$\mathbb{E}[X_t] = 0$$

$$\mathbb{V}[X_t] = \sum_{k=1}^{\infty} \phi_1^{-2k} \sigma^2_\varepsilon$$

$$\left[\frac{\phi_1^{-2}}{1 - \phi_1^{-2}} \sigma^2_\varepsilon \right] = \frac{1}{\phi_1^2 - 1} \sigma^2_\varepsilon$$

par en forme canonique

on a la même variance

$$\mathbb{E}[X_t] = 0$$

$$\mathbb{V}[X_t] = \frac{\sigma^2_\eta}{1 - \phi_1^{-2}} = \frac{\sigma^2_\varepsilon}{\phi_1^2 - 1}$$

en forme canonique

- $|\phi_1| < 1$

$$X_t = \phi_1 X_{t-1} + \varepsilon_t$$

on multiplie par X_{t-1} et on prend l'VE
 $\gamma_X(1) = \phi_1 \gamma_X(0)$

avec X_{t-h} au lieu de X_{t-1}

$$\begin{aligned}\gamma_X(h) &= \phi_1 \gamma_X(h-1) = \phi_1^h \gamma_X(0) = \phi_1^h \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} \\ &= \phi_1^2 \gamma_X(h-2) \\ &= \phi_1^3 \gamma_X(h-3) \dots\end{aligned}$$

$$\gamma_X(1) = \phi_1 = p_X(1) \text{ car } \phi_1 = \frac{\gamma_X(1)}{\gamma_X(0)} = p_X(1)$$

$$\gamma_X(h) = 0 \text{ pour } h > 1 \quad \text{par def}$$

- $f_X(\omega) = \frac{\sigma_\varepsilon^2}{2\pi} \frac{1}{|1 - \phi_1 e^{i\omega}|^2} \quad X_t = \phi_1 X_{t-1} + \varepsilon_t \sim AR(1)$

$$f_Y(\omega) = \frac{1}{f_X(\omega)} = \frac{1}{2\pi} \frac{(2\pi)^2}{\sigma_\varepsilon^2} |1 - \phi_1 e^{i\omega}|^2 \quad Y_t = \eta_t - \phi_1 \eta_{t-1} \quad \text{MA(1)}$$

- $\hat{p}_X(h) = \hat{p}_Y(h) = \frac{\gamma_Y(h)}{\gamma_Y(0)} = \begin{cases} \frac{-\phi_1}{1 + \phi_1^2} & \text{pour } h = \pm 1 \\ 0 & \text{pour } |h| > 1 \end{cases}$

7/12/2023

SÉRIES TEMPORELLES.

4.4 Processus ARMA(p, q)

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

avec (ε_t) l'innovation (donc orthogonal au passé de X_{t-1})

On multiplie par X_{t-h} et on prend l'IE

pour $h \geq q$

$$\gamma_X(h) = \phi_1 \gamma_X(h-1) + \dots + \phi_p \gamma_X(h-p)$$

On écrit pour $h = q+1, \dots, q+p$ pour obtenir p équations de Yule-Walker.

4.5 Processus ARIMA(p, d, q)

$$\text{Marche aléatoire } X_t = X_{t-1} + \varepsilon_t \quad (\varepsilon_t) \sim \mathcal{BB}(0, \sigma^2_\varepsilon)$$

$$\left. \begin{array}{l} X_0 \\ (1-L)X_t = \varepsilon_t \end{array} \right\} \Rightarrow \text{NON STATIONNAIRE}$$

$$\underbrace{\Delta}_{= \Delta} X_t = \varepsilon_t \sim \mathcal{BB}(0, \sigma^2_\varepsilon) \quad \nearrow (1-L)^d \text{ on différencie } d \text{ fois.}$$

$$\text{ARIMA}(p, d, q) \quad \phi(L) \Delta^d X_t = \Theta(L) \varepsilon_t \quad d \geq 1$$

$$\text{degré } \phi = p \quad (\Rightarrow \phi_p \neq 0)$$

$$\text{degré } \Theta = q \quad (\Rightarrow \Theta_q \neq 0)$$

non stationnaire


= homogène dans le temps

Donc on pose des conditions initiales
car on ne peut pas laisser le processus venir de n'importe quel instant dans le temps.

6.6 SARIMA $(p, d, q)(P, D, Q)$

NB:

Sert pour saisonnalité



On a une double dynamique temporelle

effet annuel

polynôme retard d'une année sur l'autre

effet mode = dynamique annuelle

$$\phi(L^{12})X_t = \Theta(L^{12})U_t \text{ ARMA}(p, q) \text{ (magazines, ...)}$$

de l'année 1 sur 2

effet mensuel

$$\phi(L)U_t = \Theta(L)\varepsilon_t \text{ ARMA}(p, q)$$

$$(\varepsilon_t) \sim BB(0, 6\varepsilon)$$

$$\Rightarrow \phi(L^{12})\phi(L)X_t = \Theta(L^{12})\Theta(L)\varepsilon_t$$

SARMA₁₂ $(p, q)(P, Q)$ Exemple $\underbrace{\text{mensuel}}_{n} \underbrace{\text{annuel}}$ * SARIMA $(0, 0, 1)^{(1, 0, 0)}$

correspond à

$$X_t - \varphi X_{t-12} = \varepsilon_t + \theta \varepsilon_{t-1}$$

avec comme conditions

$$|\varphi| < 1$$

$$|\theta| < 1$$

pour que X_t soit stationnaire

$$X_t = (1 - \varphi L^{12})^{-1}(1 + \theta L)\varepsilon_t$$

$$= \sum_{k=0}^{\infty} \varphi^k L^{12k} (1 + \theta L)\varepsilon_t$$

$$= \varepsilon_t + \theta \varepsilon_{t-1} + \varphi \varepsilon_{t-12} + \varphi \theta \varepsilon_{t-13} + \varphi^2 \varepsilon_{t-24} + \varphi^2 \theta \varepsilon_{t-25} + \dots$$

$$\star \star \mathbb{E}[X_t] = 0$$

$$\star \star \star \mathbb{V}[X_t] = (1 + \theta^2) \frac{1}{1 - \varphi^2} \sigma_{\varepsilon}^2$$

(NB les ε_t sont de $\text{cov} = 0$)

$\mathbb{V}[X_t]$ existe car processus stationnaires

$$\text{on a } X_t = \varphi X_{t-12} + \varepsilon_t + \theta \varepsilon_{t-1} \quad (\star)$$

$$\Rightarrow \mathbb{V}[X_t] = \varphi^2 \mathbb{V}[X_{t-12}] + (1 + \theta^2) \sigma_{\varepsilon}^2 + \varphi \text{Cov}(X_{t-12}, \varepsilon_t) + \theta \text{Cov}(X_{t-12}, \varepsilon_{t-1}) + \theta \text{Cov}(\varepsilon_t, \varepsilon_{t-1})$$

$$\Rightarrow \mathbb{V}[X_t] = \frac{1}{1 - \varphi^2} (1 + \theta^2) \sigma_{\varepsilon}^2$$

stationnaire

$$\text{d'où } \mathbb{V}[X_t] = \mathbb{V}[X_{t-12}]$$

$$(\star) \times X_{t-1} \text{ et on prend l'IE : } \gamma_X(1) = \varphi \gamma_X(11) + 0 +$$

$$(\star) \times \varepsilon_t \text{ et on prend l'IE : }$$

$$\text{Cov}(X_t, \varepsilon_t) = 0 + \sigma_{\varepsilon}^2 + 0$$

$$(\star) \times X_{t-11} \text{ et on prend l'IE : }$$

$$\gamma_X(11) = \varphi \gamma_X(1)$$

$$\text{D'où } \gamma_X(1) = \frac{1}{1 - \varphi} \theta \sigma_{\varepsilon}^2$$

Pour avoir $\gamma_X(2)$:


$$\begin{aligned} (\star) \times X_{t-2} \text{ et IE : } \gamma_X(2) &= \varphi \gamma_X(10) \\ (\star) \times X_{t-10} \text{ et IE : } \gamma_X(10) &= \varphi \gamma_X(2) \end{aligned} \quad \left. \right\} \Rightarrow \gamma_X(2) = 0 \quad \gamma_X(10) = 0$$

NB $\text{Cov}(X_{t-h}, \varepsilon_{t-1})$ pour $h > 1 = 0$ car innovation

ce qui donne $\rho_X(12h) = \varphi^h$

$$\rho_X(12h-1) = \rho_X(12h+1) = \frac{\theta}{1 + \theta^2} \varphi^h$$

$$\rho_X(h) = 0 \text{ sinon}$$



effet auto régressif tous les ans
= influence d'une année sur l'autre
décrissante en $\varphi^{h/12}$

effet MA
= influence d'un mois sur l'autre

Chapitre 5

Estimation ARMA et ARIMA

On doit estimer p , d et q qui sont des entiers naturels !

On ne peut pas estimer aussi facilement que des réels que l'on peut approcher au fur et à mesure et qu'on finira par atteindre avec TLL. Alors que pour les entiers naturels soit c'est bon soit c'est faux.

Il faut faire une identification a priori (de p , d et q) en proposant des valeurs réalisables/appropriées

ensuite il faut déterminer les coefficients des polynômes.

Méthodes usuelles : maximum de vraisemblance, moindres carrés, méthode des moments

Vérification

* On doit tester que φ_p et Θ_q soient significativement différents de 0 : on recommande le modèle avec un degré en moins etc...

* Vérifier que (ϵ_t) est un BB. de nombreux en estimant son autocorrélation (tests existent) en estimant d'abord ϵ_t et en partant de $\phi(L) \epsilon_t = \Theta(L) \epsilon_t \Rightarrow \Theta(L) \phi(L) \epsilon_t = \epsilon_t$

Choix d'un modèle


* Utiliser un choix de comparaison de modèles (si plusieurs bons modèles)

5.2

1^{re} étape identifier si stationnaire ou non ?

si non, car par ex [trend saisonnalité] déterministes on les enlève

Il y a des tests pour vérifier si stationnaire mais le prof préfère d'abord qui on fasse des analyses graphiques en regardant d'abord la série elle-même et sa forme.

 l'autocorrélogramme décroît très vite vers 0 quand stationnaire exponentiellement

NON STATIONNAIRE

et on aura des autocorrélogrammes comme ça

D'ailleurs pas sur-différencier (car on se rapproche du module = 1 par exemple $X_t = \epsilon_t$)

$$\Rightarrow \Delta X_t = \epsilon_t - \epsilon_{t-1} = \underbrace{(1-L)}_{\text{MA}(1)} \epsilon_t$$

racines du polynôme doivent être

> à 1.

$$\begin{array}{ll} \text{MA}(q) & f_X(h) = 0 \quad |h| > q \\ \text{AR}(p) & f_X(h) = 0 \quad |h| > p \end{array}$$

$$r_X(h) = 0 \quad h > p$$

$$\begin{array}{ll} \text{Test } H_0: \gamma_X(q+1) = 0 & \gamma_X(q+2) = 0 \\ H_1: \gamma_X(q+1) \neq 0 & \dots \end{array}$$

Loi asymptotique

$$\sqrt{T} \left(\hat{p}_x(h+q) - \underbrace{p_x(h+q)}_{h \geq 1} \right) \underset{T \rightarrow +\infty}{\sim} \mathcal{N}(0, 1 + \sum_{j=1}^q p_x^2(j))$$

autocorrelogramme empirique tend vers autocorrelogramme théorique.

Région d'acceptation 5%.

$$[0, 4/T(1 + \sum p_x^2(j))] \text{ Test du Khi 2.}$$

$\downarrow 1,96^2$ on remplace p par son estimateur.

Si on a une seule autocorrelation en 0 \Rightarrow MA(1)

$$(q = 1)$$

Pour p (du AR(p)) 1 seule valeur de l'autocorrelation partielle au inverse \Rightarrow AR(1) ($\Rightarrow p = 1$)

Mais si c'est un ARMA(p, q) comment estime-t-on p et q ?
on va regarder si ce sont des AR(p^*) ou MA(q^*)

$$\phi(L)x_t = \Theta(L)\varepsilon_t \Rightarrow x_t = \phi^{-1}(L)\Theta(L)\varepsilon_t$$

$$= \sum_{k=0}^{\infty} b_k \underbrace{\varepsilon_{t-k}}$$

décroît exponentiellement
 q^* vite vers 0.

$$\approx \sum_{k=0}^{q^*} b_k \varepsilon_{t-k}$$

$q^* > q \quad p^* \geq p$ On doit trouver q^* et p^* de telle sorte que $\text{ARMA}(p, q) = \text{MA}(q^*)$ et $\text{ARMA}(p, q) = \text{AR}(p^*)$ comme ils sont forcément supérieurs à p et q on va descendre en valeurs pour arriver aux vrais p et q .

Estimation d'un AR(ρ) $X_t = \phi_1 X_{t-1} + \dots + \phi_\rho X_{t-\rho} + \varepsilon_t$

Exemple

AR(1) $X_t = \phi X_{t-1} + \varepsilon_t$ représentation canonique
 $\Rightarrow |\phi| < 1$

$$\gamma_X(1) = \phi \gamma_X(0)$$

$$\phi = \rho_X(1)$$

$$\hat{\phi}_T = \frac{\frac{1}{T} \sum_{t=1}^{T-1} X_t X_{t-1}}{\frac{1}{T} \sum_{t=1}^T X_t^2}$$

$$\text{on a } \sqrt{T} (\hat{\phi}_T - \phi) \xrightarrow[T \rightarrow +\infty]{} \mathcal{N}(0, \frac{6\varepsilon^2}{\gamma_X(0)}) \quad \text{car}$$

$$\begin{aligned} \sqrt{T} (\hat{\phi}_T - \phi) &\xrightarrow[T \rightarrow +\infty]{} \mathcal{N}(0, 1 - \phi^2) & \gamma_X(0) \\ &= \mathbb{W}[X_t] \\ &= \frac{6\varepsilon^2}{1 - \phi^2} \end{aligned}$$

Vraisemblance

Densité associée à (X_1, \dots, X_T)

$$f(X_1, \dots, X_T) \stackrel{(x_1, \dots, x_T)}{\text{inconnue}} \quad \text{on suppose } \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$$

$$\text{mais on connaît } f_{X_t | X_{t-1}}(x_t, x_{t-1})$$

$$X_t = \phi X_{t-1} + \varepsilon_t \Rightarrow X_t | (X_{t-1} = x_{t-1}) \sim \mathcal{N}(\phi x_{t-1}, \sigma_\varepsilon^2)$$

$$\text{d'où } f_{X_t | X_{t-1}}(x_t, x_{t-1}) = \frac{1}{\sqrt{2\pi} \sigma_\varepsilon} e^{-\frac{1}{2\sigma_\varepsilon^2} (x_t - \phi x_{t-1})^2}$$

$$X_t = \sum_{k=0}^{\infty} \phi^k \varepsilon_{t-k} \Rightarrow X_t \sim \mathcal{N}(0, \frac{\sigma_\varepsilon^2}{1 - \phi^2})$$

par la même loi \mathcal{N}

$$\begin{aligned} f(X_1, \dots, X_T) &\stackrel{(x_1, \dots, x_T)}{=} \underbrace{f_{X_T | X_{T-1}, \dots, X_1}}_{= f_{X_T | X_{T-1}}} \underbrace{f_{X_{T-1}, \dots, X_1}}_{\text{apporte }} \\ &= f_{X_T | X_{T-1}} \text{ car } X_{T-2}, \dots, X_1 \text{ pas} \end{aligned}$$

d'informations supplémentaires car $X_t = \phi X_{t-1} + \varepsilon_t$

Exemple

$$\text{MA}(1) \quad X_t = \varepsilon_t + \theta \varepsilon_{t-1} \quad \hat{\theta}_T \quad \begin{array}{l} \text{Estimateur} \\ \text{du Maximum} \\ \text{de Vraisemblance} \\ (\text{EMV}) \end{array}$$

$$\text{on a } (Y_t) \sim \text{AR}(1) \Rightarrow \mathbb{V}[Y_t] = \frac{\sigma^2}{1-\theta^2}$$

$$\sqrt{T}(\hat{\theta}_T - \theta) \xrightarrow{D} \mathcal{N}(0, 1 - \theta^2)$$

$$X_t = \phi X_{t-1} + \varepsilon_t$$